

Sup Galilée

Inférence de paramètres dans les modèles SIR par Approximate Bayesian Computation

Yacques CHENGLI
Damien GANDREY

Déclaration d'intégrité académique

Nous certifions que ce rapport a été réalisé dans le cadre du projet portant sur l'inférence de paramètres dans les modèles épidémiologiques SIR.

Certains codes utilisés pour les simulations et les méthodes d'inférence ont été développés par des auteurs et sont disponibles dans le dépôt GitHub associé au projet.

Les articles scientifiques utilisés sont systématiquement cités dans la bibliographie.

Table des matières

1	Introduction	3
2	Contexte épidémiologique	3
2.1	Le modèle SIR	3
2.2	Nombre de reproduction de base	4
2.3	Nombre de reproduction effectif	4
2.3.1	Interprétation du nombre de reproduction effectif R_e	4
3	Inférence bayésienne et Approximate Bayesian Computation (ABC)	6
3.1	Fondement de l'inférence bayésienne	6
3.1.1	Pourquoi a-t on besoin d'utiliser l'inférence bayésienne	6
3.1.2	Quels sont les paramètres et les données	7
3.1.3	Principes de l'inférence bayésienne	7
3.2	Méthodes ABC	8
3.2.1	Premier algorithme : ABC-Rejet	8
3.2.2	Nouvelle algorithme : ABC-SMC (Sequential Monte-Carlo)	9
4	Étude de cas 1 : données simulées	9
4.1	Description du modèle et des paramètres simulés	9
4.2	Génération des données simulées	10
4.3	Types de données observées	10
4.4	Résultats ABC-Rejet	11
4.4.1	Type 1 : Données complètes (Nombre d'infecté et de guéris du jour 1 au jour 17)	11
4.4.2	Type 2 : Le nombre d'infecté et de guéris au jour 17	14
4.4.3	Type 3 : Le nombre de guéri au jour 17	17
5	Étude de cas 2 : Modèle SIR structuré par âge	19
5.1	Contexte	19
5.2	Structure de la population	20
5.3	Conditions initiales	20
5.4	Matrice de contact	20
5.5	Modèle mathématique	21
5.6	Paramètres utilisés	22
5.7	Objectif de l'inférence	22
5.8	Résultats	22
5.8.1	ABC-SMC (Sequential Monte-Carlo)	23
5.8.2	ABC-Rejet	25
6	Conclusion	26

1 Introduction

Les maladies infectieuses constituent un enjeu majeur de santé publique. La pandémie de COVID-19 a notamment mis en évidence l'importance des modèles mathématiques dans la compréhension et la prévision de la propagation des épidémies.

Les modèles compartimentaux, et en particulier le modèle SIR, permettent de représenter l'évolution d'une maladie au sein d'une population à travers différents états épidémiologiques.

Toutefois, les paramètres gouvernant ces modèles, tels que le taux de transmission ou le taux de guérison, sont généralement inconnus et doivent être estimés à partir de données observées.

Dans ce projet, nous nous intéressons aux méthodes d'Approximate Bayesian Computation (ABC), qui permettent d'effectuer une inférence bayésienne lorsque la fonction de vraisemblance est difficile voire impossible à calculer explicitement.

L'objectif est d'étudier ces méthodes sur deux cas d'étude :

- un premier cas reposant sur des données simulées à partir d'un modèle SIR classique ;
- un second cas basé sur un modèle structuré par âge inspiré d'études sur la propagation de la rougeole.

Tous les résultats qui figurent dans ce rapport sont reproductibles à l'aide des codes et des données qui se trouvent dans le répertoire Github suivant : <https://github.com/YChengLi31/methodes-abc-estimation-parametres-modeles-epidemiologiques>

2 Contexte épidémiologique

2.1 Le modèle SIR

Le modèle SIR est l'un des modèles les plus utilisés en épidémiologie mathématique.

La population est divisée en trois compartiments :

- S : individus susceptibles ;
- I : individus infectés ;
- R : individus retirés de l'épidémie.

La transmission de l'épidémie se déroule comme ceci :




FIGURE 1 – Schéma de transmission du modèle SIR

Les équations du modèle sont :

$$\begin{aligned}\frac{dS}{dt} &= -\beta \frac{SI}{N} \\ \frac{dI}{dt} &= \beta \frac{SI}{N} - \gamma I \\ \frac{dR}{dt} &= \gamma I\end{aligned}$$

où β représente le taux de transmission, γ le taux de guérison et N la population totale.

2.2 Nombre de reproduction de base

Le nombre de reproduction de base est défini par :

$$R_0 = \frac{\beta}{\gamma}$$

Il représente le nombre moyen de contaminations produites par un individu infectieux dans une population totalement susceptible.

Si :

- $R_0 < 1$: l'épidémie s'éteint ;
- $R_0 = 1$: seuil critique ;
- $R_0 > 1$: l'épidémie peut se propager.

How 1,000 cases would increase under different infection rates




FIGURE 2 – Schéma de l'évolution de l'épidémie selon R_0

2.3 Nombre de reproduction effectif

Au cours de l'épidémie, la proportion de susceptibles diminue.

On définit alors :

$$R_e(t) = R_0 \frac{S(t)}{N}$$

2.3.1 Interprétation du nombre de reproduction effectif R_e

On part de l'équation différentielle décrivant l'évolution du nombre d'infectés dans le modèle SIR :

$$\frac{dI}{dt} = \beta \frac{SI}{N} - \gamma I$$

On factorise par I :

$$\frac{dI}{dt} = I \left(\beta \frac{S}{N} - \gamma \right)$$

Puis on factorise par γ :

$$\frac{dI}{dt} = \gamma I \left(\frac{\beta S}{\gamma N} - 1 \right)$$

Or, le nombre de reproduction de base est défini par :

$$R_0 = \frac{\beta}{\gamma}$$

Ainsi :

$$\frac{\beta S}{\gamma N} = R_0 \frac{S}{N}$$

On définit alors le nombre de reproduction effectif :

$$R_e = R_0 \frac{S}{N}$$

On obtient donc :

$$\frac{dI}{dt} = \gamma I (R_e - 1)$$

Cette écriture permet d'interpréter directement l'évolution de l'épidémie.

— Si $R_e > 1$, alors :

$$\frac{dI}{dt} > 0$$

Le nombre d'infectés augmente et l'épidémie progresse.

— Si $R_e = 1$, alors :

$$\frac{dI}{dt} = 0$$

Le nombre d'infectés n'augmente plus. On atteint alors le pic épidémique.

— Si $R_e < 1$, alors :

$$\frac{dI}{dt} < 0$$

Le nombre d'infectés diminue et l'épidémie régresse.

On remarque que $I > 0$ et $\gamma > 0$. Le signe de $\frac{dI}{dt}$ dépend donc uniquement du terme $(R_e - 1)$. Ainsi :

$$R_e > 1 \implies \text{croissance de l'épidémie}$$

$$R_e < 1 \implies \text{décroissance de l'épidémie}$$

Le nombre de reproduction effectif mesure donc en permanence la capacité réelle de transmission de la maladie au cours de l'épidémie.




FIGURE 3 – Schéma de l'évolution de l'épidémie selon R_e

3 Inférence bayésienne et Approximate Bayesian Computation (ABC)

3.1 Fondement de l'inférence bayésienne

Lorsqu'on cherche à ajuster un modèle mathématique d'épidémie à des données réelles, la méthode classique repose sur le calcul d'une vraisemblance. Or, pour des modèles stochastiques complexes (modèles à structure d'âge, modèles spatiaux, données manquantes), cette vraisemblance est souvent intraitable ou inconnue.

L'Approximante Bayesian Computation (ABC) contourne ce problème en remplaçant ce calcul par des simulations directes du modèle, et en acceptant les jeux de paramètres qui produisent des sorties proches des données observées. Et dans ce cadre les paramètres sont considérés comme des variables aléatoires donc elle possède une distribution de probabilité.

De plus, l'objectif est d'estimer la probabilité d'une cause ou d'une hypothèse à partir de l'observation d'événements connus, en combinant les connaissances antérieures (probabilité a priori) avec les nouvelles preuves (données observées) pour obtenir une probabilité a posteriori.

3.1.1 Pourquoi a-t-on besoin d'utiliser l'inférence bayésienne

De nos jours, on observe des paramètres inconnus suite à une épidémie ou un autre phénomène.

Par exemple, dans le modèle **SIR**, on retrouve

— β : taux de transmissions

— γ : taux de guérisons

que l'on voudrait estimer.

La première méthode serait de maximiser la fonction de vraisemblance, cependant, cette fonction est intraitable car il y a beaucoup de donnée et on ne possède pas d'écriture explicite de cette dernière.

3.1.2 Quels sont les paramètres et les données

Avant d'expliquer plus en détail cette méthode, nous allons d'abord expliquer les paramètres et les données que nous avons utiliser pour réaliser cette étude.

Dans le cadre du modèle **SIR** (susceptibles, infectés, guéris) :

— On a pour données D une matrice composée de 3 vecteurs sur j jours :

— $(S_1, \dots, S_j)$: les susceptibles

— $(I_1, \dots, I_j)$: les infectés

— $(R_1, \dots, R_j)$: les guéris

— On a pour paramètre $\theta = (\beta, \gamma)$

— β : le taux de transmission

— γ : le taux de guérison

3.1.3 Principes de l'inférence bayésienne

Revenons à cette notion d'Inférence Bayésienne.

Important : Le paramètre θ n'est plus une valeur fixe mais une variable aléatoire donc elle possède une distribution de probabilité.

But : Avoir la loi du paramètres sachant les données.

Définition de l'inférence bayésienne : Le principe de l'inférence bayésienne est d'estimer la loi de probabilité du paramètres sachant les données (distribution a posteriori) en fonction des connaissances que l'on a au préalable sur le paramètre (le prior) avec les données (D).

Et par la relation de Bayes on a :

$$\mathbb{P}(\theta | D) = \frac{\mathbb{P}(D | \theta)\mathbb{P}(\theta)}{\mathbb{P}(D)} \propto \mathbb{P}(D | \theta)\mathbb{P}(\theta)$$

On retrouve cette proportionnalité avec car $\mathbb{P}(D | \theta)\mathbb{P}(\theta)$ car $\mathbb{P}(D)$ ne dépend pas de θ .
avec

— $\mathbb{P}(\theta | D)$: la distribution a posteriori (cette proba nous permet de savoir les paramètres sachant les données)

— $\mathbb{P}(D | \theta)$: la fonction de vraisemblance ou Likelihood (ici D est fixé et on fait varier θ pour avoir les meilleurs paramètres qui décrivent les données)

— $\mathbb{P}(\theta)$: la distribution a priori (connaissances sur θ avant de voir les données)

De plus, on peut réécrire cette égalité avec les densités conditionnelles.

$$(1) \quad f_{(\Theta, D)}(\theta, d) = f_{\Theta|D=d}(\theta) f_D(d)$$

$$(2) \quad f_{(\Theta, D)}(\theta, d) = f_{D|\Theta=\theta}(d) f_{\Theta}(\theta)$$

$$(1) \quad \text{et} \quad (2) \quad \implies \quad f_{\Theta|D=d}(\theta) f_D(d) = f_{D|\Theta=\theta}(d) f_{\Theta}(\theta)$$

$$\implies \quad f_{\Theta|D=d}(\theta) = \frac{f_{D|\Theta=\theta}(d) f_{\Theta}(\theta)}{f_D(d)}$$

Par exemple pour $\mathbb{P}(\theta | D)$ on peut dire que c'est la probabilité de calculer les taux de transmissions, infections etc en sachant que l'on ai observé des pandémies. Par ailleurs, la fonction de vraisemblance $\mathbb{P}(D | \theta)$ est compliqué voire impossible à avoir d'où l'utilisation de l'Approximante Bayesian Computation (ABC). Cette méthode permet de passer d'une écriture analytique de la fonction de vraisemblance à des simulations de lois.

3.2 Méthodes ABC

3.2.1 Premier algorithme : ABC-Rejet

ABC-Rejet est l'algorithme le plus simple provenant de l'ABC.

Et son but est de tirer M variables aléatoire θ^* qui suit la loi $\mathbb{P}(\theta | D)$.

Pseudo-code :

ABC-Rejet :

- θ^* qui suit une loi de distribution du prior $\mathbb{P}(\theta)$
- On génère D^* avec le modèle mathématique que l'on étudie en utilisant les paramètres θ^*
- On regarde la distance entre D et D^* (ie. $d(D, D^*) \leq \epsilon$) et si elle est inférieure à ϵ alors on garde θ^* sinon on rejette
- On répète jusqu'à obtenir M particules θ^*

Sachant que l'algorithme ne reproduit pas exactement les données théoriques alors, on a à la fin cette approximation.

$$\mathbb{P}(\theta | D) \approx \mathbb{P}(\theta | d(D, D^*) \leq \epsilon)$$

Pourquoi ABC-Rejet approxime bien $\mathbb{P}(\theta | D)$?

C'est parce que l'algorithme garde seulement les paramètres qui produisent des données ressemblant aux vrais données D (c'est le troisième point dans le pseudo-code de l'algorithme). Donc, à la fin on a la distribution a posteriori.

Limite de l'ABC-Rejet

- **Faible efficacité computationnelle :** Plus le nombre de particule M est grand plus l'exécution du code est lente car à chaque proposition de particule l'algorithme doit résoudre une équation différentielle ordinaire.
- **Choix du seuil de la tolérance ϵ :**
 - Plus la tolérance est grande plus on accepte de particule mais plus l'erreur sur la distribution à posteriori (loi des paramètres sachant les données) est grande.

- Inversement, plus la tolérance est petite plus l'algorithme est lent car on accepte beaucoup moins de particule.
- **Dépendance de la formule de la distance utilisé** : La formule de la distance est compliqué à choisir. Par exemple, si on prenait la distance euclidienne et que l'on utilisait deux informations, une information peut avoir plus de poids que l'autre car sa valeur peut être plus grande que l'autre.
- **Dépendance aux statistiques résumées** : Après l'observation d'une épidémie, on retrouve beaucoup d'information par exemple :
 - L'âge des patients
 - La localisation
 - Le jour de contamination
 - etc.

Il est souvent impossible d'utiliser et de comparer l'ensemble des informations.

Une réduction de l'information est alors nécessaire pour faciliter l'analyse et la comparaison. Cette simplification provoque une perte d'information.

Dans d'autres cas, le manque d'information nous contraint à travailler avec les données disponibles, même lorsqu'elles sont insuffisantes pour décrire complètement le phénomène étudié.

- **Problèmes d'identifiabilité** : Notre modèle est non identifiable car plusieurs couple de paramètres peuvent donner les même résultats. Donc les paramètres seront difficilement distinguables.

3.2.2 Nouvelle algorithme : ABC-SMC (Sequential Monte-Carlo)

Cet algorithme est basé sur plusieurs générations G donc chaque génération possède une tolérance $\epsilon_1 > \epsilon_2 > \dots > \epsilon_G$. Pour la première génération, les particules sont obtenues à l'aide de l'algorithme ABC-Rejet. Puis de la deuxième génération à la dernière on réduit successivement la tolérance, cela est possible car au lieu de tirer les paramètres selon la distribution du prior, on utilise les paramètres de la génération précédente en les perturbant grâce à un poids.

Cette méthode permet de diminuer drastiquement le temps de calcul, réduit le nombre de particule rejetée et fournit une approximation de la loi des paramètres sachant les données de manière plus précise que l'ABC-Rejet. Puisqu'à chaque génération on utilise les particules précédentes donc on peut réduire progressivement la tolérance donc suivant les générations les particules acceptées permettent de produire des simulations où elles correspondront de plus en plus aux données observées.

4 Étude de cas 1 : données simulées

4.1 Description du modèle et des paramètres simulés

Dans cette première étude de cas, nous considérons un cadre de données simulées afin d'évaluer la capacité de la méthode ABC (Approximate Bayesian Computation) à retrouver les paramètres β et γ du modèle étudié dans un environnement contrôlé.

Le modèle est initialisé avec une population totale de taille :

$$N = 100$$

répartie initialement en :

- $S_0 = 99$ individus susceptibles,
- $I_0 = 1$ individu infecté.
- $R_0 = 0$ individu guéri

Les paramètres du modèle sont fixés comme suit :

- Taux de transmission : $\beta = 1.5$,
- Taux de récupération : $\gamma = 0.5$,
- Nombre de reproduction de base : $R_0 = 3$.

Ces paramètres correspondent à un scénario épidémiologique où la propagation de l'infection est significative, comme suggéré par la valeur de R_0 supérieure à 1.

4.2 Génération des données simulées

Les données sont simulées sur un horizon temporel de :

$$T = 17 \text{ jours}$$

Le modèle est simulé de manière discrète sur une grille temporelle régulière afin de suivre l'évolution des compartiments $S(t)$, $I(t)$ et $R(t)$.

La dynamique du système repose sur les mécanismes classiques de transition :

- infection des individus susceptibles avec un taux proportionnel à $\beta \frac{S_t I_t}{N}$,
- récupération des individus infectés avec un taux γI_t .

Les trajectoires sont obtenues par simulation jour par jour, en mettant à jour les états du système sur l'ensemble de la période.

Le système est initialisé avec une unique réalisation, et les trajectoires simulées permettront de comparer avec l'inférence des paramètres via la méthode ABC.




FIGURE 4 – Schéma de l'évolution de l'épidémie : Données simulées

4.3 Types de données observées

Afin d'évaluer l'impact du niveau d'information disponible sur l'inférence des paramètres, plusieurs scénarios d'observation sont considérés.

Ces scénarios correspondent à des situations où l'observateur ne dispose pas nécessairement de l'ensemble des trajectoires complètes du système, mais uniquement de certaines quantités agrégées ou partielles.

— **Type 1 : données complètes**

Ce premier cas correspond à l'observation de deux variables du modèle au cours du temps, notamment les trajectoires des individus infectés et guéris. Il constitue le scénario de référence, où l'information disponible est maximale.

— **Type 2 : observations partielles au temps final**

Dans ce scénario, seules les valeurs au temps final $t = 17$ sont observées. Il s'agit des quantités de personnes infectées et guéries à la fin de la période étudiée. Ce cas correspond à une situation réaliste où seules des données de bilan sont disponibles.

— **Type 3 : observation encore plus limitée**

Le troisième cas considère une information encore plus réduite, où seule la population des individus guéris au temps final est disponible. Ce cadre permet d'évaluer la robustesse de la méthode ABC dans un contexte de forte perte d'information.

Ces différents niveaux d'observation permettent d'analyser la sensibilité de la méthode d'inférence aux informations disponibles. En particulier, la comparaison entre les cas montre comment la réduction de l'information impacte la qualité de l'estimation des paramètres du modèle.

4.4 Résultats ABC-Rejet

— Les données théoriques : $D = (S_t, I_t, R_t) \quad \forall t = 1, \dots, 17$

— Les données simulées : $D = (S_t^*, I_t^*, R_t^*) \quad \forall t = 1, \dots, 17$

(S_t) (resp. (S_t^*)) désigne le nombre d'individus susceptibles au temps (t) dans le modèle théorique (resp. simulé).

(I_t) (resp. (I_t^*)) désigne le nombre d'individus infectés au temps (t) dans le modèle théorique (resp. simulé).

(R_t) (resp. (R_t^*)) désigne le nombre d'individus guéris au temps (t) dans le modèle théorique (resp. simulé).

Rappel : Taux de transmission théorique : $\beta = 1.5$; Taux de guérisons théorique : $\gamma = 0.5$

4.4.1 Type 1 : Données complètes (Nombre d'infecté et de guéris du jour 1 au jour 17)

Les valeurs fixées pour l'algorithme ABC-Rejet sont :

— Nombres de particules : $M = 1000$

— La tolérance : $\epsilon = 20$

Sachant que dans cette partie, on utilise le nombre d'infecté et de guéri du jour 1 au jour 17 alors la formule utilisé pour la distance est :

$$d(D, D^*) = \sqrt{\sum_{t=1}^{17} (I_t - I_t^*)^2} + \sqrt{\sum_{t=1}^{17} (R_t - R_t^*)^2}$$

Suite à la simulation de l'algorithme on obtient un vecteur de 1000 variables aléatoires qui suit la loi $P(\theta | D)$.

Analysons ces estimations puis traçons leurs histogrammes

Analyse des paramètres

Pour le paramètre beta :

Moyenne des estimations : 1.5056

Variance des estimations : 0.0072

Intervalle de crédibilité à 95% : [1.3582 , 1.6605]

Largeur de l'intervalle : 0.3023

FIGURE 5 – Analyse du paramètres β

Pour le paramètre gamma :

Moyenne des estimations : 0.5139

Variance des estimations : 0.0033

Intervalle de crédibilité à 95% : [0.4166 , 0.6304]

Largeur de l'intervalle : 0.2138

FIGURE 6 – Analyse du paramètres γ

On remarque que les moyennes sont au alentour de 1.5 et 0.5, leurs variances sont faible, cela montre qu'ils se concentrent autour des valeurs théoriques et les largeurs d'intervalles sont petites. Par conséquent, on a une bonne estimation de β et γ .

Histogrammes des paramètres




FIGURE 7 – Histogramme de β




FIGURE 8 – Histogramme de γ

On voit qu'il y a une belle distribution de la loi des paramètres sachant les données autour des valeurs théoriques (pointillé rouge), ce qui prouve que nos estimations sont correctes.

Nous allons également tracer 10 trajectoires des infectés et des guéris en choisissant de manière aléatoire 10 couples (β, γ) parmi les particules acceptés.

Notre but serai de comparer les trajectoires simulées aux trajectoires théoriques afin d'évaluer la qualité de l'approximation faite par l'algorithme. Si les trajectoires simulées se rapprochent des trajectoires théoriques alors les paramètres acceptés reproduisent correctement la dynamique de l'épidémie.




FIGURE 9 – Trajectoires des infectés et des guéris du modèle SIR en utilisant 10 particules acceptées de l'ABC-Rejet.

- Rond rouge : trajectoire théorique des infectés
- Triangle vert : trajectoire théorique des guéris
- Courbe Grise : trajectoire des infectés et des guéris simuler à partir des paramètres acceptés

On remarque que si on utilise les informations sur les infectés et les guéris du jour 1 au jour 17, on retrouve une bonne approximation des trajectoires simulées par rapport aux trajectoires théoriques, donc, les paramètres acceptés permettent de reproduire la dynamique de l'épidémie.

4.4.2 Type 2 : Le nombre d'infecté et de guéris au jour 17

Les valeurs fixées pour l'algorithme ABC-Rejet sont :

- Nombres de particules : $M = 1000$
- La tolérance : $\epsilon = 2$

Dans ce type 2, on utilise le nombre d'infecté et de guéri au jour 17 alors la formule utilisé pour la distance est :

$$d(D, D^*) = \sqrt{(I_{17} - I_{17}^*)^2} + \sqrt{(R_{17} - R_{17}^*)^2}$$

Suite à la simulation de l'algorithme on obtient un vecteur de 1000 variables aléatoires qui suit la loi $P(\theta | D)$.

Analysons ces estimations puis traçons leurs histogrammes

Analyse des paramètres

```
Pour le paramètre beta :
Moyenne des estimations : 2.18
Variance des estimations : 0.2531
Intervalle de crédibilité à 95% : [ 1.2535 , 2.9708 ]
Largeur de l'intervalle : 1.7173
```

FIGURE 10 – Analyse du paramètres β

```
Pour le paramètre gamma :
Moyenne des estimations : 0.6061
Variance des estimations : 0.0408
Intervalle de crédibilité à 95% : [ 0.2903 , 0.9732 ]
Largeur de l'intervalle : 0.6829
```

FIGURE 11 – Analyse du paramètres γ

On remarque qu'en diminuant les informations utilisées, on perd de la précision qui se traduit par l'augmentation de la largeur des intervalles et les moyennes sont plus éloignées des valeurs théoriques.

Histogrammes des paramètres




FIGURE 12 – Histogramme de β




FIGURE 13 – Histogramme de γ

Les deux histogrammes nous montre que les paramètres acceptés se disperse uniformément autour des valeurs théoriques. Cette dispersion nous indique que les paramètres sont choisis selon la loi a priori et que les données observés n'apportent peu d'information sur les paramètres.

Par conséquent, la distribution des paramètres se rapprochent de la distribution de la loi a priori et ne présente pas de concentration marqué autour des valeurs théoriques.

Nous allons également tracer 10 trajectoires des infectés et des guéris en choisissant de manière aléatoire 10 couples (β, γ) parmi les particules acceptés.




FIGURE 14 – Trajectoires des infectés et des guéris du modèle SIR en utilisant 10 particules acceptées de l'ABC-Rejet.

Rappel :

- Rond rouge : trajectoire théorique des infectés
- Triangle vert : trajectoire théorique des guéris
- Courbe Grise : trajectoire des infectés et des guéris simuler à partir des paramètres ac-

ceptés

On remarque qu'il y a bien à la fin une convergence des trajectoires simulées vers les trajectoires théoriques puisqu'on a utilisé le nombre d'infecté et de guéri au jour 17. De plus, la première partie des trajectoires simulées ne suivent pas les trajectoires théoriques cela est dû au fait que plusieurs couple de paramètre peuvent donner le résultat sans que le début y corresponde.

4.4.3 Type 3 : Le nombre de guéri au jour 17

Les valeurs fixées pour l'algorithme ABC-Rejet sont :

- Nombres de particules : $M = 1000$
- La tolérance : $\epsilon = 1$

Dans ce type 2, on utilise le nombre de guéri au jour 17 alors la formule utilisée pour la distance est :

$$d(D, D^*) = \sqrt{(R_{17} - R_{17}^*)^2}$$

Suite à la simulation de l'algorithme on obtient un vecteur de 1000 variables aléatoires qui suit la loi $P(\theta | D)$.

Analysons ces estimations puis traçons leurs histogrammes

Analyse des paramètres

Pour le paramètre beta :

Moyenne des estimations : 2.0878
Variance des estimations : 0.3317
Intervalle de crédibilité à 95% : [0.9445 , 2.9443]
Largeur de l'intervalle : 1.9998

FIGURE 15 – Analyse du paramètre β

Pour le paramètre gamma :

Moyenne des estimations : 0.5039
Variance des estimations : 0.0595
Intervalle de crédibilité à 95% : [0.1356 , 0.9682]
Largeur de l'intervalle : 0.8326

FIGURE 16 – Analyse du paramètre γ

On remarque qu'en utilisant une seule information, on perd de la précision qui se traduit par l'augmentation de la largeur des intervalles comparé au type 2, les variances sont également plus élevées par rapport au type 2, cependant, les moyennes sont plus proches des valeurs théoriques que celles du type 2.

Histogrammes des paramètres




FIGURE 17 – Histogramme de β




FIGURE 18 – Histogramme de γ

Les deux histogrammes nous montre que les paramètres acceptés se disperse uniformément autour des valeurs théoriques. Cette dispersion nous indique que les paramètres sont choisis selon la loi a priori et que les données observés n'apportent peu d'information sur les paramètres.

Par conséquent, la distribution des paramètres se rapprochent de la distribution de la loi a priori et ne présente pas de concentration marqué autour des valeurs théoriques.

Nous allons également tracer 10 trajectoires des infectés et des guéris en choisissant de manière aléatoire 10 couples (β, γ) parmi les particules acceptés.




FIGURE 19 – Trajectoires des infectés et des guéris du modèle SIR en utilisant 10 particules acceptées de l'ABC-Rejet.

On remarque qu'il y a bien à la fin une convergence des trajectoires simulées des guéris vers les trajectoires théoriques des guéris puisqu'on a utilisé le nombre de guéri au jour 17. De plus, la première partie des trajectoires simulées ne suivent pas les trajectoires théoriques cela est dû au fait que plusieurs couple de paramètre peuvent donner le résultat sans que le début y corresponde.

Conclusion par rapport au 3 type de données

On peut constater que la meilleure approximation de la loi des paramètres sachant les données est celle du type 1 car on possède beaucoup d'informations : le nombre d'infecté et de guéri du jour 1 au jour 17.

Et le type 2 nous donne une approximation moins précise par rapport au type 1 et les moyennes sont plus éloignées des valeurs théoriques ce qui est normal puisqu'on passe des données complètes du jour 1 au jour 17 à des données partielles le nombre d'infecté et de guéri au jour 17.

L'approximation issue du type 3 est moins précise que le type 2, puisqu'on utilise maintenant une seule information : le nombre de guéri au jour 17. Cependant, la moyenne des paramètres est un peu plus proche que celle du type 2 mais la variance est plus élevée donc la dispersion est plus grande.

5 Étude de cas 2 : Modèle SIR structuré par âge

5.1 Contexte

Le second cas d'étude vise à se rapprocher d'une situation épidémiologique plus réaliste en introduisant une structure par âge dans le modèle SIR.

Cette étude s’inspire des travaux réalisés sur la rougeole de 2004 au Malawi présentés dans l’article de McKinley et Cook (2019). Dans ce contexte, les individus ne sont plus considérés comme une population homogène mais sont répartis dans plusieurs groupes d’âge possédant des comportements de contact différents.

L’objectif est d’étudier l’influence de ces interactions entre groupes d’âge sur la propagation de la maladie et d’évaluer la capacité des méthodes ABC à retrouver les paramètres de transmission à partir de données simulées.

Dans le cadre de ce projet, nous avons construit une version simplifiée du modèle original afin de faciliter l’implémentation et l’interprétation des résultats.

5.2 Structure de la population

La population est divisée en quatre groupes d’âge :

- Enfants ;
- Adolescents ;
- Adultes ;
- Séniors.

Les effectifs retenus pour chaque groupe sont :

$$N_0 = \begin{pmatrix} 19505 \\ 14802 \\ 25001 \\ 10000 \end{pmatrix}$$

où les composantes correspondent respectivement aux enfants, adolescents, adultes et séniors. La population totale est donc, $N = 69.308$ individus.

5.3 Conditions initiales

Au début de l’épidémie, nous supposons qu’un faible nombre d’individus est infecté dans chaque groupe d’âge.

Le vecteur des infectés initiaux est donné par :

$$I_0 = \begin{pmatrix} 8 \\ 3 \\ 3 \\ 1 \end{pmatrix}$$

où les composantes correspondent respectivement aux enfants, adolescents, adultes et séniors. Le vecteur des guéris initiaux est supposé nul :

$$R_0 = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

Les susceptibles initiaux sont alors obtenus par :

$$S_0 = N_0 - I_0.$$

5.4 Matrice de contact

Les interactions entre groupes d’âge sont décrites à l’aide d’une matrice de contact, également appelée matrice WAIFW (*Who Acquires Infection From Whom*).

Chaque coefficient W_{ij} représente l'intensité des contacts entre les individus du groupe i et ceux du groupe j .

La matrice utilisée dans notre étude est représentée ci-dessous.

Matrice de contact $W = (W_{ij})$				
Chaque coefficient W_{ij} représente l'intensité des contacts entre le groupe i (lignes) et le groupe j (colonnes)				
Groupe i (lignes) ↓	Groupe j (colonnes)			
	1. Enfants	2. Adolescents	3. Adultes	4. Seniors
1. Enfants	1.5	0.8	0.3	0.1
2. Adolescents	0.8	1.2	0.5	0.1
3. Adultes	0.3	0.5	0.7	0.2
4. Seniors	0.1	0.1	0.2	0.4

- W_{ij} : intensité des contacts entre le groupe i et le groupe j
- Plus W_{ij} est grand, plus les contacts entre les groupes i et j sont fréquents
- La matrice n'est pas nécessairement symétrique ($W_{ij} \neq W_{ji}$)

FIGURE 20 – Matrice de contact

On observe notamment que les contacts sont plus fréquents à l'intérieur d'un même groupe d'âge, en particulier chez les enfants.

5.5 Modèle mathématique

Pour chaque groupe d'âge i , le modèle SIR s'écrit :

$$\frac{dS_i}{dt} = -\lambda_i S_i$$

$$\frac{dI_i}{dt} = \lambda_i S_i - \gamma I_i$$

$$\frac{dR_i}{dt} = \gamma I_i$$

où λ_i désigne la force d'infection du groupe i .

Cette quantité représente le risque instantané pour un individu susceptible du groupe i de devenir infecté.

Elle est définie par :

$$\lambda_i = \beta \sum_{j=1}^4 W_{ij} \frac{I_j}{N_j}$$

où :

- β est le taux de transmission ;
- W_{ij} représente l'intensité des contacts entre les groupes i et j ;
- I_j est le nombre d'infectés dans le groupe j ;
- N_j est la taille du groupe j .

5.6 Paramètres utilisés

Les paramètres retenus pour générer les données simulées sont :

$$\beta = 0.08$$

$$\gamma = 0.05$$

$$FE = 0.0001$$

où FE représente la fraction initialement infectée de la population.

Ces valeurs produisent une dynamique épidémique réaliste avec une croissance initiale de l'épidémie suivie d'une diminution progressive du nombre d'infectés lorsque le nombre de susceptibles devient insuffisant.




FIGURE 21 – Schéma de l'évolution de l'épidémie : Données réelles

5.7 Objectif de l'inférence

Une fois les données simulées générées, celles-ci sont considérées comme des données observées.

L'objectif est alors d'appliquer et de comparer deux méthodes ABC afin de retrouver les paramètres et la méthode la plus efficace ayant servi à produire ces données.

Plus précisément, nous cherchons à estimer les paramètres :

$$\theta = (\beta, \gamma)$$

à partir des trajectoires simulées du modèle.

Les résultats obtenus seront ensuite comparés aux valeurs utilisées lors de la génération des données afin d'évaluer la qualité de l'inférence.

5.8 Résultats

Ici on utilisera deux algorithmes d'ABC afin de comparer leurs résultats.

Valeurs théoriques : le taux de transmission : $\beta = 0.08$; le taux de guérison : $\gamma = 0.05$

Le nombre de particule et les tolérances pour les deux algorithmes

Tolérances utilisées

- Nombre de nouveau cas par semaine : ϵ^T
- Proportion de malade dans chaque groupe d'âge : ϵ^A

ABC-Rejet :

- Nombre de particule : $M = 100$
- $\epsilon^T = 3000$
- $\epsilon^A = 0.02$

ABC-SMC :

- Nombre de particule : $M = 1000$
- $\epsilon^T = (12000, 11000, 10000, 9000, 8000, 7000, 6000, 5000, 4000, 3000)$
- $\epsilon^A = (0.15, 0.12, 0.10, 0.08, 0.06, 0.05, 0.04, 0.03, 0.025, 0.02)$

5.8.1 ABC-SMC (Sequential Monte-Carlo)

Rappel : ABC-SMC est une algorithmne sur plusieurs générations. Pour la première génération on utilise un ABC-Rejet et de la deuxième à la dernière, on réutilise les paramètres acceptés des générations précédentes et cela nous permet de réduire les tolérances.

Donc à la dernière génération, on a des variables aléatoires suivant la loi des paramètres sachant les données qui permettent de simuler des données proches des données théoriques.

Analysons les paramètres acceptés ainsi que les histogrammes produit par cet algorithmne.

Analyse des paramètres

```
Pour le paramètre beta :
Moyenne des estimations : 0.0738
Variance des estimations : 4.7e-05
Intervalle de crédibilité à 95% : [ 0.0622 , 0.0886 ]
Largeur de l'intervalle : 0.0264
```

FIGURE 22 – Analyse du paramètres β

```
Pour le paramètre gamma :
Moyenne des estimations : 0.0469
Variance des estimations : 1e-04
Intervalle de crédibilité à 95% : [ 0.0311 , 0.0647 ]
Largeur de l'intervalle : 0.0336
```

FIGURE 23 – Analyse du paramètres β

On remarque que la moyenne des paramètres sont proches des valeurs théoriques, de plus, on a une bonne concentration des paramètres acceptés (variable aléatoire qui suit la loi des paramètres sachant les données) autour des valeurs théoriques d'après les variances. Et, les largeurs des intervalles sont également petit donc on retrouve une certaine précision. Pour simuler cet algorithmne il nous a fallut 6 heures et 09 minutes.




FIGURE 24 – Histogramme de β




FIGURE 25 – Histogramme de γ

On remarque une bonne distribution qui se concentre autour de la valeur théorique (pointillé rouge) pour γ . Pour β la distribution est un peu plus vers la gauche que la valeur théorique (pointillé rouge).

5.8.2 ABC-Rejet

La simulation de cet algorithme nous a pris 11 heures 20 minutes pour seulement 100 particules.

Analyse des paramètres

```
Pour le paramètre beta :  
Moyenne des estimations : 0.0766  
Variance des estimations : 1e-04  
Intervalle de crédibilité à 95% : [ 0.0637 , 0.0942 ]  
Largeur de l'intervalle : 0.0305
```

FIGURE 26 – Analyse du paramètres β

```
Pour le paramètre gamma :  
Moyenne des estimations : 0.0481  
Variance des estimations : 1e-04  
Intervalle de crédibilité à 95% : [ 0.032 , 0.0685 ]  
Largeur de l'intervalle : 0.0365
```

FIGURE 27 – Analyse du paramètres β

On remarque que cette algorithme à une moyenne un peu plus proche que celle de ABC-SMC, par contre les variances et les largeurs des intervalles sont plus grandes que celles de l'ABC-SMC, cela nous dit que l'ABC-Rejet est moins précis et il possède une dispersion plus élevé.

Histogrammes des paramètres




FIGURE 28 – Histogramme de β




FIGURE 29 – Histogramme de γ

On remarque que l'histogramme est plus hétérogène pour les deux paramètres comparé aux ceux de l'ABC-SMC.

Conclusion sur les deux méthodes

On peut remarquer à l'issue de ces deux méthodes que l'ABC-SMC est plus précis et plus rapide car pour 1000 particules, il a pris 6 heures 29 minutes comparé à l'ABC-Rejet qui a pris 11 heures 20 minutes pour seulement 100 particules. Bien évidemment, les 100 variables aléatoires de l'ABC-Rejet peuvent être bruité mais c'est là qu'intervient le temps de calcul. Pour conclure, l'ABC-Rejet est l'algorithme le plus simple des ABC et il n'est pas souvent utilisé dû au fait de son temps de calcul extrêmement long c'est pourquoi, l'ABC-SMC est privilégié.

6 Conclusion

Dans ce projet, nous avons étudié l'inférence des paramètres d'un modèle épidémiologique de type SIR à l'aide des méthodes d'Approximate Bayesian Computation (ABC).

Dans un premier temps, nous avons montré comment ces méthodes permettent de contourner la vraisemblance en remplaçant celle-ci par des simulations du modèle et une comparaison entre données observées et simulées.

L'étude sur données simulées a permis de mettre en évidence plusieurs points importants. Tout d'abord, la qualité de l'inférence dépend fortement de la quantité d'information disponible : plus les observations sont complètes, plus la distribution a posteriori des paramètres est concentrée autour des valeurs réelles. À l'inverse, une réduction de l'information entraîne une augmentation de l'incertitude et une perte de précision dans l'estimation des paramètres.

Nous avons également comparé différentes variantes de l'algorithme ABC. L'ABC-Rejection, bien que simple à mettre en œuvre, montre des limites importantes en termes de coût computationnel et de précision lorsque la dimension du problème augmente ou lorsque les données sont peu informatives. En revanche, l'ABC-SMC (Sequential Monte Carlo) améliore significativement l'efficacité de l'inférence en exploitant une succession de populations de particules et une réduction progressive des tolérances.

Dans le cas du modèle SIR structuré par âge, nous avons introduit une complexité supplémentaire en prenant en compte les interactions entre groupes d'âge via une matrice de contact. Cette extension permet de se rapprocher davantage de situations épidémiologiques réelles, mais augmente également la difficulté de l'inférence. Les résultats obtenus confirment que l'ABC-SMC reste plus performant que l'ABC-Rejection en termes de compromis entre précision et temps de calcul.

Ainsi, ce travail met en évidence l'intérêt des méthodes ABC pour l'inférence de paramètres dans des modèles épidémiologiques complexes, tout en soulignant l'importance du choix de l'algorithme et des données observées.

Enfin, les résultats obtenus sont entièrement reproductibles grâce aux codes disponibles sur le dépôt GitHub associé au projet.

Références

- [1] Anthony Minter and Ruta Retkute. Approximate bayesian computation for infectious disease modelling. *Epidemics*, 29 :100368, 2019. <https://www.sciencedirect.com/science/article/pii/S175543651930026X>.
- [2] Yacques Chengli and Damien Gandrey. Méthodes abc - estimation de paramètres sir, 2026. <https://github.com/YChengLi31/methodes-abc-estimation-parametres-modeles-epidemiologiques>.
- [3] Amanda Minter. abc_r - approximate bayesian computation r code, 2019. https://github.com/amanda-minter/abc_R.