Sup Galilée

Méthodes ABC pour l'estimation de taux de transition en épidémiologie et pour la modélisation du vieillissement

Yacques CHENGLI
Damien GANDREY

Juin - Juillet 2026

Déclaration d'intégrité académique

Nous certifions que ce rapport a été réalisé dans le cadre du stage portant sur les méthodes ABC pour l'estimation de taux de transition en épidémiologie et pour la modélisation du vieillissement.

Certains codes utilisés pour les simulations et les méthodes d'inférence ont été développés par des auteurs et sont disponibles dans le dépôt GitHub associé au projet.

Les articles scientifiques utilisés sont systématiquement cités dans la bibliographie.

Table des matières

1 Introduction **4**

2 Présentation du projet **5**
2.1 Contexte biologique 5
2.2 Les données expérimentales 5

3 Partie I – Données simulées **6**
3.1 Modélisation mathématique 6
3.2 Simulation numérique du modèle et validation 8
3.2.1 Génération des temps de transition 8
3.2.2 Validation des temps simulés 8
3.2.3 Vérification des lois utilisées 8
3.3 Estimation des paramètres grâce à l'algorithme ABC-SMC (Approximate Bayesian Computation Sequential Monte Carlo) 10
3.3.1 Première partie : estimation de F, G, H en fixant K_1, K_2, D 12
3.3.2 Deuxième partie : estimations de K_1, K_2, D en fixant F, G, H 15
3.4 Comparaison des simulations obtenues avec les paramètres estimés (distance d_4) . 23
3.5 Analyse de la fonction de mortalité Smurf $\kappa(t)$ à partir de la distribution *a posteriori* (distance d_4) 26
3.5.1 Courbe moyenne et intervalle de crédibilité à 95 % 26
3.5.2 Erreur quadratique intégrée 27
3.5.3 Conclusion 28

4 Partie 2 – Données réelles **28**
4.1 Traitement de données 28
4.2 Estimation des paramètres grâce à l'algorithme ABC-SMC (Approximate Bayesian Computation Sequential Monte Carlo) 29
4.2.1 Première partie : estimation de F, G, H en fixant K_1, K_2, D 29
4.2.2 Deuxième partie : estimations de K_1, K_2, D en fixant F, G, H 33
4.3 Vérification des lois estimées et dynamique de la population Smurf 35
4.4 Conclusion et Ouverture 37

5 Partie 3 – Étude de l'influence de la densité sur la transition vers l'état Smurf **38**
5.1 Contexte de l'étude 38
5.2 Objectifs de l'étude 38
5.3 Vérification de la loi de transition empirique 39
5.4 Estimation des paramètres grâce à l'algorithme ABC-SMC (Approximate Bayesian Computation Sequential Monte Carlo) 41
5.4.1 Première partie estimation de β en fixant tous les autres paramètres F, G, H, K_1, K_2, D 42
5.4.2 Deuxième partie estimation de F, G, H, β en fixant tous les autres paramètres K_1, K_2, D 45
5.5 Confrontation des simulations aux données réelles 48
5.6 Conclusion de la Partie 3 50

6 Conclusion générale **51**

Appendices **52**

A Analyse des paramètres et traçage de leurs histogrammes avec la distance d_1 **52**

B Tracage de la population Smurf sur les données réelles avec la distance d_1 **54**

7 Bilan : Organisation, mission et acquisition **55**
7.1 Présentation de la structure d'accueil et de l'entreprise 55
7.2 Organisation quotidiennes du travail 55
7.3 Tâches réalisées pendant le stage 55
7.4 Partie techniques du travail 56
7.5 Ceux que nous avons appris 56
7.6 Bilan 56

8 Références **58**

1 Introduction

Le vieillissement est classiquement décrit comme un déclin physiologique continu, se traduisant par une augmentation progressive du risque de mortalité au cours du temps. Cette vision, popularisée depuis les premiers modèles démographiques de Gompertz, suppose que les organismes se dégradent de façon lente et homogène tout au long de leur vie.

Des travaux plus récents menés sur la drosophile (*Drosophila melanogaster*) remettent en question cette vision continue. Tricoire et Rera ont mis en évidence, chez cet insecte, un phénotype appelé *Smurf* : une augmentation brutale de la perméabilité intestinale, détectable en nourrissant les mouches avec un colorant alimentaire bleu normalement non absorbé par le tube digestif [1]. Les individus présentant ce phénotype meurent presque systématiquement dans les jours qui suivent son apparition, et ce quel que soit leur âge chronologique. Ces observations ont conduit à proposer un modèle en deux phases de vieillissement : une phase *Non-Smurf*, durant laquelle la mortalité est quasiment nulle, suivie d'une transition brutale vers une phase *Smurf*, phase terminale caractérisée par un risque de décès très élevé. Le modèle initial (dit « 2PAC ») proposé par les auteurs modélisait la transition Non-Smurf $\rightarrow$ Smurf par une simple loi linéaire et la mortalité en phase Smurf par un taux constant.

Un travail plus récent, mené par Breuil, Doumic, Kaakaï et Rera, reprend statistiquement ces données expérimentales (population de 1159 drosophiles femelles suivies individuellement) à l'aide de méthodes d'estimation non paramétrique des taux de risque [2]. Cette réanalyse affine sensiblement le modèle initial sur deux points essentiels. D'une part, le taux de transition Non-Smurf $\rightarrow$ Smurf ne suit pas une simple droite mais une loi de Gompertz-Makeham, croissant de façon exponentielle avec l'âge. D'autre part, et c'est le résultat le plus marquant de cette étude, la mortalité des individus Smurf n'est pas constante : environ 40 % des mouches meurent dans les 24 heures suivant la transition, avant que le taux de mortalité ne décroisse puis se stabilise à une valeur plus faible. Ce comportement est modélisé par un taux de mortalité décroissant de façon exponentielle plutôt que constant. C'est ce second modèle, plus fin, qui constitue le **modèle 3** utilisé dans ce stage, avec :

- un taux de transition Non-Smurf $\rightarrow$ Smurf de type Gompertz-Makeham, dépendant de trois paramètres F, G, H ;
- un taux de mortalité des individus Smurf de forme exponentielle décroissante, dépendant de trois paramètres K_1, K_2, D.

L'objectif de ce stage est double : (i) mettre en œuvre numériquement ce modèle en simulant des populations synthétiques de drosophiles, afin de vérifier que le simulateur reproduit fidèlement les lois théoriques attendues, puis (ii) utiliser une méthode d'inférence bayésienne approchée, l'algorithme ABC-SMC (Approximate Bayesian Computation – Sequential Monte Carlo), afin de retrouver les six paramètres du modèle à partir de données simulées, avant d'appliquer cette méthodologie à de véritables données expérimentales.

Organisation du rapport

Ce rapport est organisé en deux grandes parties.

- **Partie I – Données simulées.** Nous présentons d'abord le modèle mathématique et sa justification biologique, puis le simulateur développé pour générer des populations synthétiques de drosophiles, sa validation (comparaison aux lois théoriques et aux ordres de grandeur de l'article), et enfin l'estimation des six paramètres du modèle par ABC-SMC à partir de ces données simulées, ainsi que l'analyse critique des résultats obtenus (comparaison des courbes de population, choix de la distance).
- **Partie II – Données expérimentales réelles.** Dans un second temps, la méthodologie validée en Partie I sera appliquée aux données expérimentales réelles (lignées DGRP) issues des articles de référence, dans le but d'estimer les paramètres du modèle à partir d'observations biologiques effectives et non plus simulées.

2 Présentation du projet

2.1 Contexte biologique

L'objectif de ce stage est d'étudier un modèle mathématique décrivant le vieillissement de populations de drosophiles (*Drosophila melanogaster*) à partir d'observations expérimentales. Ces travaux s'inscrivent dans la continuité de plusieurs études montrant qu'un changement physiologique précède systématiquement la mort chez ces individus.

Au cours de leur vie, les drosophiles passent successivement par deux états biologiques :

— un état **Non-Smurf**, correspondant à une mouche dont la barrière intestinale est intacte ;
— un état **Smurf**, caractérisé par une perte de cette barrière et une augmentation importante du risque de décès.

Le passage entre ces deux états constitue un marqueur du vieillissement. L'objectif est donc de modéliser cette transition ainsi que la durée de survie des individus après leur entrée dans l'état Smurf.

Les travaux réalisés durant ce stage ont consisté dans un premier temps à comprendre les modèles proposés dans la littérature, puis à développer un programme de simulation permettant de générer artificiellement des populations de drosophiles. Ces données simulées serviront ensuite à tester des méthodes d'inférence de type Approximate Bayesian Computation (ABC) afin de retrouver les paramètres du modèle.

2.2 Les données expérimentales

Les données utilisées dans les articles proviennent d'expériences réalisées sur plusieurs lignées génétiques de drosophiles (DGRP). Pour chaque mouche, deux informations principales sont observées :

— le temps auquel elle devient Smurf ;
— le temps auquel elle décède.

À partir de ces observations, il est possible de reconstruire les courbes de survie des populations ainsi que l'évolution du nombre de mouches Smurf au cours du temps.

Les expériences ont été réalisées sur six lignées génétiques différentes (DGRP_83, DGRP_88, DGRP_91, DGRP_105, DGRP_136 et DGRP_195), représentant au total plusieurs centaines d'individus par lignée.

Les résultats montrent que les durées de vie des populations Non-Smurf diffèrent fortement selon les lignées génétiques. En revanche, une fois devenues Smurf, les durées de survie restent relativement similaires d'une lignée à l'autre. Cette observation suggère que les différences de longévité proviennent principalement de la vitesse à laquelle les individus deviennent Smurf, davantage que de leur survie après cette transition.

Ces données constituent la base des modèles mathématiques développés dans les articles et utilisés durant ce stage.

3 Partie I – Données simulées

3.1 Modélisation mathématique

Les modèles étudiés reposent sur des fonctions de risque (ou fonctions de hasard) permettant de décrire les deux étapes du vieillissement :

— le passage de l'état Non-Smurf vers l'état Smurf ;

— le décès des individus après leur entrée dans l'état Smurf.

Conformément aux recommandations de notre encadrante, nous avons retenu le **modèle 3**, qui correspond au cas sans dépendance entre les deux temps de transition (paramètre $\gamma = 0$).

Le risque instantané de devenir Smurf est décrit par une loi de Gompertz :

$$k_s(t) = F + G\, e^{Ht},$$

où :

— F représente un risque de base constant ;

— G contrôle l'augmentation du risque avec le temps ;

— H décrit la vitesse de croissance de ce risque.

Le risque de décès des individus Smurf est modélisé par une loi exponentielle décroissante :

$$k_d(a) = K_1 + K_2 e^{-Da},$$

où a désigne le temps écoulé depuis l'entrée dans l'état Smurf.

Dans ce modèle,

— K_1 représente le risque résiduel de décès à long terme ;

— K_2 décrit le surplus de mortalité observé immédiatement après la transition ;

— D contrôle la vitesse à laquelle ce surplus décroît.

Les paramètres utilisés pour les simulations correspondent à ceux estimés dans les travaux de référence :

$$\begin{aligned} F &= 0.0014680557 \\ G &= 7.5447644 \times 10^{-5} \\ H &= 0.0066373291 \\ K_1 &= 0.0073127349 \\ K_2 &= 0.0293175233 \\ D &= 0.06715 \end{aligned}$$

Pour rendre précis le lien entre les fonctions de risque introduites ci-dessus et les données que nous observons (ou simulons), il est nécessaire d'introduire explicitement les variables aléatoires sous-jacentes au modèle.

Pour chaque individu $i \in \{1, \ldots, N_0\}$, on note :

— $T_{NS}^{(i)}$ le temps écoulé depuis le début de l'expérience jusqu'à la transition Non-Smurf $\to$ Smurf de l'individu i ;

— $T_S^{(i)}$ la durée passée par l'individu i dans l'état Smurf avant son décès ;

— $T_{Dead}^{(i)} = T_{NS}^{(i)} + T_S^{(i)}$ le temps total de vie de l'individu.

Dans le cadre du modèle 3 (données simulées, individus supposes indépendants et identiquement distribues), les variables $T_{NS}^{(i)}$ sont i.i.d. de fonction de risque $k_s(t) = F + Ge^{Ht}$, et les variables $T_S^{(i)}$ sont i.i.d. de fonction de risque $k_d(a) = K_1 + K_2 e^{-Da}$, indépendamment des $T_{NS}^{(i)}$. Les fonctions de survie associées s'écrivent :

$$S_{NS}(t) = \mathbb{P}(T_{NS} > t) = \exp\left(-\int_0^t k_s(u)\, du\right) = \exp\left(-Ft - \frac{G}{H}\left(e^{Ht} - 1\right)\right),$$

$$S_S(a) = \mathbb{P}(T_S > a) = \exp\left(-\int_0^a k_d(u)\,du\right) = \exp\left(-K_1 a - \frac{K_2}{D}\left(1 - e^{-Da}\right)\right).$$

Les données observées ne sont pas directement les temps individuels $T_{NS}^{(i)}$, $T_S^{(i)}$ (inconnus en pratique), mais les **processus de comptage** de la population a chaque instant t :

$$N_{NS}(t) = \sum_{i=1}^{N_0} \mathbf{1}_{\{T_{NS}^{(i)} > t\}}, \qquad N_S(t) = \sum_{i=1}^{N_0} \mathbf{1}_{\{T_{NS}^{(i)} \le t < T_{Dead}^{(i)}\}}, \qquad N_{Dead}(t) = \sum_{i=1}^{N_0} \mathbf{1}_{\{T_{Dead}^{(i)} \le t\}}.$$

Pour relier ces comptages aux paramètres $\theta = (F, G, H, K_1, K_2, D)$, on définit, pour un individu donne, les probabilités d'appartenir a chacun des trois états a l'instant t :

$$p_{NS}(t;\theta) = S_{NS}(t), \qquad p_S(t;\theta) = \int_0^t k_s(u) S_{NS}(u)\, S_S(t-u)\,du, \qquad p_{Dead}(t;\theta) = 1 - p_{NS}(t;\theta) - p_S(t;\theta),$$

ou $k_s(u)S_{NS}(u)$ est la densité de probabilité de transition Non-Smurf $\to$ Smurf a l'instant u, et $S_S(t-u)$ la probabilité de survivre encore $t-u$ unités de temps en phase Smurf. Sous l'hypothèse d'indépendance entre individus, le vecteur des comptages a un instant t fixe suit alors une loi multinomiale :

$$\big(N_{NS}(t),\, N_S(t),\, N_{Dead}(t)\big) \;\sim\; \text{Multinomiale}\Big(N_0\,;\; p_{NS}(t;\theta),\, p_S(t;\theta),\, p_{Dead}(t;\theta)\Big).$$

C'est cette loi multinomiale, implicite dans nos simulations, qui justifie de comparer les trajectoires simulées $\big(N_{NS}^*(t), N_S^*(t), N_{Dead}^*(t)\big)$ aux trajectoires observées via les distances $d_1, \ldots, d_5$ introduites plus loin : chaque distance mesure, sous une forme ou une autre, l'écart entre une réalisation de ce processus multinomial et celle obtenue avec les paramètres candidats θ^*.

À partir de ces fonctions de risque, il est possible de calculer les fonctions de survie, puis de générer aléatoirement les temps de transition des individus grâce à la méthode de l'inversion de la fonction de répartition. Les simulations obtenues permettent alors de reconstruire l'évolution temporelle des populations Non-Smurf, Smurf et des individus décédés.

Ces simulations sont ensuite réutilisées pour faire intervenir la méthode ABC afin d'estimer les paramètres de notre modèle mathématique.

3.2 Simulation numérique du modèle et validation

Cette section décrit le travail de simulation et de validation du modèle réalisé en amont de l'estimation par ABC-SMC.

3.2.1 Génération des temps de transition

Les temps passés dans chacune des deux phases (Non-Smurf et Smurf) sont simulés par inversion de la fonction de survie associée à chaque loi de risque. Dans une première version, la racine de l'équation de survie était recherchée à l'aide de la fonction `uniroot()` de R. Cette approche, bien que fonctionnelle, s'est révélée coûteuse en temps de calcul lorsqu'il s'agit de générer un grand nombre d'individus, ou de répéter la simulation des milliers de fois dans le cadre de l'algorithme ABC.

Une version optimisée du simulateur a donc été développée, reposant sur la méthode de Newton-Raphson pour la recherche de racine, nettement plus rapide que `uniroot()`. Les principales améliorations apportées sont :

— l'utilisation de Newton-Raphson pour l'inversion des fonctions de survie ;
— la construction d'un modèle unique et réutilisable, où le modèle mathématique et les paramètres sont clairement séparés ;
— la mise en place d'un cache, afin d'éviter de recalculer une simulation déjà obtenue pour un jeu de paramètres identique.

Cette structure a permis de réduire significativement les temps de calcul de l'algorithme ABC-SMC, qui nécessite des dizaines de milliers de simulations.

3.2.2 Validation des temps simulés

Afin de vérifier que le simulateur reproduit correctement la dynamique attendue, les temps moyens passés dans chaque phase ont été comparés aux ordres de grandeur rapportés expérimentalement par Breuil et al. [2] :

	Simulation	**Article [2]**
Temps moyen en phase Non-Smurf	$\approx$ 16 jours	$\approx$ 16 jours
Temps moyen en phase Smurf	$\approx$ 3,8 jours	$\approx$ 4 jours
Temps de vie moyen total	$\approx$ 20 jours	$\approx$ 20 jours

TABLE 1 – Comparaison des durées moyennes simulées et rapportées dans l'article de référence.

Les valeurs simulées sont donc cohérentes avec les données expérimentales, ce qui constitue une première validation de l'implémentation du modèle avant l'application de la méthode ABC-SMC.

3.2.3 Vérification des lois utilisées

Pour valider plus rigoureusement la procédure de simulation, les fonctions de répartition empiriques obtenues à partir des temps simulés ont été comparées aux fonctions de répartition théoriques des lois utilisées :

— pour le temps Non-Smurf, les données simulées sont en accord avec la loi de Gompertz-Makeham retenue pour le taux de transition ;
— pour le temps Smurf, les données simulées reproduisent correctement la loi de mortalité à taux exponentiellement décroissant du modèle 3.

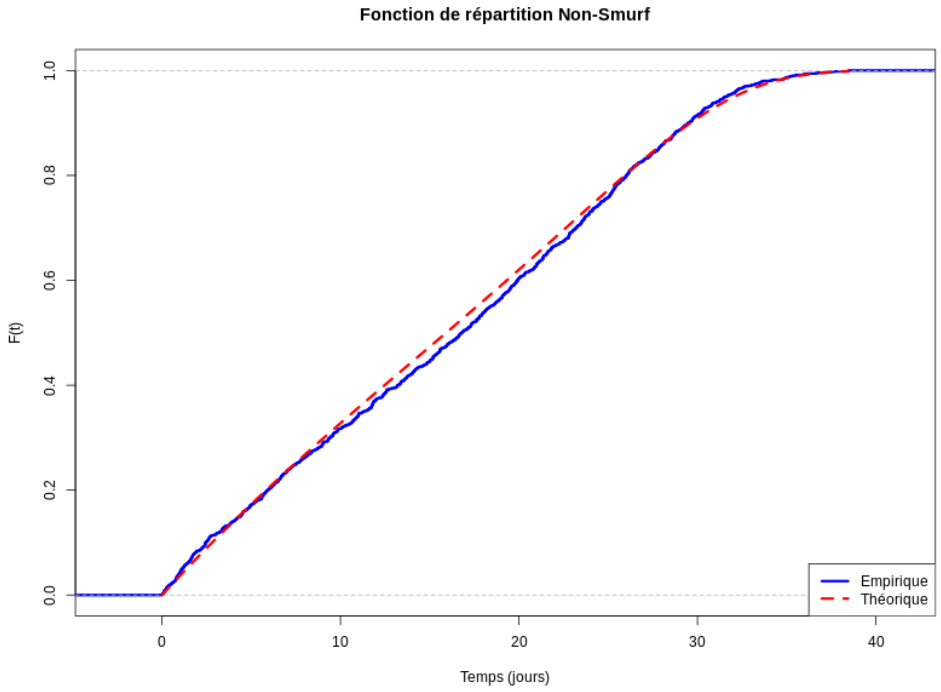


FIGURE 1 – Fonction de répartition empirique vs théorique – temps Non-Smurf.

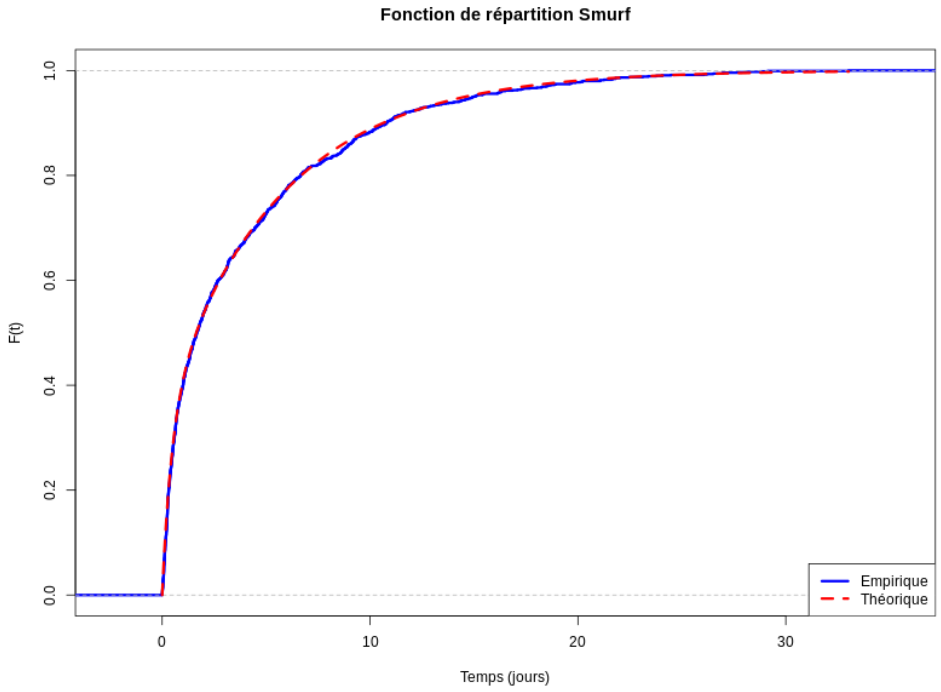


FIGURE 2 – Fonction de répartition empirique vs théorique – temps Smurf.

La superposition quasi parfaite des courbes empiriques et théoriques confirme que l'algorithme de génération des temps de transition est correctement implémenté.

3.3 Estimation des paramètres grâce à l'algorithme ABC-SMC (Approximate Bayesian Computation Sequential Monte Carlo)

Cet algorithme est basé sur plusieurs générations G donc chaque génération possède une tolérance $\epsilon_1 > \epsilon_2 > ... > \epsilon_G$. Pour la première génération, les particules sont obtenue à l'aide de l'algorithme ABC-Rejet (explication plus détaillé ici [3] pour l'ABC-Rejet). Puis de la deuxième génération à la dernière on réduit successivement la tolérance, cela est possible car au lieu de tirer les paramètres selon la distribution du prior, on utilise les paramètres de la génération précédente en les perturbant grâce à un poids.

Cette méthode permet de diminuer drastiquement le temps de calcul, réduit le nombre de particule rejetée et fournit une approximation de la loi des paramètres sachant les données de manière plus précise que l'ABC-Rejet. Puisqu'à chaque génération on utilise les particules précédentes donc on peut réduire progressivement la tolérance donc suivant les générations les particules acceptés permettent de produire des simulations où elles correspondront de plus en plus aux données observées.

Rappel : ABC-Rejet
- θ^* qui suit une loi de distribution du prior $\mathbb{P}(\theta)$
- On génère W^* avec le modèle mathématique que l'on étudie en utilisant les paramètres θ^*
- On regarde la distance entre W et W^* (ie. $d(W, W^*) \leq \epsilon$) et si elle est inférieur à ϵ alors on garde θ^* sinon on rejette
- On répète jusqu'à obtenir M particules θ^*

Nous allons utiliser l'algorithme **ABC-SMC** (explication plus détaillé ici [4] pour l'ABC-SMC) pour estimer les 6 paramètres, plus précisément l'algorithme nous donneras M variables aléatoires qui suivent la loi $P(\ \theta \mid W\ )$

- $\theta = (\ F, G, H, K_1, K_2, D\ )$
- W : Données observées qui est composé de plusieurs éléments et les plus utile sont
  - $((N_{NS})_t)_{1 \leq t \leq T}$: Nombre de mouches dans la phase Non-Smurf
  - $((N_S)_t)_{1 \leq t \leq T}$: Nombre de mouches dans la phase Smurf
  - $((N_{Dead})_t)_{1 \leq t \leq T}$: Nombre de mouche mort
  - θ^* est tiré uniformément entre $\pm 90\%$ des valeurs théoriques
  - ϵ est fixé en faisant tourner le calcul de la distance plusieurs fois

On ne peut pas estimer les 6 paramètres d'un coup car cela demanderait un temps de calcul élevé. De plus, on peut avoir un problème d'identifiabilité car plusieurs groupes de paramètres peuvent donner les mêmes résultats.

Pour pallier à cela, on fixe d'abord 3 paramètres et on estime les 3 autres.

Fixons les variables utile dans l'algorithme :
- Nombres de particules : M = 1000
- Nombres de mouches : $N_0 = 1200$

Nous savons que les données sont mesurées toutes les 24 heures et chaque simulation de l'ABC-SMC comporte 6 générations.

Nous allons également introduire les informations utilisées dans la formule de la distance. On sait que la longueur des vecteurs des données n'est pas forcément la même suivant les simulations

car la longueur du vecteur qui correspond à l'unité de temps est calculé en prenant la partie entière du maximum du vecteur $T_{Dead} = T_{Non-Smurf} + T_{Smurf}$

— T_{Dead} : au bout de combien de temps la mouche décède
— $T_{Non-Smurf}$: au bout de combien de temps la mouche reste dans la phase Non-Smurf
— T_{Smurf} : au bout de combien de temps la mouche reste dans la phase Smurf

C'est-à-dire en fonction du temps de vie des mouches dans les phases les longueur des vecteurs sont différentes. Donc lorsqu'on simule le jeux de données théoriques W et celui issus des paramètres tirés selon leurs prior W^*, un des vecteurs sera de taille plus petite à ce moment la on le complète avec des 0 jusqu'à qu'ils soient de même taille.

Par la suite dans tout les calculs de distance tous les vecteurs de taille plus petite sera complété par des 0 jusqu'à ce que la taille du petit vecteur égale la taille du grand vecteur.

Posons :
— n = $max(\ longueur(N_{Dead})\ ,\ longueur(N^*_{Dead})\ )$
— m = $max(\ longueur(N_{NS})\ ,\ longueur(N^*_{NS})\ )$
— p = $max(\ longueur(N_S)\ ,\ longueur(N^*_S)\ )$

Nous allons énumérer les formule de distance utilisées :

— $d_1 = \sqrt{\sum_{i=1}^{n} ((N_{Dead})_i - (N^*_{Dead})_i)^2}$

— $d_2 = \sqrt{\sum_{i=1}^{m} ((N_{NS})_i - (N^*_{NS})_i)^2}$

— $d_3 = \sqrt{\sum_{i=1}^{m} ((N_{NS})_i - (N^*_{NS})_i)^2} + \sqrt{\sum_{i=1}^{m} ((N_S)_i - (N^*_S)_i)^2}$

— $d_4 = (d_1, abs(\frac{(N_S)_{17}}{(N_S)_{17}+(N_{Dead})_{17}} - \frac{(N^*_S)_{17}}{(N^*_S)_{17}+(N^*_{Dead})_{17}}))$ (on expliquera ce que signifie le 17)

— $d_5 = (d_1, \sum_{i=1}^{p}(\frac{(N_S)_i}{(N_S)_i+(N_{Dead})_i} - \frac{(N^*_S)_i}{(N^*_S)_i+(N^*_{Dead})_i})^2)$

Cette estimation se déroulera en deux parties :

— **1ère partie :** Estimations des 3 premiers paramètres (F, G, H) en fixant les 3 derniers $(K_1\ ,\ K_2\ ,\ D)$.

— **2ème partie :** Estimations des 3 derniers paramètres (K_1, K_2, D) en fixant les 3 premiers $(F\ ,\ G\ ,\ H)$.

Rappel : Les paramètres théoriques sont :

$$
\begin{aligned}
F &= 0.0014680557 \\
G &= 7.5447644 \times 10^{-5} \\
H &= 0.0066373291 \\
K_1 &= 0.0073127349 \\
K_2 &= 0.0293175233 \\
D &= 0.06715
\end{aligned}
$$

Tous les résultats ci-dessous peut être réalisé grâce aux fichiers mis à disposition sur notre Github : `https://github.com/YChengLi31/methodes-abc-estimation-parametres-modeles-epidemiologique`

3.3.1 Première partie : estimation de F, G, H en fixant K_1, K_2, D

Dans cette partie, nous allons estimer (F, G, H) en fixant $(K_1\ ,\ K_2\ ,\ D)$.

Nous avons obtenu deux fois M variables aléatoires d'après l'algorithme ABC-SMC en utilisant deux formules de distance d_2 et d_3, qui, pour les deux, nous donnent des résultats satisfaisants.

Pour la distance d_2, on fixe $\epsilon = (2000, 1000, 900, 700, 500, 350)$

Analysons l'estimation des paramètres ainsi que leurs histogrammes

Analyse des paramètres

```
Pour le paramètre F :
  Moyenne des estimations : 0.001557
  Variance des estimations : 6.5e-08
  Intervalle de crédibilité à 95% : [ 0.001048 ,  0.002005 ]
  Largeur de l'intervalle :  0.000957
  Erreur relative :  0.06047353

Pour le paramètre G :
  Moyenne des estimations : 7.3212e-05
  Variance des estimations : 1e-09
  Intervalle de crédibilité à 95% : [ 1.2e-05 ,  0.000138 ]
  Largeur de l'intervalle :  0.000126
  Erreur relative :  0.0296322

Pour le paramètre H :
  Moyenne des estimations : 0.007077
  Variance des estimations : 1.792e-06
  Intervalle de crédibilité à 95% : [ 0.004775 ,  0.009838 ]
  Largeur de l'intervalle :  0.005063
  Erreur relative :  0.06619795
```

FIGURE 3 – Analyse des paramètres

On remarque que l'erreur relative des paramètres est inférieur à 7% ce qui est bien et l'estimation est précise car la largeur de l'intervalle est faible.

Regardons leurs histogrammes

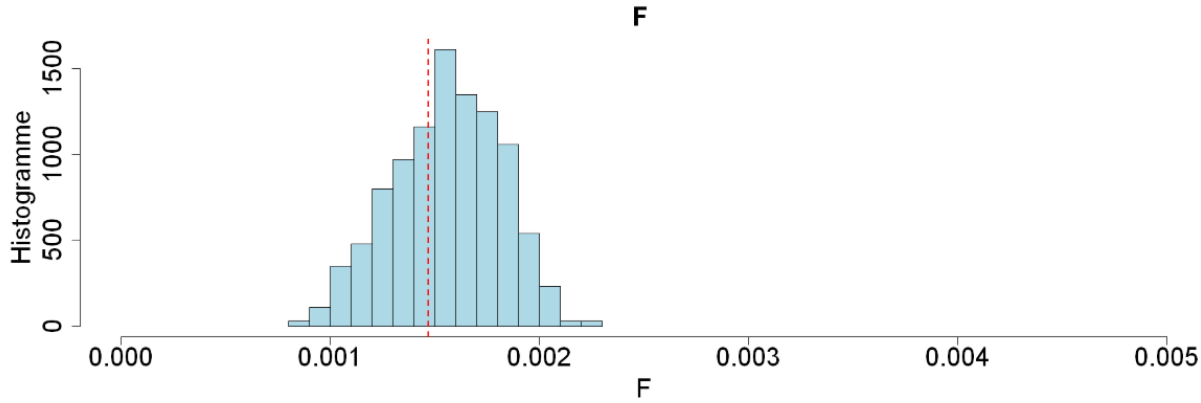


FIGURE 4 – Histogramme de F

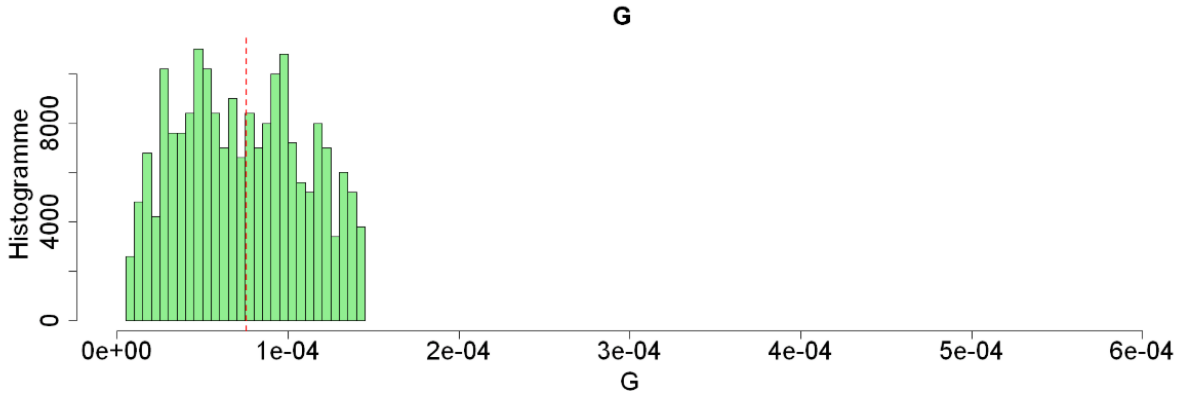


FIGURE 5 – Histogramme de G

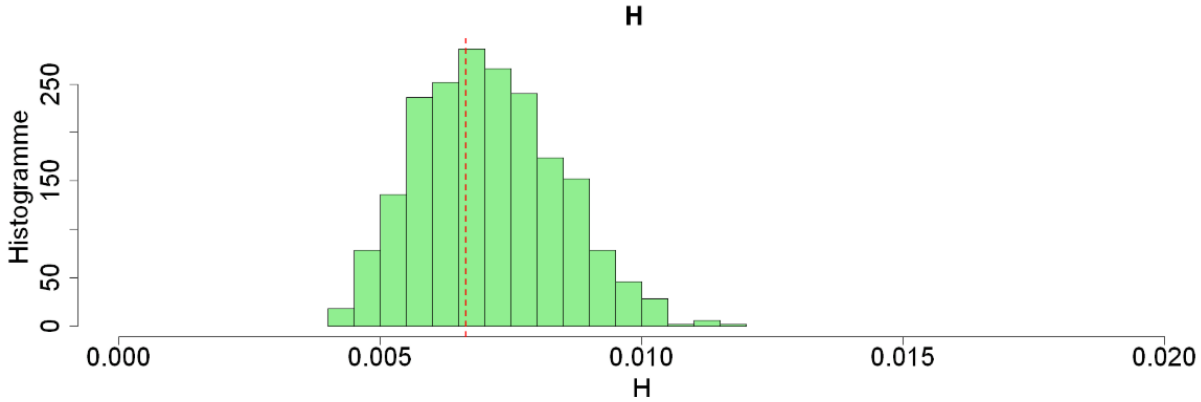


FIGURE 6 – Histogramme de H

Les histogrammes sont pour la plupart assez centrés autour de leur valeur théorique (pointillé rouge) ce qui est un bon point même si cela reste confus pour l'histogramme de G. Cependant, l'analyse des paramètres du dessus nous montre qu'il n'y a pas de problème pour G.

On essayer de diminuer l'erreur relative en rajoutant une infomations supplémentaire dans le calcul de la distance c'est dire le nombre de mouche dans la phase Smurf.

Pour la distance d_3, on fixe la tolérance $\epsilon = (2000, 1000, 900, 800, 700, 500)$

Analysons l'estimation des paramètres ainsi que leurs histogrammes

Analyse des paramètres

```
Pour le paramètre F :
  Moyenne des estimations : 0.001545
  Variance des estimations : 5.7e-08
  Intervalle de crédibilité à 95% : [ 0.001078 ,  0.001957 ]
  Largeur de l'intervalle :  0.000879
  Erreur relative :  0.05248428

Pour le paramètre G :
  Moyenne des estimations : 7.3504e-05
  Variance des estimations : 1e-09
  Intervalle de crédibilité à 95% : [ 1.2e-05 ,  0.000137 ]
  Largeur de l'intervalle :  0.000125
  Erreur relative :  0.02575837

Pour le paramètre H :
  Moyenne des estimations : 0.006967
  Variance des estimations : 1.834e-06
  Intervalle de crédibilité à 95% : [ 0.004832 ,  0.010022 ]
  Largeur de l'intervalle :  0.00519
  Erreur relative :  0.04966489
```

FIGURE 7 – Analyse des paramètres

On remarque que l'erreur relative des paramètres est plus petite que lla simulation précédente c'est à dire inférieur à 5.5% ce qui est bien et l'estimation est précise car la largeur de l'intervalle est faible.

Regardons leurs histogrammes

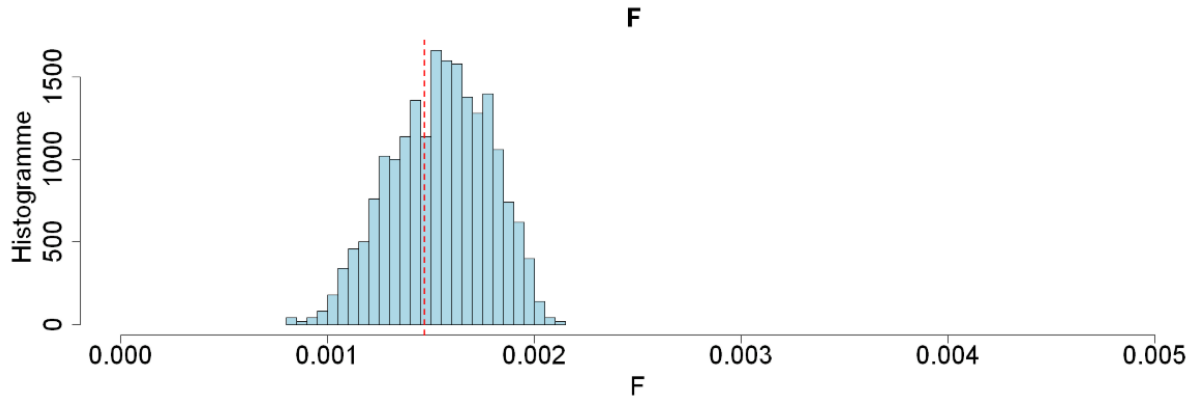


FIGURE 8 – Histogramme de F

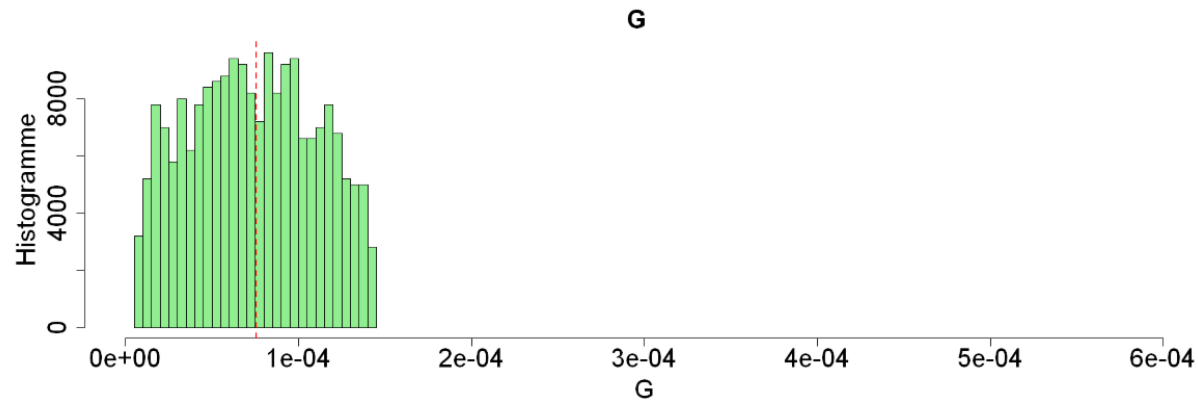


FIGURE 9 – Histogramme de G

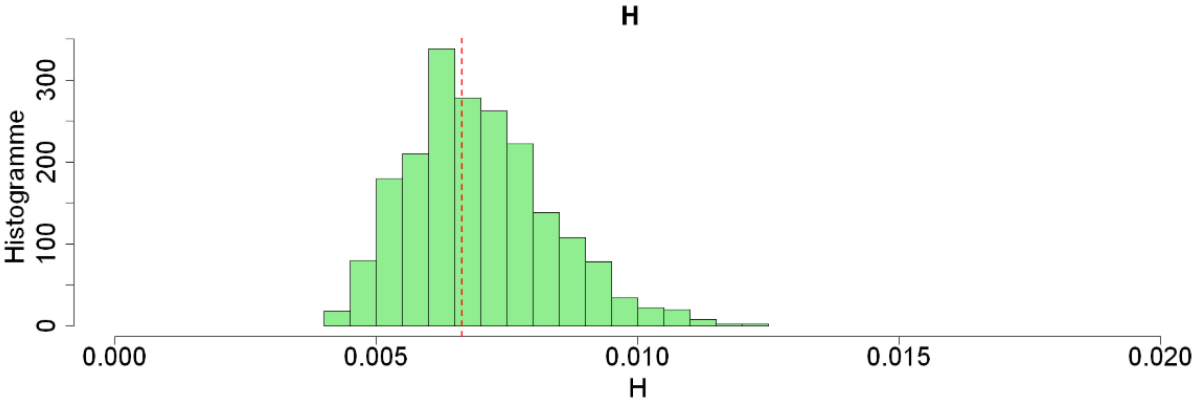


FIGURE 10 – Histogramme de H

On remarque que la distribution de G est un peu plus centré autour de la valeur théorique contrairement à la simulation précédente qui était un peu moins clair. Et la distribution de F et H sont satisfaisantes.

Conclusion sur cette première partie : On peut constater que la meilleur approximation de la loi des paramètres sachant les données est celle est avec le nombre de mouche dans les phases Smurf et Non-Smurf. De plus, même si on réduit l'information en utilisant que le nombre de mouche dans la phase Non-Smurf les approximations de la loi des paramètres sachant les données sont aussi satisfaisantes.

3.3.2 Deuxième partie : estimations de K_1, K_2, D en fixant F, G, H

Cette partie est la plus intéressante car les paramètres sont plus difficiles à estimer, car, dans cette partie on cherche les constantes d'un taux décroissant exponentiellement. C'est pourquoi, toutes les informations sont dans les premières heures.

Dans cette partie on a utilisé trois distances d_1 , d_4 et d_1 mais sur 12 heures.

Pour la distance d_1, on fixe ϵ = (9000, 8000 , 6000 ,5000 ,4000,3000)

Analysons l'estimation des paramètres ainsi que leurs histogrammes

Analyse des paramètres

```
Pour le paramètre K1 :
  Moyenne des estimations : 0.009664
  Variance des estimations : 3.762e-06
  Intervalle de crédibilité à 95% : [ 0.005992 ,  0.013408 ]
  Largeur de l'intervalle :  0.007416
  Erreur relative :  0.3215787

Pour le paramètre K2 :
  Moyenne des estimations : 0.02861168
  Variance des estimations : 0.000200381
  Intervalle de crédibilité à 95% : [ 0.004783 ,  0.053586 ]
  Largeur de l'intervalle :  0.048803
  Erreur relative :  0.02407571

Pour le paramètre D :
  Moyenne des estimations : 0.069141
  Variance des estimations : 0.001016003
  Intervalle de crédibilité à 95% : [ 0.013007 ,  0.122544 ]
  Largeur de l'intervalle :  0.109537
  Erreur relative :  0.02964863
```

FIGURE 11 – Analyse des paramètres

On remarque une bonne estimation pour K_2, D et leur erreur relative est inférieur à 3%. Cependant, ce n'est pas le cas pour K_1 où l'erreur relative est supérieur à 30%.

Regardons leurs histogrammes

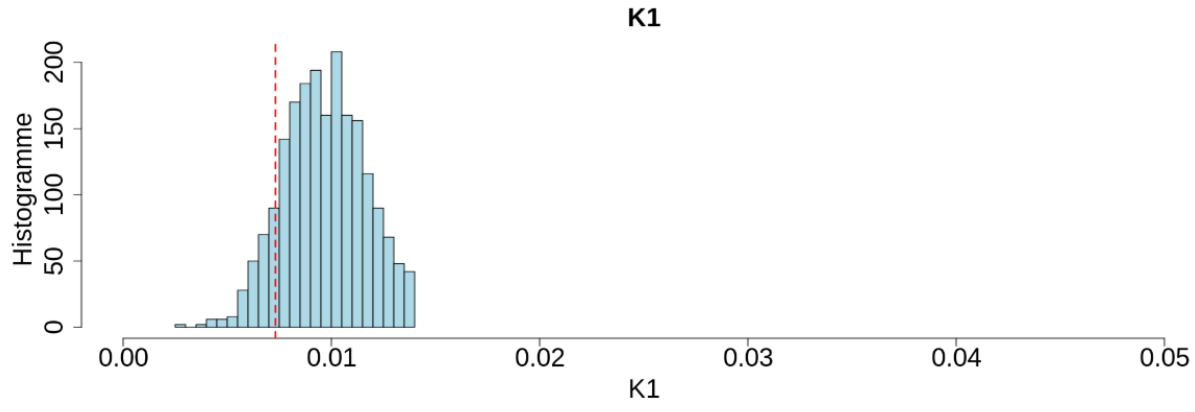


FIGURE 12 – Histogramme de K1

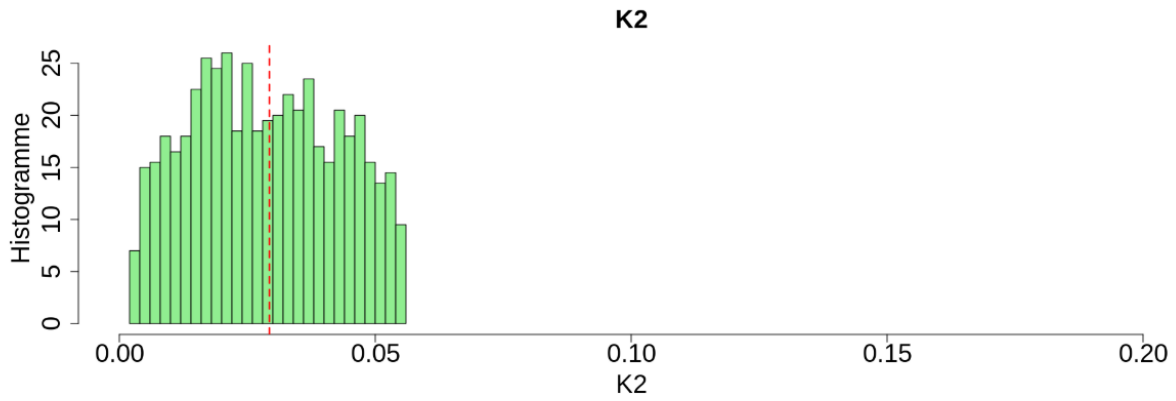


FIGURE 13 – Histogramme de K2

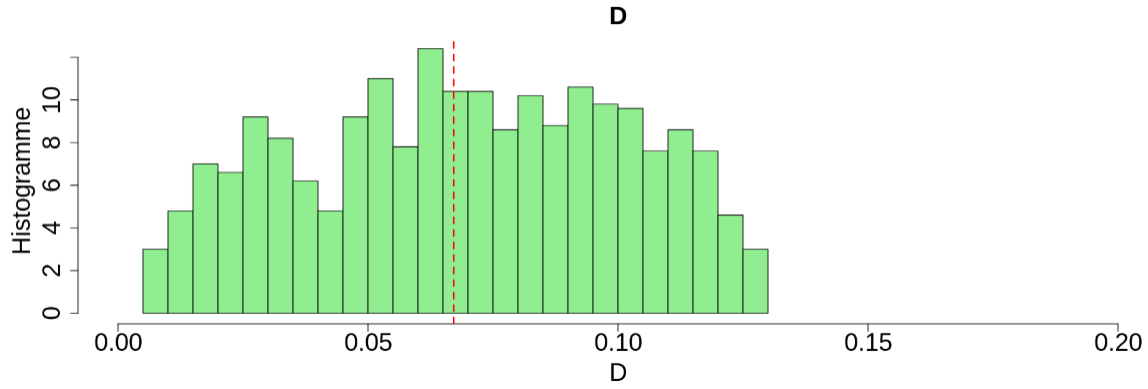


FIGURE 14 – Histogramme de D

On voit que la distribution de K_2 et D sont bien dispersé autour des valeurs théoriques (pointillé en rouge), ce qui n'est pas le cas pour K_1 et on peut s'attendre à cela car l'erreur relative de la moyenne de K_1 était de 32%

La distance d_4 permet de réduire erreur relative de K_1 : On peut rajouter de l'information sur K_1 car on sait que d'après le taux :

$$k_d(a) = K_1 + K_2 exp(-Da)$$

qui décrit comment les mouches se comportent dans la phase Smurf, on peut avoir de l'info sur K1 quand a tend vers l'infini donc introduisons dans le caclul de la distance la proportion de mouche encore vivante dans la phase Smurf. C'est pourquoi, nous allons utiliser la distance d_4 et le 17 signifie le pic de mouche dans la phase Smurf. Cette distance est différente des autres car elle nous donne deux valeurs : une par rapport au nombre de mouche morte et une autre par rapport à la propotion de mouche vivante dans la phase Smurf.

Pour cette distance d_4, on fixe deux tolérances :

$$\epsilon_A = \epsilon_{Dead} = (9000, 8000, 7000, 6000, 5000, 4000)$$

$$\epsilon_B = \epsilon_{proportion} = (0.2, 0.15, 0.10, 0.08, 0.06, 0.05)$$

Analysons l'estimation des paramètres ainsi que leurs histogrammes

Analyse des paramètres

```
Pour le paramètre K1 :
  Moyenne des estimations : 0.007069
  Variance des estimations : 2.191e-06
  Intervalle de crédibilité à 95% : [ 0.00436 ,  0.010326 ]
  Largeur de l'intervalle :  0.005966
  Erreur relative :  0.03331497

Pour le paramètre K2 :
  Moyenne des estimations : 0.02764833
  Variance des estimations : 0.000190673
  Intervalle de crédibilité à 95% : [ 0.004952 ,  0.052566 ]
  Largeur de l'intervalle :  0.047614
  Erreur relative :  0.05693492

Pour le paramètre D :
  Moyenne des estimations : 0.076887
  Variance des estimations : 0.000832531
  Intervalle de crédibilité à 95% : [ 0.02048 ,  0.124117 ]
  Largeur de l'intervalle :  0.103637
  Erreur relative :  0.1450079
```

FIGURE 15 – Analyse des paramètres

Une de baisse significative de l'erreur relative de K_1 est observé, cependant l'erreur relative de D a augmenté.

Regardons leurs histogrammes

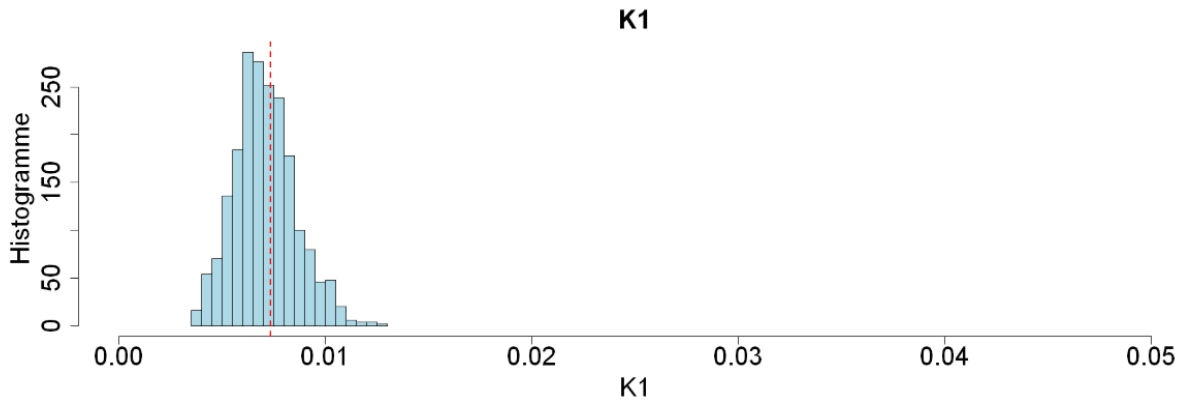


FIGURE 16 – Histogramme de K1

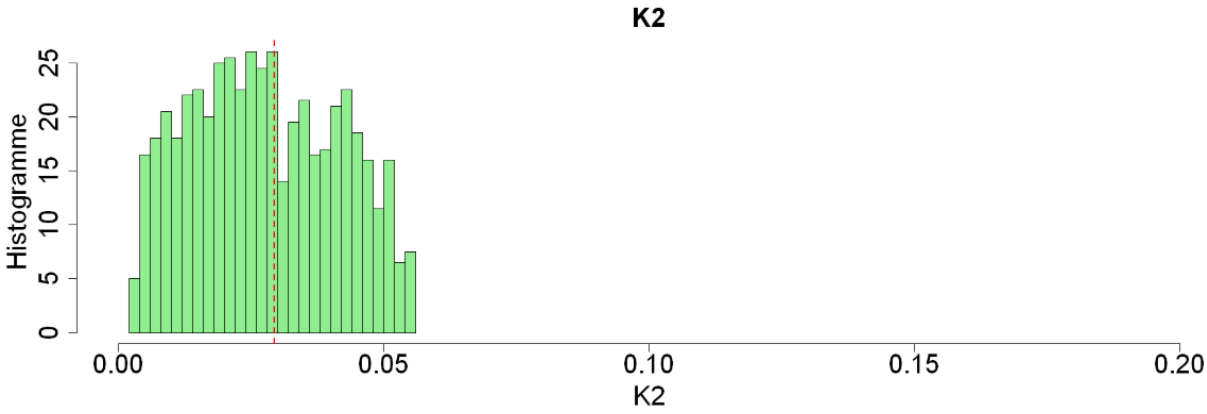


FIGURE 17 – Histogramme de K2

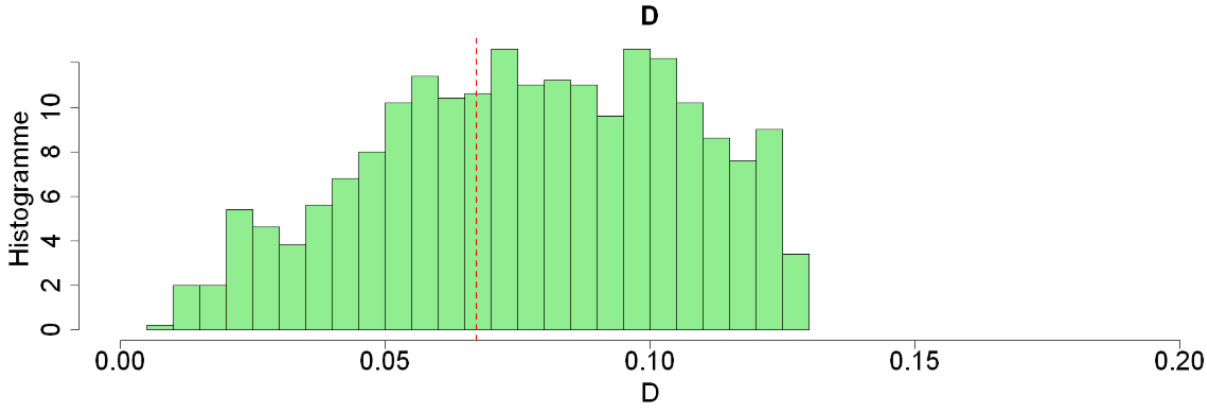


FIGURE 18 – Histogramme de D

On remarque que la distribution de K_1 est nettement plus centré autour de sa valeur théorique. A l'inverse celle de D s'étale un peu plus.

Piste intuitive mais fausse : On peut se dire qu'on pourrait rajouter de l'information dans le calcul de **la distance** d_5 pour permettre de réduire les erreurs relatives. C'est-à-dire qu'au lieu de prendre la proportion de mouche vivante dans la phase Smurf au jour 17, on la prend tout au long du cycle.

Pour cette distance d_5, on fixe deux tolérances :

$$\epsilon_A = \epsilon_{Dead} = (9000, 8000, 7000, 6000, 5000, 4000)$$

$$\epsilon_B = \epsilon_{proportion/jour} = (1, 0.9, 0.7, 0.5, 0.4, 0.2)$$

Analysons les estimations issus de cette idée

```
Pour le paramètre K1 :
  Moyenne des estimations : 0.009151
  Variance des estimations : 2.245e-06
  Intervalle de crédibilité à 95% : [ 0.006404 ,  0.011945 ]
  Largeur de l'intervalle :  0.005541
  Erreur relative :  0.2513698

Pour le paramètre K2 :
  Moyenne des estimations : 0.02096996
  Variance des estimations : 0.000120527
  Intervalle de crédibilité à 95% : [ 0.004662 ,  0.046172 ]
  Largeur de l'intervalle :  0.04151
  Erreur relative :  0.2847296

Pour le paramètre D :
  Moyenne des estimations : 0.080795
  Variance des estimations : 0.00079944
  Intervalle de crédibilité à 95% : [ 0.019586 ,  0.124767 ]
  Largeur de l'intervalle :  0.105181
  Erreur relative :  0.2032058
```

FIGURE 19 – Analyse des paramètres

On remarque que les erreurs relatives ont beaucoup augmenté au lieu de baissé. Ce phénomène est a cause de la répétitions des mêmes informations ce qui accentue le problème d'identifiabilité. C'est pourquoi, cette piste n'est pas envisageable.

Piste envisageable pour diminuer l'erreur de K_1 : Pour essayer de diminuer l'erreur relative de K_1, on sait que les informations par rapport aux variables aléatoires à estimer sont dans les premières heures alors, on peut se dire qu'au lieu de prélever les données toutes les 24 heures ce que l'on faisait jusqu'à maintenant, on prélève les données toutes les 12 heures.

Analysons les résultats de cette modification temporelle. On a utilisé la **distance** d_1.
On fixe ϵ = (10000, 9000 , 8000 ,7000 , 6000 , 5000)

Analysons l'estimation des paramètres ainsi que leurs histogrammes

Analyse des paramètres

```
Pour le paramètre K1 :
  Moyenne des estimations : 0.008435
  Variance des estimations : 9.262e-06
  Intervalle de crédibilité à 95% : [ 0.002853 ,  0.013565 ]
  Largeur de l'intervalle :  0.010712
  Erreur relative :  0.1534083

Pour le paramètre K2 :
  Moyenne des estimations : 0.03054019
  Variance des estimations : 0.000194911
  Intervalle de crédibilité à 95% : [ 0.005268 ,  0.053956 ]
  Largeur de l'intervalle :  0.048688
  Erreur relative :  0.04170418

Pour le paramètre D :
  Moyenne des estimations : 0.064712
  Variance des estimations : 0.001110834
  Intervalle de crédibilité à 95% : [ 0.010641 ,  0.123123 ]
  Largeur de l'intervalle :  0.112482
  Erreur relative :  0.03630202
```

FIGURE 20 – Analyse des paramètres

On remarque les erreurs relatives de K_2 et D sont en dessous de 5% ce qui est bien et de 15% pour K_1.

Regardons leurs histogrammes

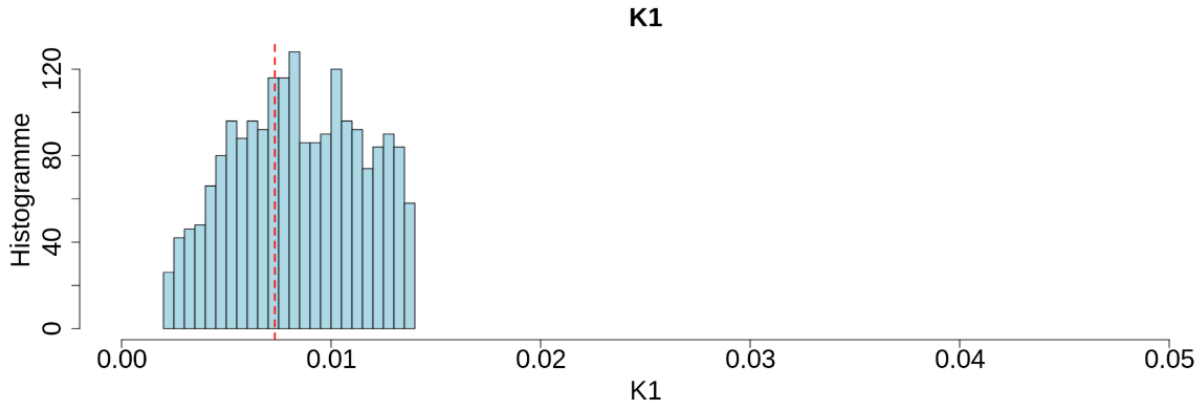


FIGURE 21 – Histogramme de K1

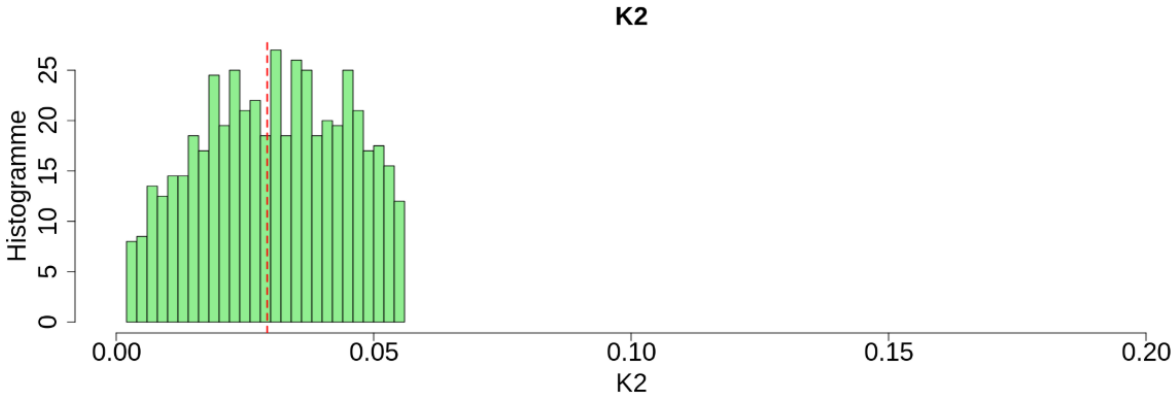


FIGURE 22 – Histogramme de K2

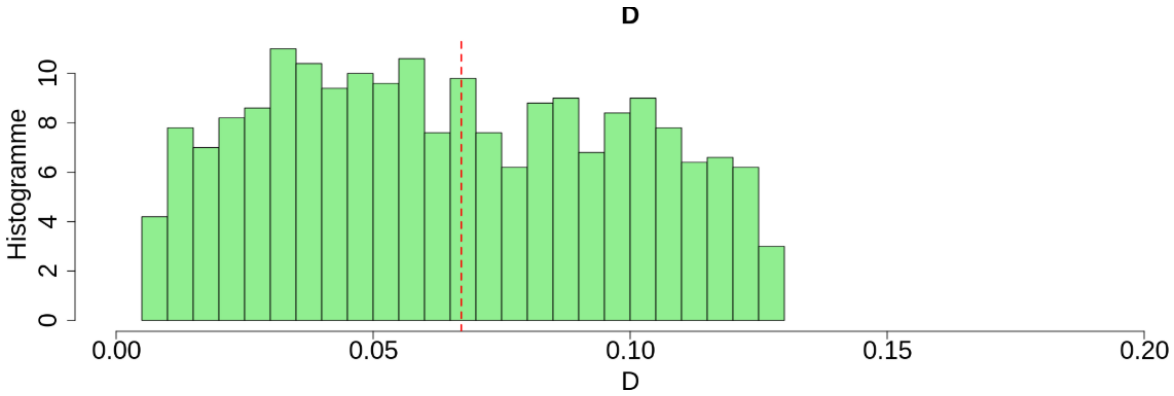


FIGURE 23 – Histogramme de D

L'histogramme de K_1 et K_2 sont bien centré autour de la valeur théorique et même si l'erreur relative de K_1 est de 15%. A première vue on dirait que l'histogramme de D n'est pas bonne ainsi que son estimation mais la partie analyse des paramètres le démontre.

Conclusion pour la deuxième partie : On remarque que la distance d_4 donne le meilleur compromis pour une prise de donnée toutes les 24 heures. De plus, la distance d_1 avec prise de données toutes les 12 heures donne également une assez bonne estimation, cependant, cette méthode peut être contraignante pour la personne qui prélève les données.

A noter : Les simulations sont aléatoires et le fait d'utiliser qu'une trajectoire dans les formules de distances ne décrit pas bien l'aléatoire car pour les mêmes paramètres on a des valeurs différentes pour N_{Dead},N_{NS},... C'est pourquoi, nous avons essayer d'estimer les 3 derniers paramètres en fixant les 3 premiers en utilisant comme distance $d_1 = \sqrt{\mathbf{E}[\sum_{i=1}^{n}((N_{Dead})_i - (N^*_{Dead})_i)^2]}$ ce qui permet de prendre en compte l'aléatoire. Cependant, ce code ne s'est pas terminer au bout de 2 jours donc on a oublié cette idée. Toutefois cette idée était une façon d'améliorer la prise en compte de l'aléatoire car le fait de travailler sur 1159 mouches produit un effet de moyennisation qui prend en compte l'aléatoire.

3.4 Comparaison des simulations obtenues avec les paramètres estimés (distance d_4)

Dans cette section, nous nous concentrons sur l'estimation des paramètres K_1, K_2 et D (en fixant F, G, H à leurs valeurs théoriques), en utilisant la distance d_4, qui combine une composante liée au nombre de morts et une composante liée à la proportion de mouches encore vivantes dans la phase Smurf. C'est cette distance qui offre le meilleur compromis parmi celles testées (voir la conclusion de la section précédente).

Afin d'évaluer la qualité de cette estimation au-delà des simples erreurs relatives et histogrammes déjà présentés, vingt particules acceptées par l'algorithme ABC-SMC ont été tirées aléatoirement parmi les particules finales. Pour chacune d'entre elles, une nouvelle simulation de population a été réalisée avec les paramètres correspondants, puis comparée à la simulation obtenue avec les paramètres théoriques.

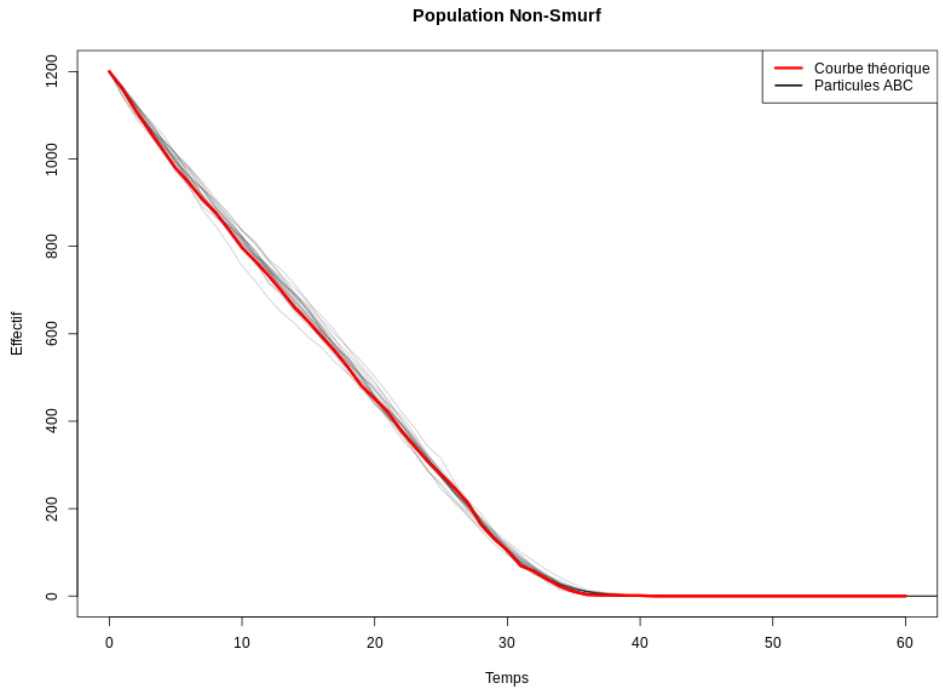


FIGURE 24 – Population Non-Smurf simulée : courbe théorique (couleur) vs 20 particules acceptées par ABC-SMC (distance d_4, en gris transparent).

Comme attendu, la population Non-Smurf est parfaitement retrouvée puisque les paramètres F, G, H sont fixés à leurs valeurs de référence : les courbes simulées se superposent pratiquement à la courbe théorique.

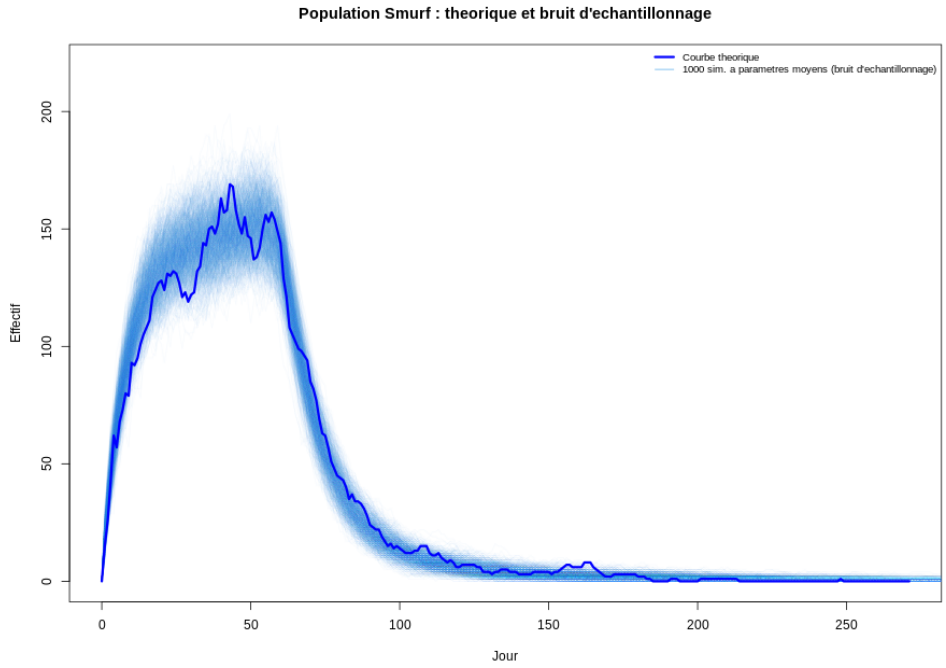


FIGURE 25 – Population Smurf simulée : comparaison entre la courbe théorique et l'enveloppe de variabilité stochastique issue de 1000 simulations aux paramètres moyens (distance d_4).

Contrairement aux populations Non-Smurf et Décédés dont les trajectoires sont évaluées à partir de 20 particules individuelles, la dynamique Smurf a fait l'objet d'une analyse complémentaire pour isoler les sources d'incertitude. Afin d'évaluer la part de variabilité intrinsèque liée au processus stochastique indépendamment de l'erreur d'estimation des paramètres, 1000 simulations ont été réalisées en fixant les paramètres K_1, K_2 et D à leurs valeurs moyennes estimées par l'ABC-SMC.

Le faisceau bleu clair obtenu représente ainsi le bruit d'échantillonnage pur (la variabilité inter-simulations à paramètres constants). On observe que la courbe théorique se situe parfaitement au cœur de ce nuage de trajectoires. Cela démontre que les écarts constatés ne proviennent pas d'un biais systématique de l'estimation, mais reflètent la stochasticit naturelle de la transition et de la survie des individus Smurf pour un effectif initial de $N_0 = 1200$.

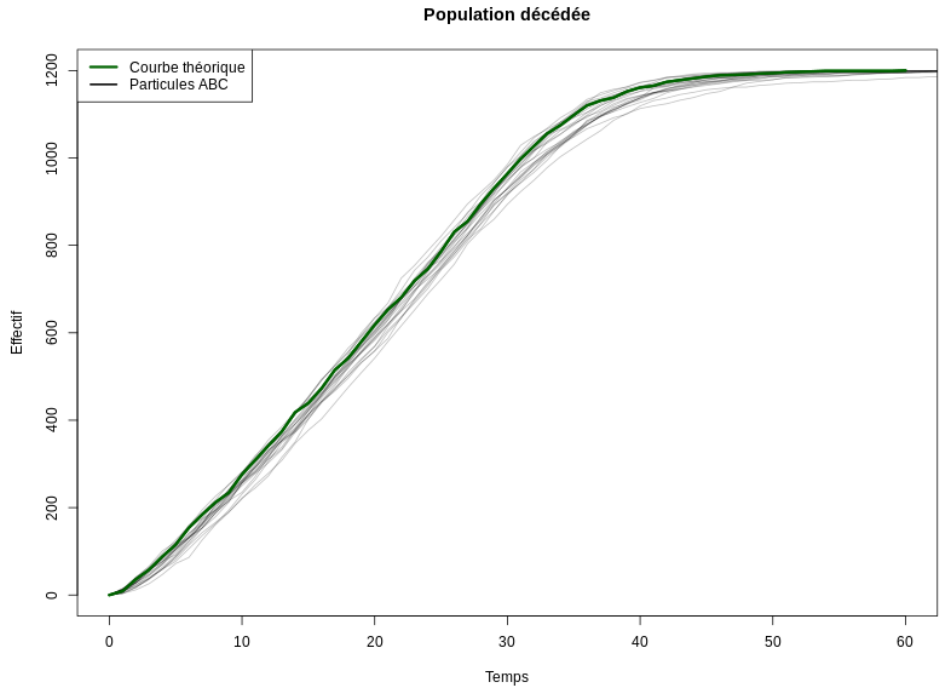


FIGURE 26 – Population des individus décédés : courbe théorique vs particules ABC-SMC (distance d_4).

Enfin, les courbes représentant la population décédée montrent une bonne concordance entre les simulations obtenues avec les paramètres estimés et la simulation théorique. Bien que les estimations individuelles des paramètres diffèrent légèrement des valeurs réelles, elles permettent de reproduire correctement la dynamique globale des décès.

Ces résultats illustrent un phénomène classique en inférence de paramètres : même lorsque les paramètres estimés ne sont pas identiques aux paramètres théoriques, la méthode ABC est capable de retrouver une dynamique de population très proche de celle observée. Plusieurs jeux de paramètres différents peuvent ainsi conduire à des trajectoires similaires, ce qui met en évidence la difficulté d'identifier de manière unique les paramètres du modèle à partir des seules données de mortalité – un problème d'identifiabilité déjà évoqué dans la section précédente.

3.5 Analyse de la fonction de mortalité Smurf $\kappa(t)$ à partir de la distribution *a posteriori* (distance d_4)

Plutôt que de se limiter à une comparaison des courbes de population, nous proposons ici une analyse portant directement sur la fonction d'intensité de mortalité Smurf :

$$\kappa(a) = K_1 + K_2\, e^{-Da}$$

où a désigne le temps passé dans la phase Smurf. Cette analyse exploite l'ensemble de la distribution *a posteriori* des particules acceptées par l'ABC-SMC (distance d_4), plutôt qu'un unique triplet ponctuel (K_1, K_2, D).

3.5.1 Courbe moyenne et intervalle de crédibilité à 95 %

Pour chaque temps a d'une grille régulière, la valeur $\kappa_i(a)$ est calculée pour chacune des particules i acceptées par l'algorithme (jeu de paramètres $(K_{1,i}, K_{2,i}, D_i)$). On en déduit, pour chaque a :

- la moyenne ponctuelle $\overline{\kappa}(a) = \dfrac{1}{M}\sum_{i=1}^{M} \kappa_i(a)$, qui constitue une estimation de $\mathbb{E}[\kappa(a) \mid \text{données}]$;
- les quantiles empiriques à 2,5 % et 97,5 %, qui définissent l'intervalle de crédibilité à 95 % de $\kappa(a)$.

Cette approche est préférable à l'évaluation de κ aux seuls paramètres moyens $(\overline{K_1}, \overline{K_2}, \overline{D})$, dans la mesure où κ est une fonction non linéaire des paramètres (à cause du terme exponentiel) : la moyenne de la fonction diffère en général de la fonction évaluée à la moyenne des paramètres.

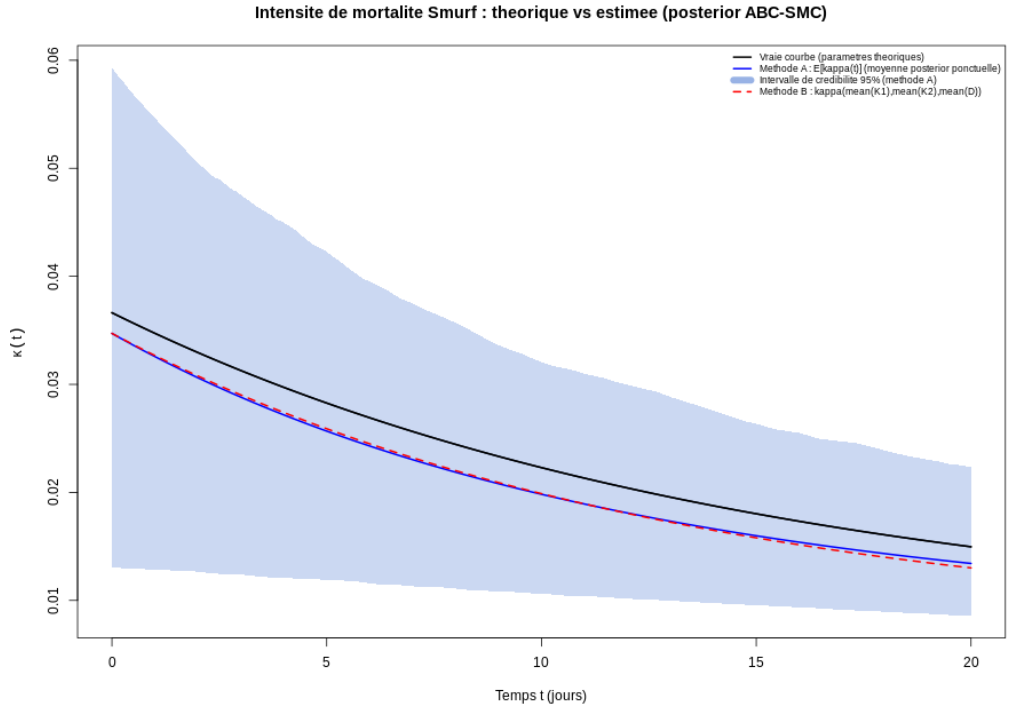


FIGURE 27 – Fonction de mortalité Smurf $\kappa(a)$: courbe théorique, moyenne *a posteriori* et intervalle de crédibilité à 95 % (distance d_4), comparée à la courbe obtenue avec les paramètres moyens.

3.5.2 Erreur quadratique intégrée

Afin de quantifier l'écart entre l'estimation *a posteriori* et la véritable fonction $\kappa_{\text{théo}}$, deux indicateurs complémentaires ont été calculés.

Le premier, l'erreur quadratique intégrée de la courbe moyenne, mesure le biais de la courbe résumée :

$$\text{ISE}_{\text{moyenne}} = \int_0^{a_{\max}} \left(\overline{\kappa}(a) - \kappa_{\text{théo}}(a)\right)^2 \, da$$

Le second, l'espérance de l'erreur quadratique intégrée, calculée particule par particule puis moyennée, tient compte en plus de la dispersion du posterior :

$$\text{IMSE} = \mathbb{E}_i\left[\int_0^{a_{\max}} \left(\kappa_i(a) - \kappa_{\text{théo}}(a)\right)^2 \, da\right]$$

Par inégalité de Jensen, on a toujours $\text{IMSE} \geq \text{ISE}_{\text{moyenne}}$; l'écart entre les deux quantifie la part de l'erreur imputable à la dispersion des particules plutôt qu'au biais de la courbe moyenne.

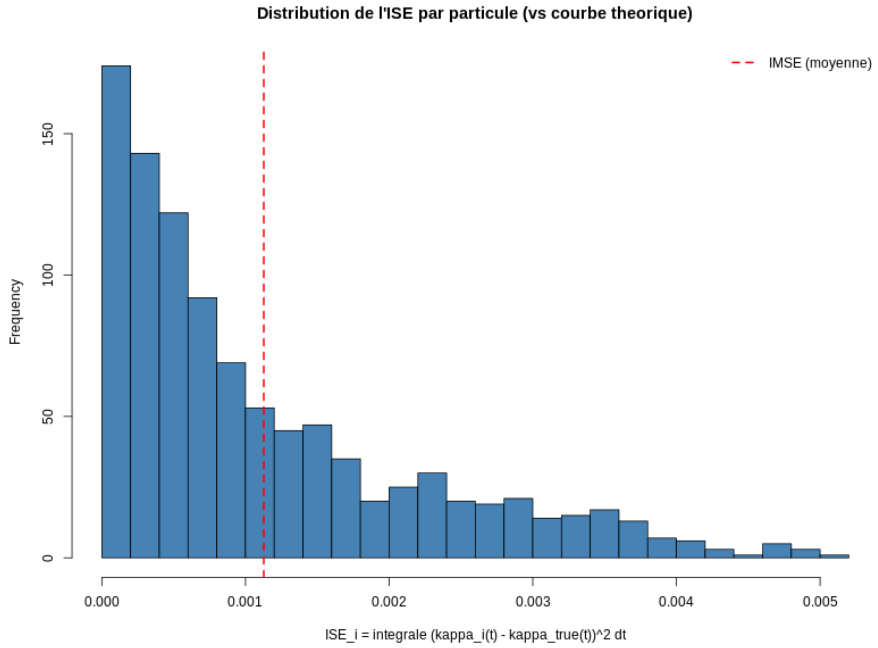


FIGURE 28 – Distribution de l'erreur quadratique intégrée ISE_i par particule acceptée (distance d_4). La ligne pointillée rouge indique l'IMSE (moyenne).

Les valeurs numériques obtenues pour les particules issues de la distance d_4 sont résumées dans le tableau 2.

Indicateur	**Valeur**
$\text{ISE}_{\text{moyenne}}$ – méthode A ($\mathbb{E}[\kappa(a)]$ ponctuel)	$1{,}028 \times 10^{-4}$
$\text{ISE}_{\text{moyenne}}$ – méthode B (κ des paramètres moyens)	$1{,}024 \times 10^{-4}$
$\text{IMSE} = \mathbb{E}_i[\text{ISE}_i]$	$1{,}127 \times 10^{-3}$
Écart-type de ISE_i entre particules	$1{,}087 \times 10^{-3}$

TABLE 2 – Erreurs quadratiques intégrées obtenues sur la distribution *a posteriori* des particules acceptées (distance d_4).

Deux observations principales se dégagent de ces résultats.

Premièrement, les méthodes A et B donnent des valeurs d'ISE quasiment identiques ($1{,}028 \times 10^{-4}$ contre $1{,}024 \times 10^{-4}$). Cela signifie que, dans ce cas précis, la non-linéarité de κ en fonction de (K_1, K_2, D) a un effet négligeable sur la courbe résumée : évaluer κ aux paramètres moyens donne ici une courbe quasiment équivalente à la moyenne ponctuelle de κ sur l'ensemble des particules. La courbe moyenne *a posteriori*, quelle que soit la méthode utilisée pour la construire, reste donc très proche de la courbe théorique : l'ISE de la moyenne est de l'ordre de 10^{-4}, ce qui traduit un biais faible.

Deuxièmement, et c'est le point le plus notable, l'IMSE ($1{,}127 \times 10^{-3}$) est environ dix fois plus élevé que l'ISE de la courbe moyenne. Conformément à l'inégalité de Jensen évoquée plus haut, cet écart montre que l'essentiel de l'erreur ne provient pas d'un biais systématique de l'estimation (la courbe moyenne est fidèle à la théorie), mais de la **dispersion des particules acceptées** : certaines particules, prises individuellement, s'écartent nettement de la courbe théorique, même si elles se compensent en moyenne. Ce constat est cohérent avec l'écart-type de ISE_i ($1{,}087 \times 10^{-3}$), qui est du même ordre de grandeur que l'IMSE lui-même : la distribution des erreurs individuelles est donc très étalée, avec probablement quelques particules nettement moins bonnes que les autres qui tirent la moyenne vers le haut. Cette forte dispersion fait écho au problème d'identifiabilité déjà observé sur le paramètre K_1 (erreur relative la plus élevée des trois), et confirme que si la dynamique de population globale est bien reproduite en moyenne, l'incertitude sur la fonction de mortalité $\kappa(a)$ elle-même reste substantielle particule par particule.

Cette analyse complète la comparaison des courbes de population de la section précédente : elle permet de quantifier précisément, sur la fonction de risque elle-même plutôt que sur les seules trajectoires de population, la qualité et l'incertitude de l'estimation obtenue avec la distance d_4.

3.5.3 Conclusion

Dans cette première partie nous avons introduit un modèle mathématiques décrivant l'évolution des deux phases Non-Smurf et Smurf. Puis, nous avons crée une simulation qui reproduit les lois théoriques tant au niveau du temps de transition que de la dynamique globale de la population.

Par la suite, l'ABC-SMC nous a permis d'estimer les 3 paramètres en fixant 3 autres. La partie estimation de F, G, H qui traduit la transition de l'état Non-Smurf à Smurf en fixant K_1, K_2, D est meilleur, tandis que l'estimation de K_1, K_2, D qui décrit le taux de mortalité des Smurf est plus complexe. Les résultats nous montre l'importance des statistiques résumées utilisées dans les distances pour l'utilisation de l'ABC.

Enfin la comparaison entre la courbe théorique et les trajectoires simulées sont satisfaisantes malgré le fait qu'il y a un problème d'identifiabilité pour K_1. Cela permet de dire que la méthodologie et l'estimation des paramètres sur des données simulées est plutôt satisfaisante. C'est pourquoi, dans la partie suivante, nous allons appliquer cela sur des données réelles.

nous avons utilisé les paramètres théoriques issues du modèle 3 de l'article [2] pour simuler une population théorique et on a effectué un tirage uniforme dont les bornes sont plus ou moins 90% des paramètres théoriques pour crée des données simulées.

4 Partie 2 – Données réelles

4.1 Traitement de données

Nous allons re-estimer les paramètres de la même manière en fixant 3 paramètres. Cependant, nous allons utiliser des données réelles prises pendant une expérience au lieu de les simuler avec les paramètres théoriques. On utilisera les données times_exp qui se situe dans le GitHub [5].

Les données réelles sont :

— N_0 : Nombre de mouche initial
— τ_{Smurf} : le temps qu'il faut pour qu'une mouche passe de l'état Non-Smurf à Smurf en heures
— τ_{Death} : le temps qu'il faut pour qu'une mouche décède en étant dans la phase Smurf en heures

Donc pour utiliser ces données dans nos simulation, il faut convertir ces données en nombres de mouches dans les phases Non-Smurf, Smurf et Mort.

La répartition se fera comme suit pour un jour donné t = 1,2,3,... :
— Mouche Non-Smurf si $t \leq \tau_{Smurf}$
— Mouche Smurf si $\tau_{Smurf} \leq t \leq \tau_{Smurf} + \tau_{Death}$
— Mouche Morte si $t \geq \tau_{Smurf} + \tau_{Death}$

Grâce à cette répartition on peut obtenir le nombre de mouche dans chaque phase afin de procéder aux approximations. Sachant que notre but est de savoir si on peut transposer l'approximation par l'algorithme ABC-SMC aux données réelles de ce faite nous allons utiliser les même distance que dans la partie précédente.

Les résultats seront interprétés d'une manière différente de ceux issus des simulations précédentes. En sachant que l'on a maintenant des données observés alors on ne connaît pas les valeurs théoriques. De plus, les paramètres du modèle 3 sont issus des hypothèses de ce modèle. Par conséquent, il n'est plus possible de calculer une erreur relative comme dans une étude de simulation. Donc les résultats issus de l'ABC seront comparés avec celles obtenus par la méthode du maximum de vraisemblance pour le modèle 3. Enfin, si les deux méthodes donnent des résultats semblables alors l'ABC fonctionne et reproduit des estimations proches de ceux du modèle 3 du modèle 3 et s'il y a de grand écart alors le modèle 3 ne décrit pas bien les données observés ou l'ABC ne fonctionne pas.

4.2 Estimation des paramètres grâce à l'algorithme ABC-SMC (Approximate Bayesian Computation Sequential Monte Carlo)

4.2.1 Première partie : estimation de F, G, H en fixant K_1, K_2, D

Dans cette partie, nous allons estimer (F, G, H) en fixant (K_1 , K_2 , D). De la même manière nous allons utiliser les **distances** d_2 **,** d_3

Pour la distance d_2, on fixe $\epsilon = (2000, 1000, 900, 700, 500, 350)$

Analysons l'estimation des paramètres ainsi que leurs histogrammes (avec les paramètres de référence du modèle 3 en pointillé en rouge)

Analyse des paramètres

```
Pour le paramètre F :
  Moyenne des estimations : 0.001527
  Variance des estimations : 6.4e-08
  Intervalle de crédibilité à 95% : [ 0.001049 ,  0.002003 ]
  Largeur de l'intervalle :  0.000954
  Ecart avec le paramètre du modèle 3  :  0.04015563

Pour le paramètre G :
  Moyenne des estimations : 7.2246e-05
  Variance des estimations : 1e-09
  Intervalle de crédibilité à 95% : [ 1.4e-05 ,  0.000138 ]
  Largeur de l'intervalle :  0.000124
  Ecart avec le paramètre du modèle 3  :  0.04244184

Pour le paramètre H :
  Moyenne des estimations : 0.006915
  Variance des estimations : 1.65e-06
  Intervalle de crédibilité à 95% : [ 0.004781 ,  0.009695 ]
  Largeur de l'intervalle :  0.004914
  Ecart avec le paramètre du modèle 3 :  0.04180383
```

FIGURE 29 – Analyse des paramètres

On voit que l'écart des résultats des deux modèles sont assez faibles environ 4% donc les résultats issus de l'ABC sont proches de ceux du modèles 3.

Regardons leurs histogrammes

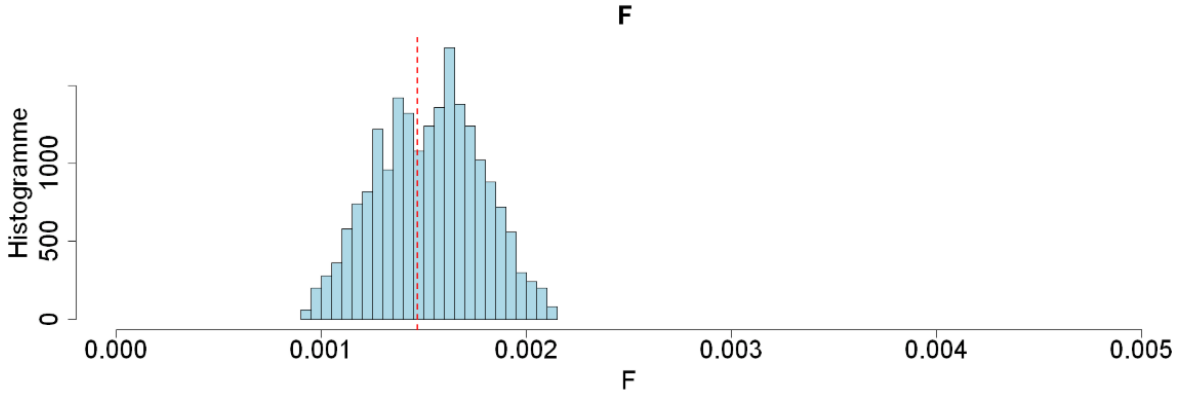


FIGURE 30 – Histogramme de F

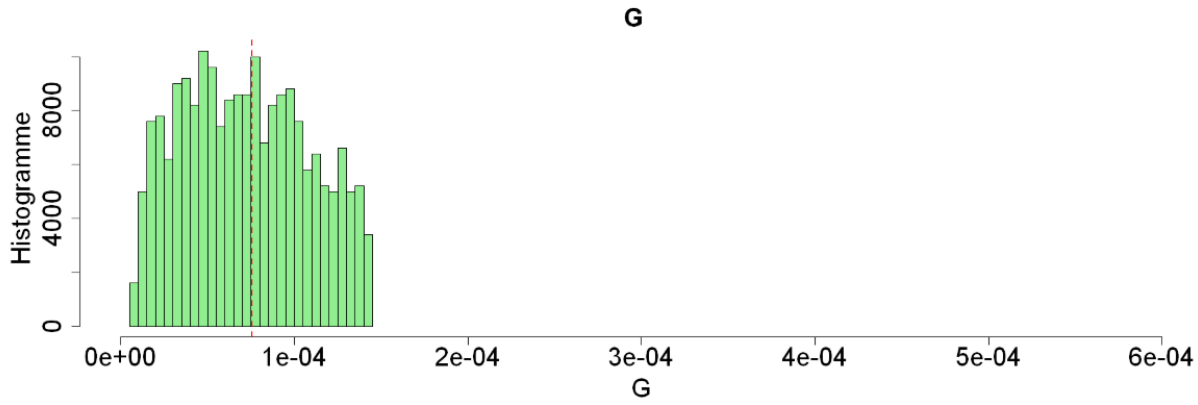


FIGURE 31 – Histogramme de G

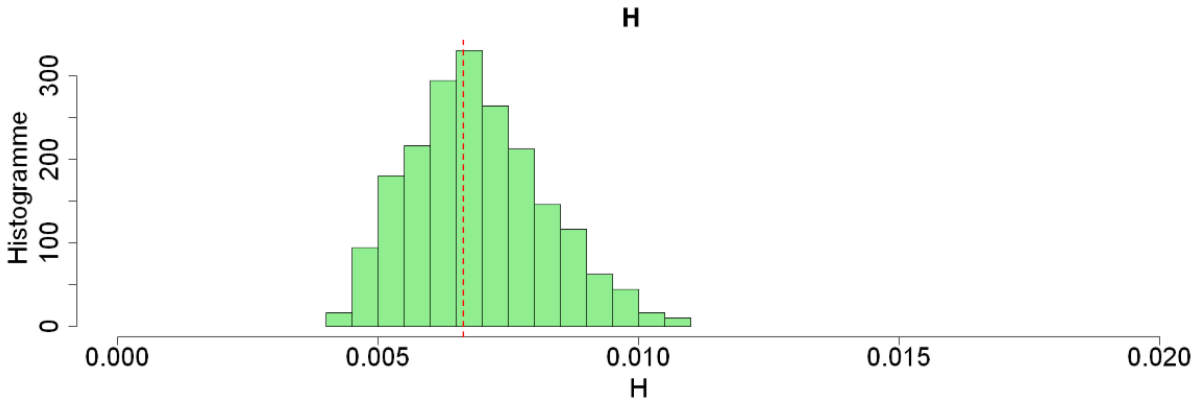


FIGURE 32 – Histogramme de H

Pour cette distance la répartition des distributions est centrées autour des paramètres de références du modèle 3.

Pour la distance d_3, on fixe la tolérance $\epsilon = (2000, 1000, 900, 800, 700, 500)$

Analysons l'estimation des paramètres (avec les paramètres de référence du modèle 3 en pointillé en rouge) ainsi que leurs histogrammes

Analyse des paramètres

```
Pour le paramètre F :
  Moyenne des estimations : 0.001499
  Variance des estimations : 4.7e-08
  Intervalle de crédibilité à 95% : [ 0.001057 ,  0.001904 ]
  Largeur de l'intervalle :  0.000847
  Ecart avec le paramètre du modèle 3  :  0.02106898

Pour le paramètre G :
  Moyenne des estimations : 7.3306e-05
  Variance des estimations : 1e-09
  Intervalle de crédibilité à 95% : [ 1.3e-05 ,  0.000138 ]
  Largeur de l'intervalle :  0.000125
  Ecart avec le paramètre du modèle 3  :  0.02839086

Pour le paramètre H :
  Moyenne des estimations : 0.007156
  Variance des estimations : 1.512e-06
  Intervalle de crédibilité à 95% : [ 0.00518 ,  0.010064 ]
  Largeur de l'intervalle :  0.004884
  Ecart avec le paramètre du modèle 3 :  0.07807166
```

FIGURE 33 – Analyse des paramètres

L'écart des résultats des deux modèles pour F et G est de 2% donc plus faible que ceux de avec la distance d_2, or, l'écart pour H est presque deux fois plus grande.

Regardons leurs histogrammes

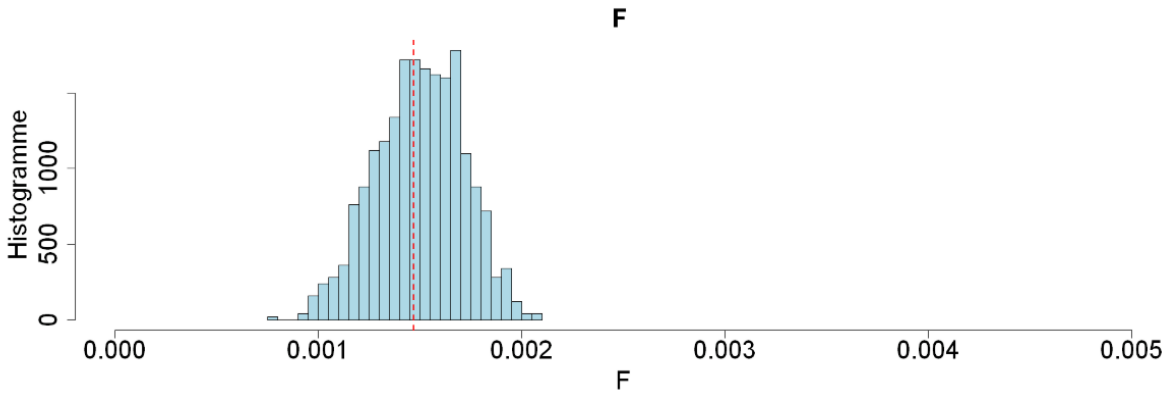


FIGURE 34 – Histogramme de F

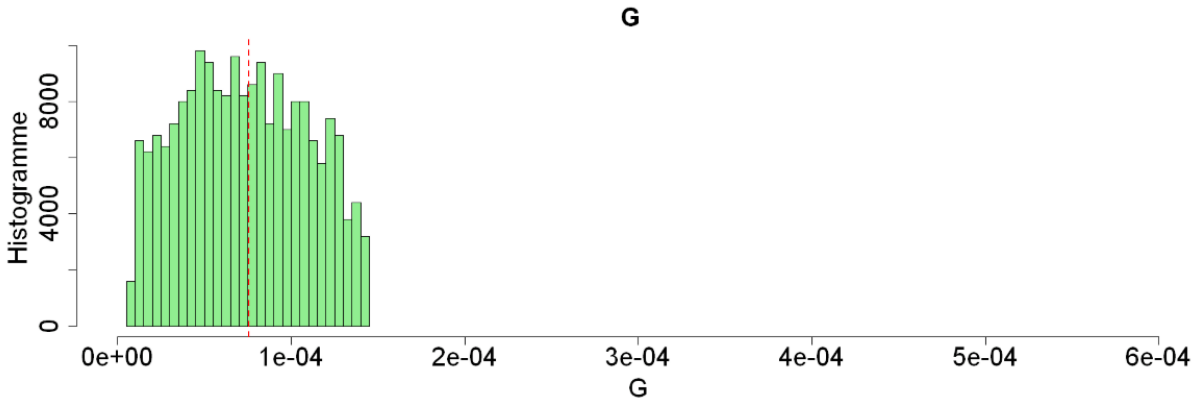


FIGURE 35 – Histogramme de G

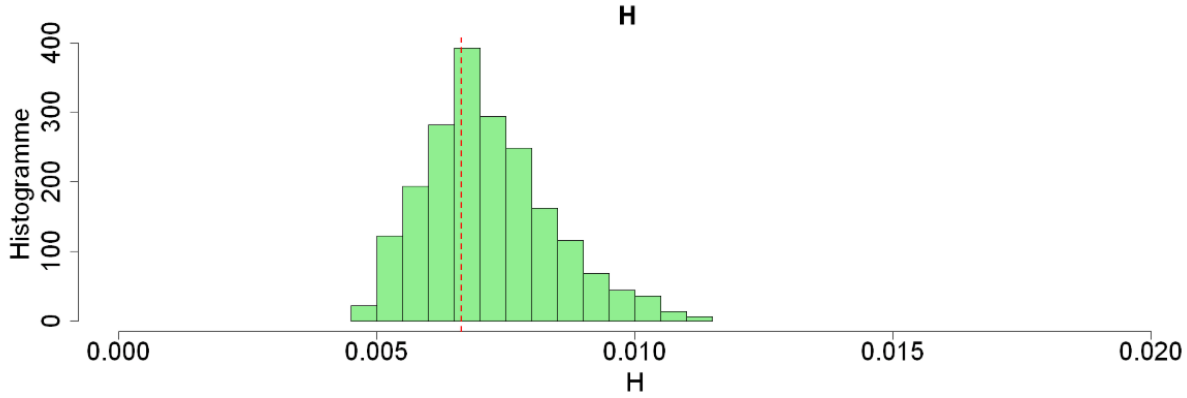


FIGURE 36 – Histogramme de H

Même remarque que les distributions précédentes.

Conclusion sur cette première partie : On peut constater que l'approximation qui offre le plus petit écart au niveau des résultats des deux méthodes est celle avec le nombre de mouche dans la phase Non-Smurf (distance d_2). Tout de même, la distance d_3 donne des bons résultats. Enfin, l'utilisation de l'ABC-SMC pour approximer les 3 premiers paramètres F, G, H en fixant les 3 derniers paramètres K_1, K_2, D au niveau des données réelles suggère que les hypothèses du modèle 3 sont compatibles avec les données réelles.

4.2.2 Deuxième partie : estimations de K_1, K_2, D en fixant F, G, H

L'estimation de ces 3 paramètres étaient déjà compliqués dans la section précédente, regardons si c'est également le cas dans cette section avec des données réelles. Nous allons utilisé la meilleur distance d_4.

Faisons une analyse des paramètres pour la **distance** d_4.

on fixe deux tolérances :

$$\epsilon_A = \epsilon_{Dead} = (9000, 8000, 7000, 6000, 5000, 4000)$$

$$\epsilon_B = \epsilon_{proportion} = (0.2, 0.15, 0.12, 0.09, 0.08, 0.07)$$

Analyse des paramètres

```
Pour le paramètre K1 :
  Moyenne des estimations : 0.009042
  Variance des estimations : 7.7e-07
  Intervalle de crédibilité à 95% : [ 0.00731 ,  0.010832 ]
  Largeur de l'intervalle :  0.003522
  Ecart avec le paramètre du modèle 3 :  0.236496

Pour le paramètre K2 :
  Moyenne des estimations : 0.01135178
  Variance des estimations : 5.1288e-05
  Intervalle de crédibilité à 95% : [ 0.003238 ,  0.029567 ]
  Largeur de l'intervalle :  0.026329
  Ecart avec le paramètre du modèle 3 :  0.6127987

Pour le paramètre D :
  Moyenne des estimations : 0.088699
  Variance des estimations : 0.000738818
  Intervalle de crédibilité à 95% : [ 0.02688 ,  0.126182 ]
  Largeur de l'intervalle :  0.099302
  Ecart avec le paramètre du modèle 3 :  0.3209049
```

FIGURE 37 – Analyse des paramètres

On remarque que l'écart pour K_2 est plus élevé que pour les autres paramètres.

Regardons leurs histogrammes

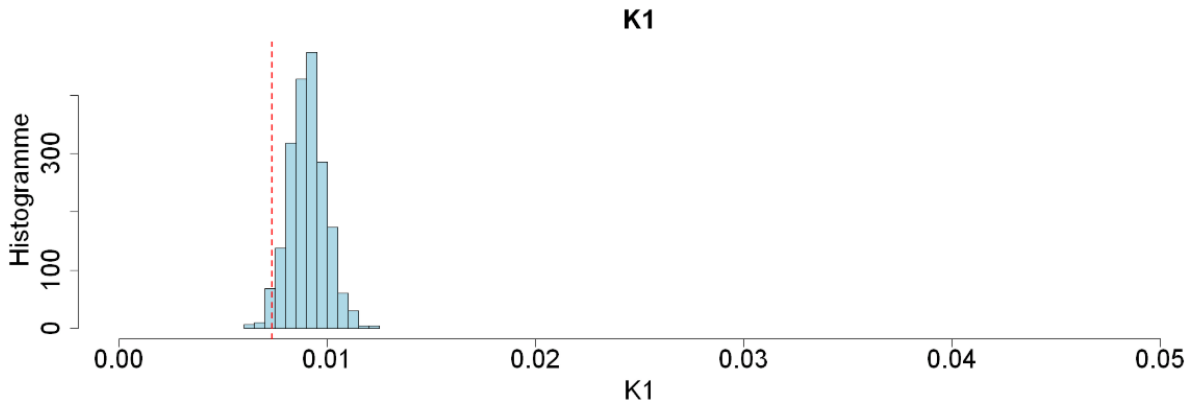


FIGURE 38 – Histogramme de K1

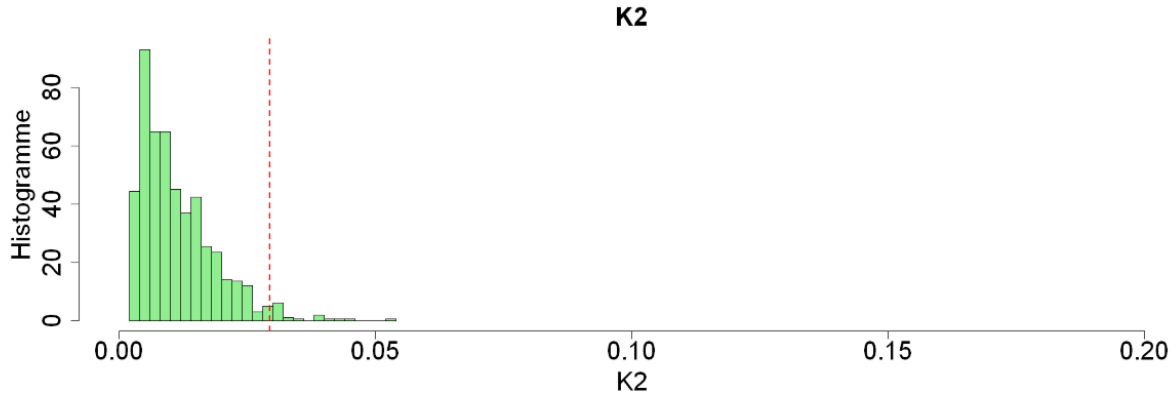


FIGURE 39 – Histogramme de K2

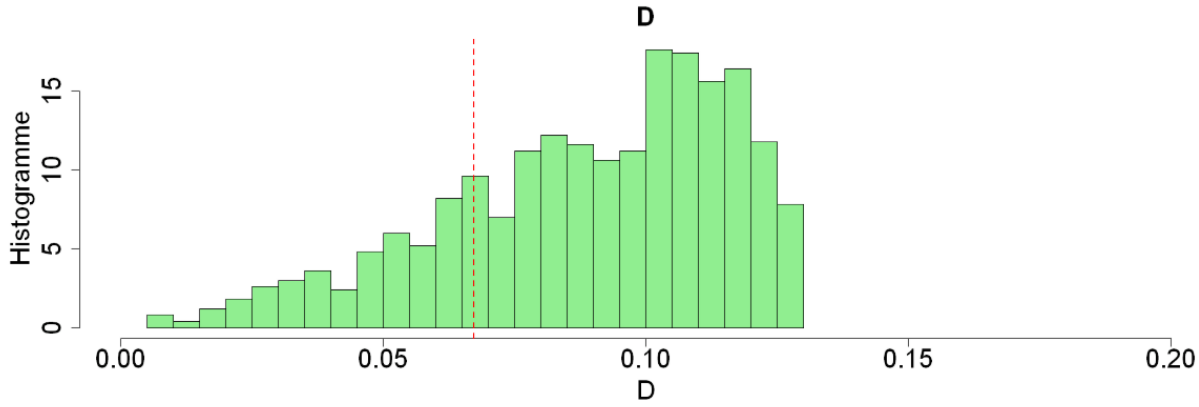


FIGURE 40 – Histogramme de D

Conclusion pour la deuxième partie : Cette partie nous montre que les résultats ne concordent pas avec les estimations de modèle 3 de l'article [2]. De ce fait, il y a deux explications soit le modèle 3 contient une erreur soit l'estimation n'est pas bonne. Nous avons également fait une analyse des paramètres et un traçage leurs histogrammes pour la distance d_1 dans la partie A de l'annexe.

4.3 Vérification des lois estimées et dynamique de la population Smurf

Les écarts importants observés ci-dessus entre l'ABC et le maximum de vraisemblance portent uniquement sur la valeur *ponctuelle* des paramètres K_1, K_2, D. Ils ne disent pas directement si le modèle 3, une fois ajusté, reproduit correctement la *forme* de la loi observée des temps de transition. Nous proposons donc une vérification complémentaire, dans le même esprit que celle menée en Partie I :

D'une part, on compare la fonction de répartition **empirique**, calculée directement à partir des temps observés (τ_{Smurf} et τ_{Death} du jeu de données `times_exp`), à la fonction de répartition **théorique moyenne a posteriori**, obtenue en recalculant la courbe associée à chacune des 1000 particules acceptées par l'ABC-SMC puis en moyennant point par point (ce qui est plus rigoureux dès lors que la loi dépend de façon non linéaire des paramètres). D'autre part, nous analysons l'impact de ces estimations sur l'effectif simulé de la population Smurf au cours du temps.

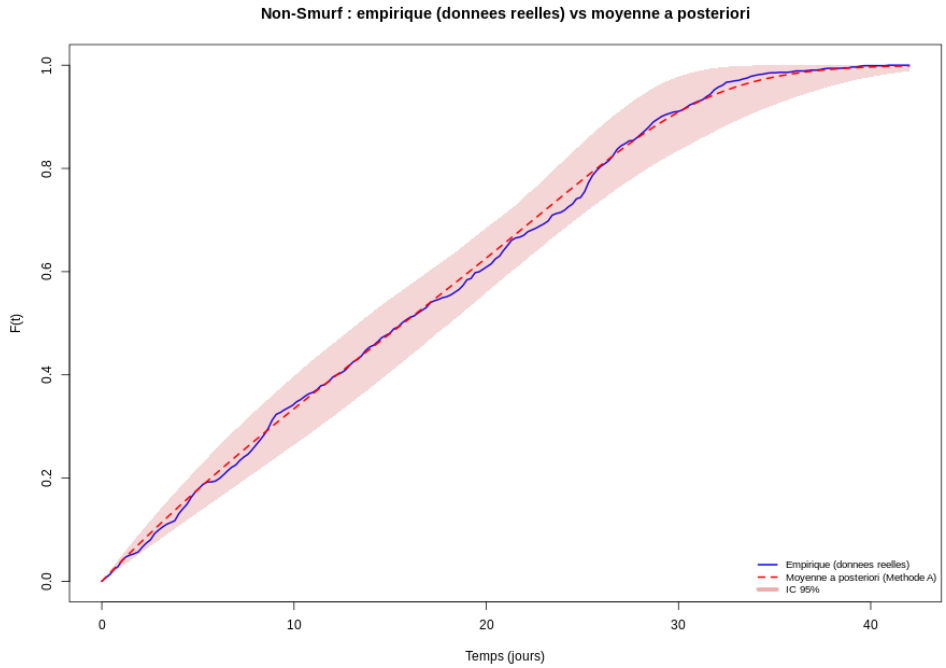


FIGURE 41 – Temps Non-Smurf : fonction de répartition empirique (données réelles) vs moyenne a posteriori des particules ABC-SMC (F, G, H), avec intervalle de crédibilité à 95 %.

Pour le temps Non-Smurf (Figure 41), l'accord est excellent : l'écart entre la courbe empirique et la moyenne a posteriori reste inférieur à 3 points de pourcentage sur toute la plage de temps observée (du jour 5 au jour 40). Ce résultat confirme que le modèle de transition Non-Smurf $\rightarrow$ Smurf (loi de Gompertz-Makeham) décrit très bien les données réelles.

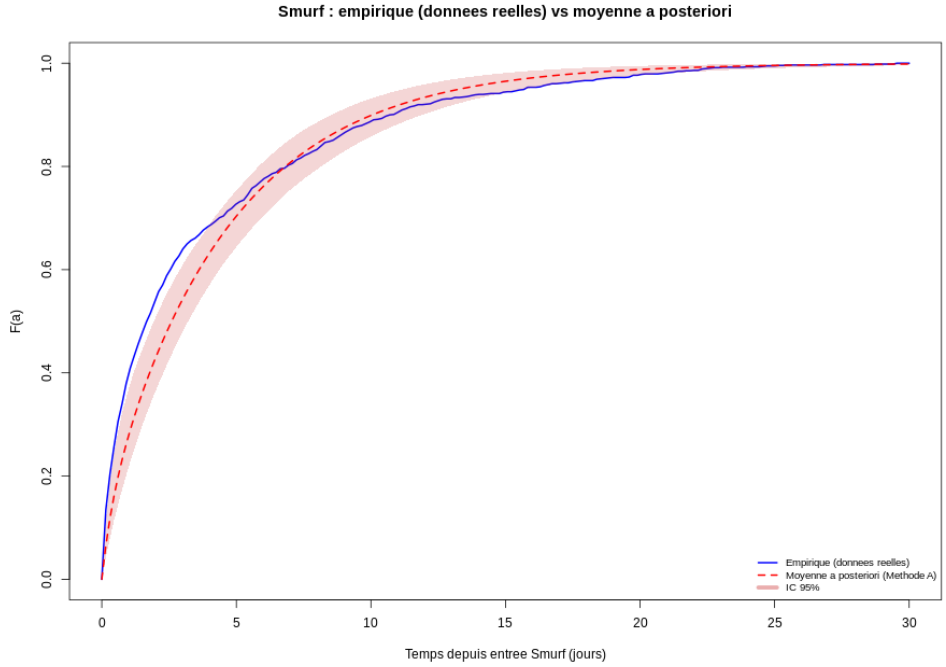


FIGURE 42 – Temps Smurf : fonction de répartition empirique (données réelles) vs moyenne a posteriori des particules ABC-SMC (K_1, K_2, D), avec intervalle de crédibilité à 95 %.

Pour le temps Smurf (Figure 42), l'image est plus nuancée. Un écart notable apparaît très tôt : au premier jour suivant la transition, la proportion empirique de mouches déjà mortes (40,9 %) est sensiblement supérieure à celle prédite par la moyenne a posteriori (28,9 %), soit un écart de 12 points. Cet écart se résorbe rapidement : il tombe à 5 points dès le jour 4, puis reste inférieur à 2 points à partir du jour 6 et jusqu'à la fin de la période observée.

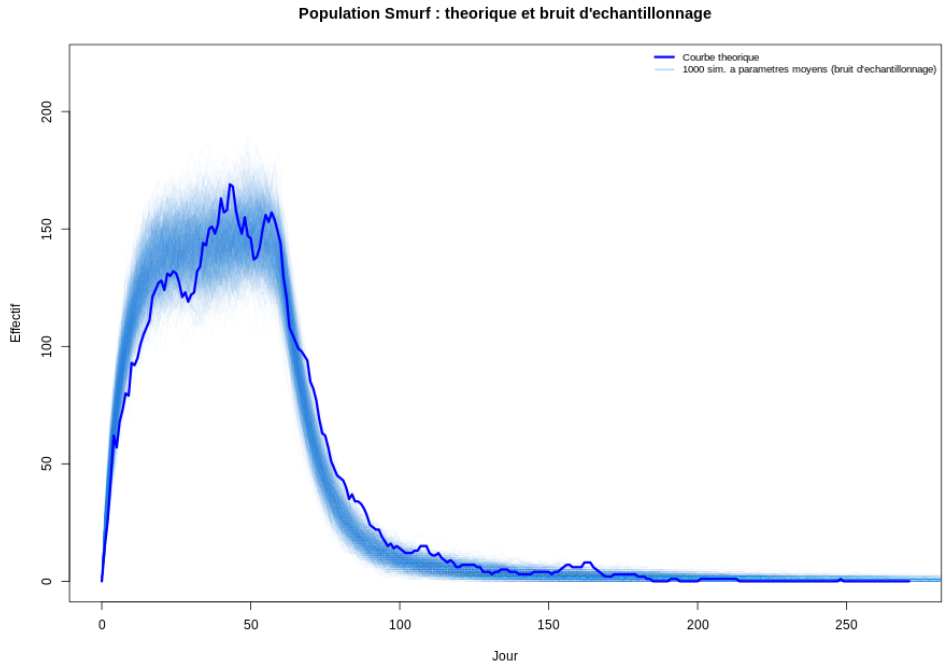


FIGURE 43 – Population Smurf sur données réelles (distance d_4) : trajectoire simulée aux paramètres moyens vs bruit d'échantillonnage (1000 simulations stochastiques, temps exprimé en jours).

Cette dynamique se traduit très clairement lorsqu'on simule l'effectif temporel de la population Smurf en fonction du temps (Figure 43, obtenue avec la distance d_4). Afin d'isoler la variabilité intrinsèque due à l'échantillonnage stochastique, 1000 simulations ont été exécutées aux paramètres moyens a posteriori $(\bar{K}_1, \bar{K}_2, \bar{D})$. On observe que la trajectoire reconstruite s'insère parfaitement au centre de l'enveloppe du bruit stochastique :

— La phase d'accumulation rapide des individus Smurf culmine vers $t \approx 45$–50 jours (atteignant un effectif pic d'environ 160–170 individus).

— La phase de déclin progressif de la population Smurf mène à une extinction quasi complète vers 180–200 jours, suivant fidèlement la dispersion stochastique attendue.

Ce constat permet de nuancer la conclusion de la section précédente : si les paramètres K_1, K_2, D pris individuellement s'écartent effectivement de ceux estimés par maximum de vraisemblance (en particulier K_1, dont l'impact est maximal dans les premières 24 à 48 heures), la dynamique d'ensemble et l'évolution temporelle de la population Smurf reconstruites à partir de la distribution a posteriori restent remarquablement fidèles à la réalité du processus. Par ailleurs, le traçage de la population Smurf sur les données réelles est également faite pour la distance d_1 dans l'annexe B.

4.4 Conclusion et Ouverture

Dans cette seconde partie, nous avons appliquée la méthodologie précédente mais cette fois-ci sur des données réelles afin d'évaluer la capacité à estimer les paramètres. Les résultats montre

que l'estimation des paramètres F, G, H par l'ABC-SMC est proche des paramètres théoriques trouvées par maximum de vraisemblance. Cela veut dire que le modèle de Gompertz-Makeham décrit bien la phase Non-Smurf.

Cependant, l'estimation des paramètres du taux de mortalité des Smurf K_1, K_2, D est plus difficile. Des écarts sont apparue entre les paramètres estimées par l'ABC-SMC est les paramètres théoriques de référence. Ceci, est du a deux erreurs soit une erreur de modèle ou bien que l'estimation par l'ABC n'est pas bonne. Toutefois, l'analyse des fonctions empiriques théoriques et moyennes a posteriori nous dit que la dynamique des populations est reproduite de manière satisfaisante. De plus, les trajectoires simulées de la population Smurf sur données réelles à partir des paramètres moyens de l'estimation reproduit correctement la courbe théorique de la population Smurf sur données réelles.

Ces résultats montrent que l'estimation des paramètres par l'ABC est pertinente. De plus cela met en évidence les limites de cette méthodes comme le problème d'identifiabilité de certain paramètres lorsque plusieurs paramètres donnent des dynamique de population très proche.

Toutefois, par faute de temps la dépendance entre les deux phases n'est pas pris en compte ce qui peut jouer énormément dans l'estimation. De plus, on peut se pencher sur différents algorithmes d'ABC plus optimisé comme l'ABC-Random Forest, ou bien même regarder si le nombre de génération a une influence sur l'estimation des paramètres.

5 Partie 3 – Étude de l'influence de la densité sur la transition vers l'état Smurf

5.1 Contexte de l'étude

Après avoir étudié le modèle sur des données simulées puis sur des données expérimentales, nous nous intéressons à une nouvelle question biologique soulevée lors des échanges avec la biologiste partenaire du projet.

Les expériences réalisées au laboratoire ne sont pas uniquement effectuées avec un nombre identique de mouches. Plusieurs densités initiales sont étudiées afin d'évaluer si le nombre d'individus présents dans un tube peut modifier la dynamique de vieillissement. Plus précisément, les expériences sont réalisées avec des tubes contenant initialement 20, 40 ou 60 mouches, avec cinq réplicats indépendants pour chacune de ces densités.

L'hypothèse biologique est que les interactions entre individus pourraient influencer l'apparition du phénotype *Smurf*. Une densité plus importante pourrait favoriser, ou au contraire ralentir, la transition des mouches de l'état *Non-Smurf* vers l'état *Smurf*. Cette hypothèse n'est pas prise en compte dans le modèle étudié jusqu'à présent et nécessite donc une analyse spécifique.

5.2 Objectifs de l'étude

L'objectif principal de cette nouvelle étude est de déterminer si la densité de population influence la vitesse de transition vers l'état *Smurf*.

Dans un premier temps, nous réalisons une analyse descriptive des données expérimentales afin d'observer l'évolution de la proportion de mouches *Smurf* au cours du temps pour chacune des trois densités étudiées. Cette première étape permet de mettre en évidence d'éventuelles différences entre les tubes contenant 20, 40 ou 60 mouches.

Dans un second temps, nous estimons directement à partir des observations un taux de passage empirique vers l'état *Smurf*. Pour un intervalle de temps $[t_i, t_{i+1}]$, ce taux est défini par

$$k_s(t_i) = \frac{\Delta S}{NS(t_i)\,\Delta t},$$

où $NS(t_i)$ désigne le nombre de mouches encore dans l'état *Non-Smurf* au début de l'intervalle, ΔS le nombre de nouvelles transitions observées durant cet intervalle et $\Delta t = t_{i+1} - t_i$ la durée séparant deux observations successives. Cette quantité constitue une estimation empirique du taux instantané de transition et permet de comparer directement les différentes densités sans faire intervenir, dans un premier temps, le modèle mathématique.

Enfin, les résultats obtenus sont confrontés au modèle développé dans les parties précédentes. Nous cherchons notamment à déterminer si le taux de transition dépend uniquement du temps ou s'il est également influencé par la densité de population. Conformément aux recommandations de notre encadrante, les paramètres F, G, H sont conservés à leurs valeurs théoriques (celles utilisées dans les parties précédentes), et nous introduisons un unique paramètre supplémentaire β traduisant l'effet de la densité **initiale** du tube N_0 :

$$k_s(t) = F + G\, e^{Ht} + \beta N_0.$$

Une formulation alternative, faisant intervenir la densité **courante** $N(t)$ (le nombre de mouches encore vivantes à l'instant t) via un paramètre γ, a également été envisagée. Les deux effets n'étant pas aisément distinguables l'un de l'autre lorsqu'ils sont introduits simultanément ($N(t)$ et N_0 étant fortement corrélés), nous les étudions dans un premier temps séparément, en commençant par β.

Si un effet de densité est mis en évidence, ce nouveau paramètre pourra ensuite être estimé par la méthode *Approximate Bayesian Computation – Sequential Monte Carlo* (ABC-SMC), afin d'intégrer cette dépendance au modèle et d'améliorer sa capacité à reproduire les observations expérimentales.

5.3 Vérification de la loi de transition empirique

Avant d'estimer β par ABC-SMC, nous proposons une première vérification visuelle directe, dans le même esprit que celle menée en Partie I : comparer, pour chaque densité initiale $N_0 \in \{20, 40, 60\}$, la fonction de répartition **empirique** du temps de transition Non-Smurf $\rightarrow$ Smurf (calculée à partir de la proportion cumulée de mouches Smurf observée, moyennée sur les 5 tubes répliques de chaque densité) à la fonction de répartition **théorique** associée au modèle $k_s(t) = F + G\, e^{Ht} + \beta N_0$, avec F, G, H fixés à leurs valeurs théoriques et pour plusieurs valeurs candidates de β (de 0 à 5×10^{-5}), afin d'évaluer visuellement si l'une de ces valeurs permet de rapprocher la théorie de l'observation.

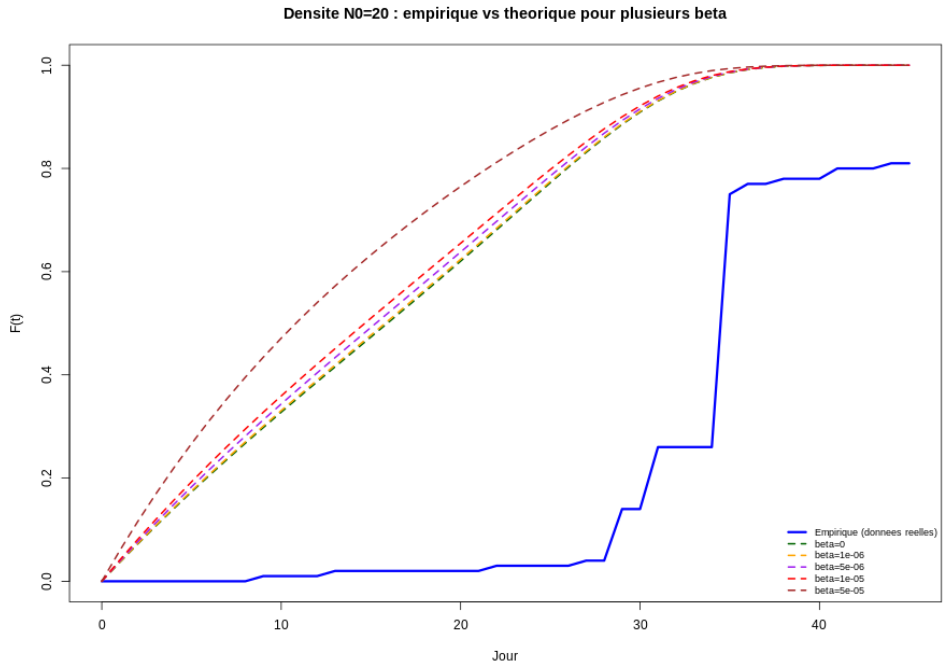


FIGURE 44 – Densité $N_0 = 20$: fonction de répartition empirique vs théorique, pour plusieurs valeurs de β.

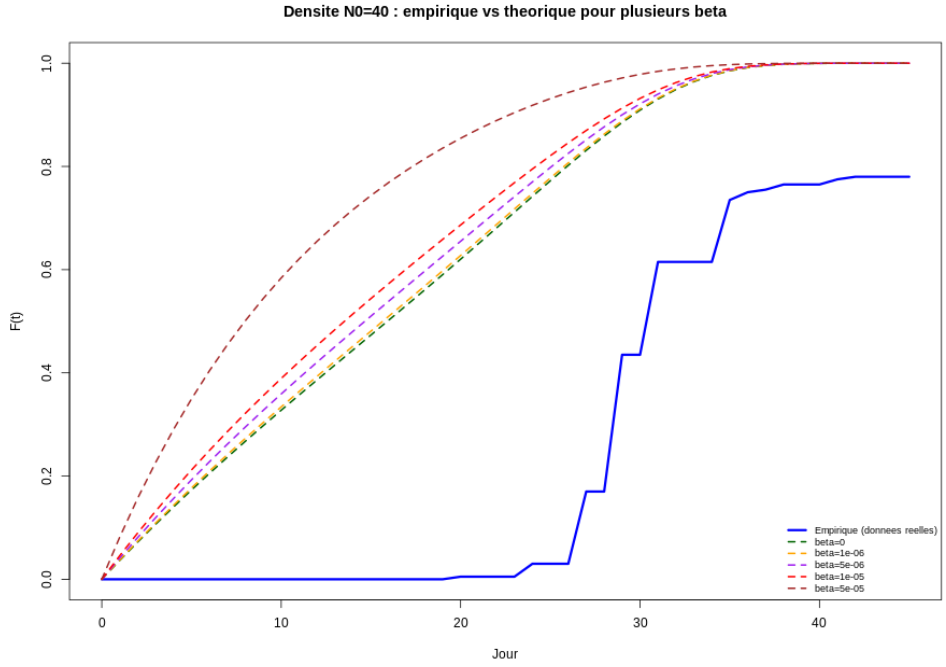


FIGURE 45 – Densité $N_0 = 40$: fonction de répartition empirique vs théorique, pour plusieurs valeurs de β.

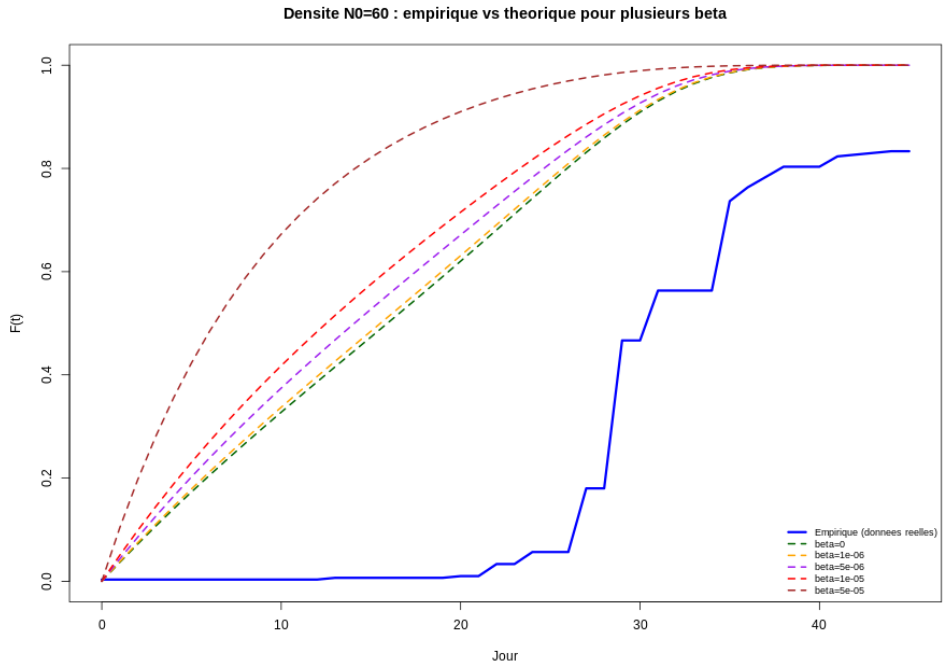


FIGURE 46 – Densité $N_0 = 60$: fonction de répartition empirique vs théorique, pour plusieurs valeurs de β.

Ces figures montrent un décalage important, pour les trois densités, entre la courbe empirique et l'ensemble des courbes théoriques testées : quelle que soit la valeur de β retenue, le modèle prédit une transition Non-Smurf $\rightarrow$ Smurf beaucoup plus précoce que ce qui est effectivement observé (la proportion empirique reste quasiment nulle jusqu'au jour 20–25, tandis que toutes les courbes théoriques, y compris pour $\beta = 0$, ont déjà largement dépassé 50 % de transition à ce stade).

Ce constat suggère que l'écart provient principalement des valeurs théoriques de F, G, H elles-mêmes – issues de la population de référence de l'article – plutôt que de l'absence d'un terme de densité : faire varier β seul ne suffit pas à corriger ce décalage temporel global, quelle que soit son amplitude. Cette observation invite à la prudence dans l'interprétation d'une estimation de β obtenue en gardant F, G, H fixes : une telle estimation risquerait de compenser artificiellement ce décalage global plutôt que de capturer un véritable effet de densité propre. C'est pourquoi, en parallèle, une estimation conjointe de F, G, H et β par ABC-SMC est également menée, afin de vérifier si l'algorithme retrouve des valeurs de F, G, H cohérentes avec les valeurs théoriques une fois ce paramètre supplémentaire introduit.

5.4 Estimation des paramètres grâce à l'algorithme ABC-SMC (Approximate Bayesian Computation Sequential Monte Carlo)

Dans cette partie nous allons nous concentrer sur l'estimation des paramètres de la transition de la phase Non-Smurf à Smurf grâce à l'algorithme ABC-SMC.

Fixons les variables utile dans l'algorithme :

— Nombres de particules : M = 1000

— Nombres de mouches : $N_0 = \{20{,}40{,}60\}$

— 5 tubes par N_0

Nous savons que pour approximer l'espérance, il faut simuler beaucoup de fois afin de satisfaire la loi des grands nombres ce qui n'est pas le cas en prenant 5 tubes par N_0. Ce choix est

du à notre volonté de coller avec les données réelles et par faute de temps.

Introduisons la formule de la distance utilisée :

$$d_5 = \sum_{N_0 \in \{20,40,60\}} \sqrt{\mathbb{E}[\sum_{i=1}^{T} (y_i^{obs}(N_0) - y_i^{sim}(N_0))^2]}$$

Ici $y_i^{obs}(N_0)$ représente la proportion de Smurf cumulé théorique au jour i pour le nombre initial de mouche N_0. De même pour les données simulées.

Cette estimation se déroulera en deux parties :

— **1ère partie :** Estimation du paramètre β en fixant (F, G, H, K_1, K_2, D).

— **2ème partie :** Estimations des 4 paramètres (F, G, H, β) en fixant (K_1, K_2, D).

5.4.1 Première partie estimation de β en fixant tous les autres paramètres F, G, H, K_1, K_2, D

Rappel : des paramètres théoriques

$$\begin{aligned} F &= 0.0014680557 \\ G &= 7.5447644 \times 10^{-5} \\ H &= 0.0066373291 \\ K_1 &= 0.0073127349 \\ K_2 &= 0.0293175233 \\ D &= 0.06715 \end{aligned}$$

Pour la simulation des données réelles on va d'abord choisir de fixer deux $\beta_{theo} = 10^{-6}$ et $\beta_{theo} = 5 * 10^{-6}$. Même si β_{theo} est inconnue, on va prendre le prendre très petit tel que $\beta_{theo} * N_0$ soit plus petit que l'ordre de grandeur du taux de passage quand $\beta = 0$ dans le modèle introduit auparavant.

Faisons une analyse des paramètres pour la **distance** d_5 avec $\beta_{theo} = 10^{-6}$.

on fixe une tolérance :

$$\epsilon_A = \epsilon_{proportion} = (1.8, 1.7, 1.5, 1.4, 1.2, 1.15)$$

Analyse des paramètres

```
Pour le paramètre beta :
  Moyenne des estimations : 1e-06
  Variance des estimations : 2.4e-13
  Intervalle de crédibilité à 95% : [ 0 ,  2e-06 ]
  Largeur de l'intervalle :  2e-06
```

FIGURE 47 – Analyse des paramètres

On remarque que la valeur moyenne de l'estimation de β est égale celle de la valeur théorique fixée. Cependant, la variance et la largeur de l'intervalle est grande.

Regardons son histogramme

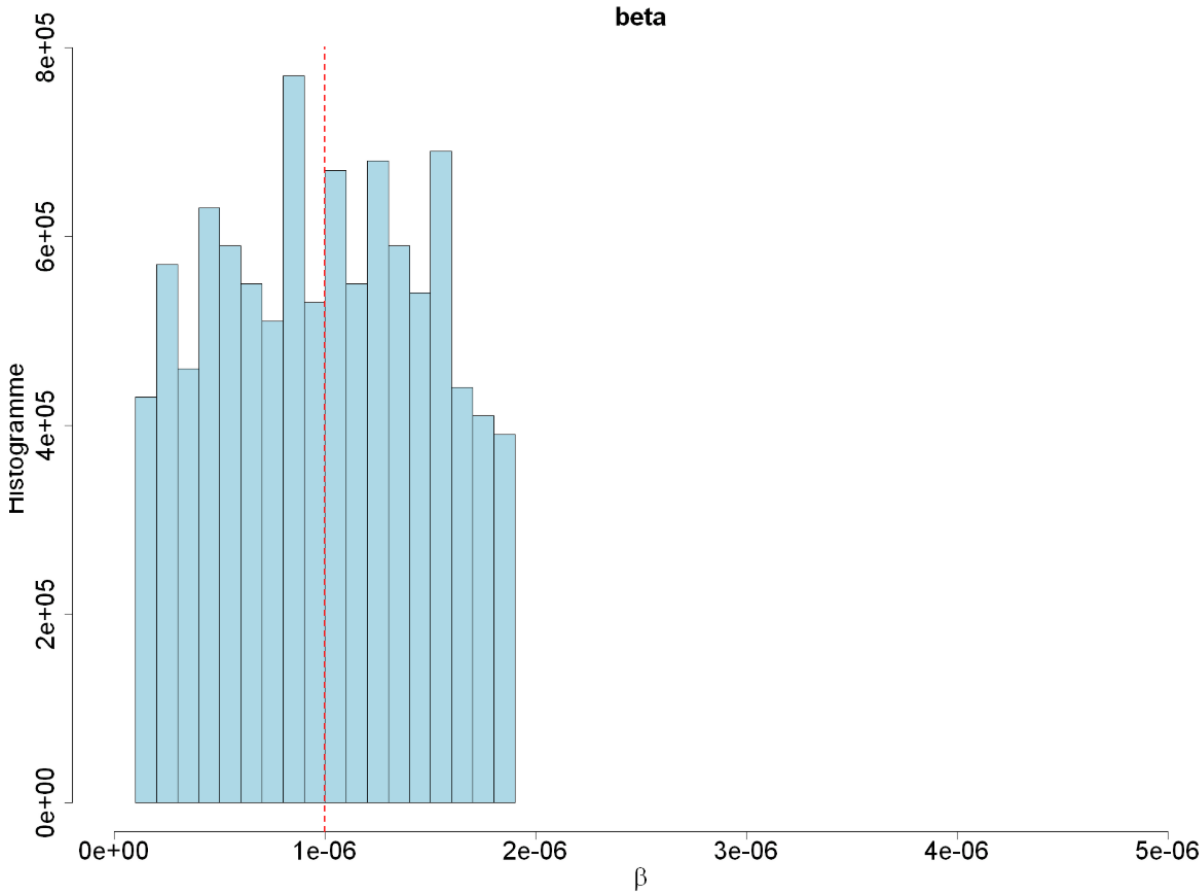


FIGURE 48 – Histogramme de β

On voit que la l'histogramme est centré autour de la valeur théorique fixée. Toutefois, on ne peut pas dire à 100% que l'ABC-SMC donne une bonne estimation car dans la distance l'espérance se base sur 5 tubes pour chaque N_0.

Faisons une analyse des paramètres pour la **distance** d_5 avec $\beta_{theo} = 5 * 10^{-6}$.

on fixe une tolérance :

$$\epsilon_A = \epsilon_{proportion} = (1.8, 1.7, 1.5, 1.4, 1.2, 1.15)$$

Analyse des paramètres

```
Pour le paramètre beta :
  Moyenne des estimations : 6e-06
  Variance des estimations : 4.206e-12
  Intervalle de crédibilité à 95% : [ 2e-06 ,  9e-06 ]
  Largeur de l'intervalle :  7e-06
```

FIGURE 49 – Analyse des paramètres

On remarque que la valeur moyenne de l'estimation de β est environ égale à la valeur théorique fixée. Cependant, la variance et la largeur de l'intervalle est également grande.

Regardons son histogramme

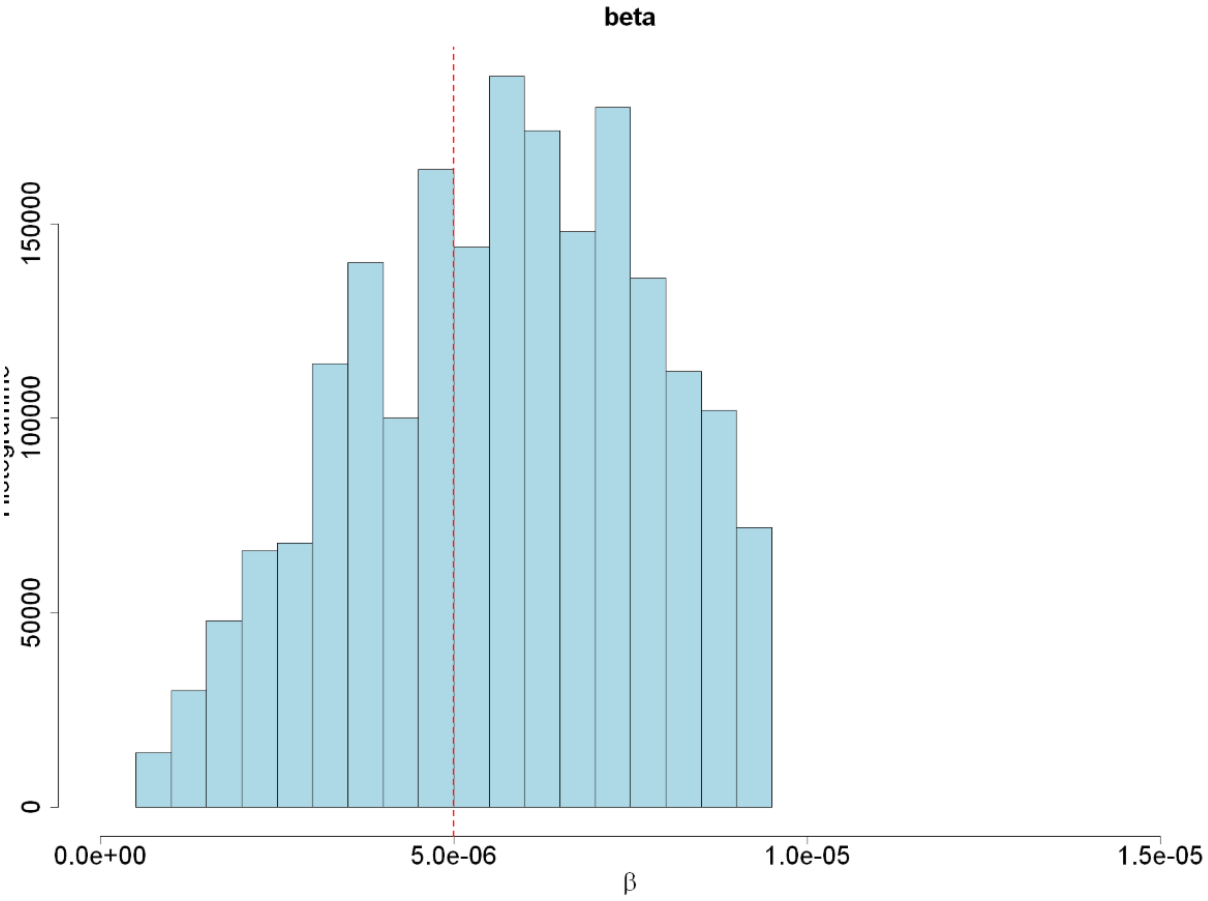


FIGURE 50 – Histogramme de β

On voit que l'histogramme est centré autour de la valeur théorique fixée de manière satisfaisante. Toutefois, on ne peut pas dire à 100% que l'ABC-SMC donne une bonne estimation car dans la distance l'espérance se base sur 5 tubes pour chaque N_0.

Par la suite nous allons utiliser $\beta_{theo} = 10^{-6}$ car c'est un peu meilleur.

5.4.2 Deuxième partie estimation de F, G, H, β en fixant tous les autres paramètres K_1, K_2, D

Faisons une analyse des paramètres pour la **distance** d_5 avec $\beta_{theo} = 10^{-6}$.

on fixe une tolérance :

$$\epsilon_A = \epsilon_{proportion} = (4, 3.7, 3.2, 2.7, 2.2, 1.7)$$

Analyse des paramètres

```
Pour le paramètre F :
  Moyenne des estimations : 0.001707
  Variance des estimations : 1.01e-07
  Intervalle de crédibilité à 95% : [ 0.00112 ,  0.002323 ]
  Largeur de l'intervalle :  0.001203
Pour le paramètre G :
  Moyenne des estimations : 7.3859e-05
  Variance des estimations : 1e-09
  Intervalle de crédibilité à 95% : [ 1.2e-05 ,  0.000138 ]
  Largeur de l'intervalle :  0.000126
Pour le paramètre H :
  Moyenne des estimations : 0.006865
  Variance des estimations : 2.416e-06
  Intervalle de crédibilité à 95% : [ 0.004139 ,  0.010337 ]
  Largeur de l'intervalle :  0.006198
Pour le paramètre beta :
  Moyenne des estimations : 1e-06
  Variance des estimations : 2.4e-13
  Intervalle de crédibilité à 95% : [ 0 ,  2e-06 ]
  Largeur de l'intervalle :  2e-06
```

FIGURE 51 – Analyse des paramètres

Regardons son histogramme

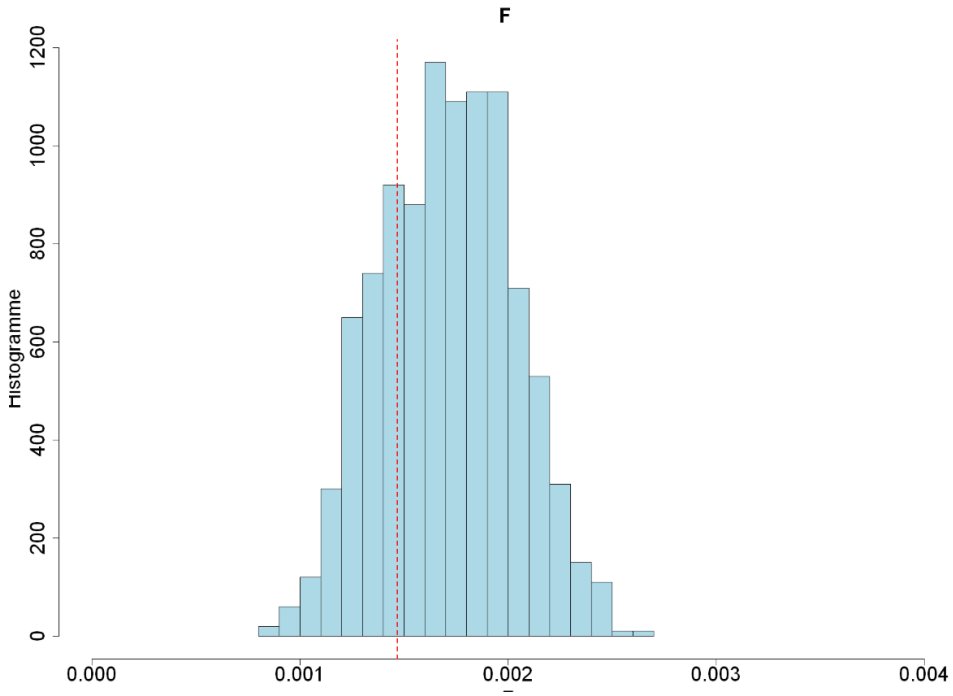


FIGURE 52 – Histogramme de F

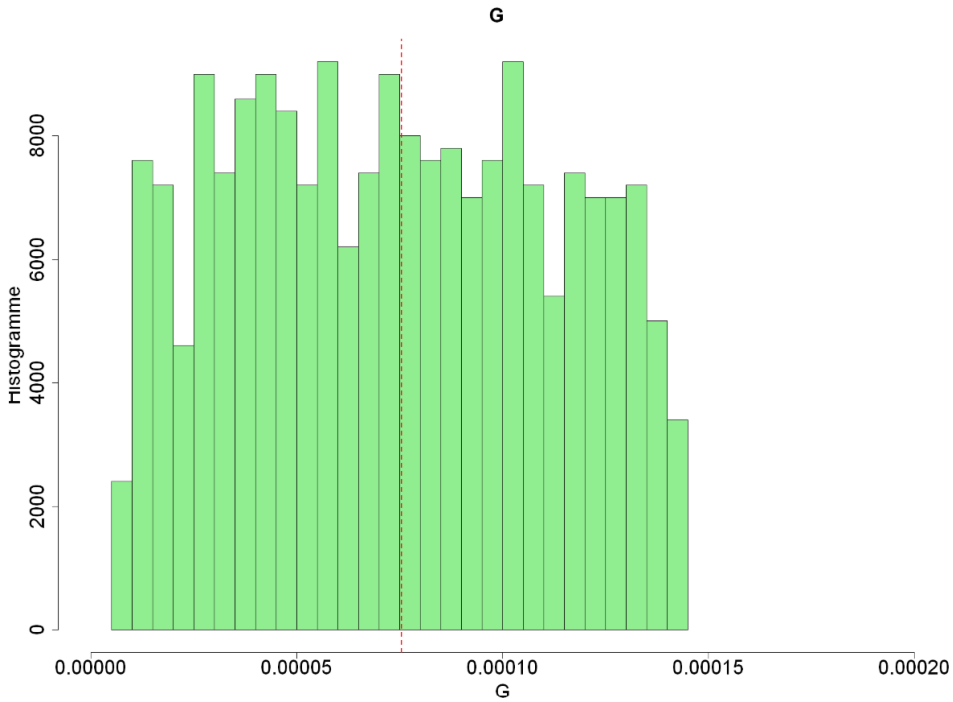


FIGURE 53 – Histogramme de G

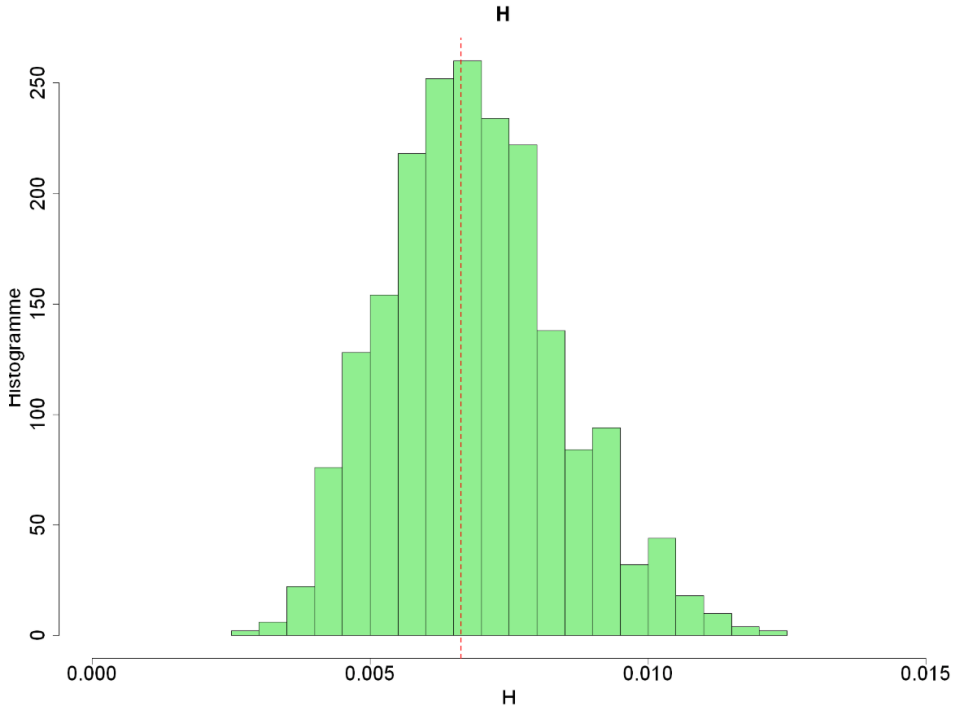


FIGURE 54 – Histogramme de H

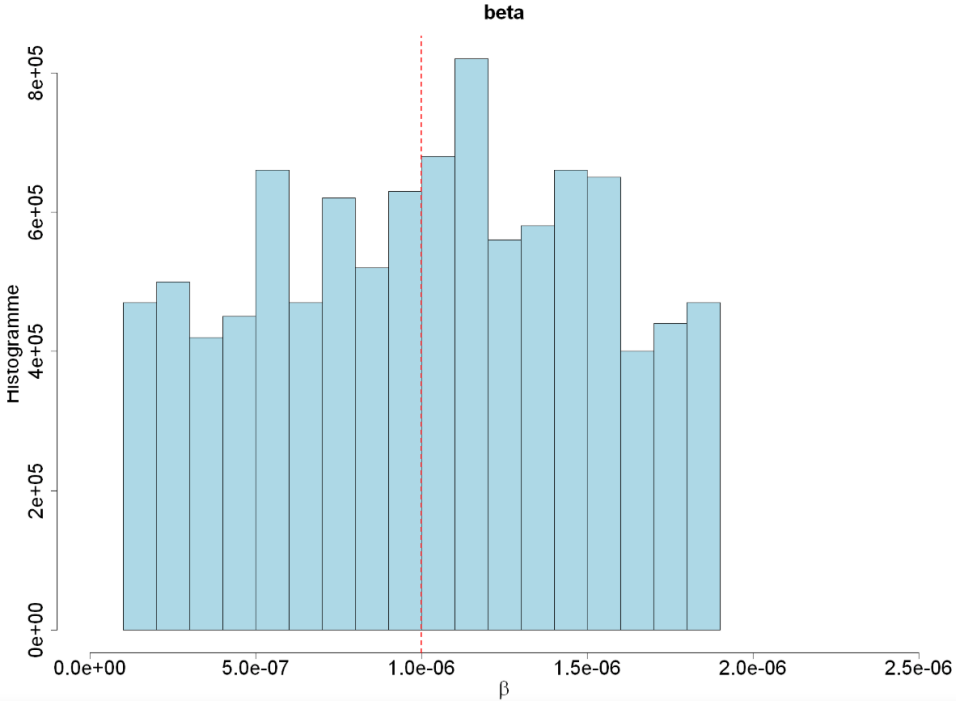


FIGURE 55 – Histogramme de β

On voit que les histogrammes de F, H, β sont assez centré autour de la valeur théorique fixée, cependant, c'est un peu moins évident pour G.

5.5 Confrontation des simulations aux données réelles

Afin d'évaluer si le modèle, une fois F, G, H et β estimés conjointement par ABC-SMC, parvient à reproduire la dynamique réellement observée, nous simulons des tubes virtuels avec les paramètres **moyens** obtenus sur les 1000 particules acceptées :

$$\overline{F} = 1{,}71 \times 10^{-3}, \quad \overline{G} = 7{,}39 \times 10^{-5}, \quad \overline{H} = 6{,}87 \times 10^{-3}, \quad \overline{\beta} = 1{,}01 \times 10^{-6}.$$

Pour chacune des trois densités ($N_0 = 20, 40, 60$), 1000 simulations indépendantes sont réalisées avec ce même jeu de paramètres moyens – seule la stochasticité de la simulation varie d'un tirage à l'autre. Cela permet d'isoler la variabilité due au simple bruit d'échantillonnage, à paramètres fixés, et de la comparer directement à la proportion cumulée de mouches Smurf réellement observée (moyennée sur les 5 tubes répliques de chaque densité).

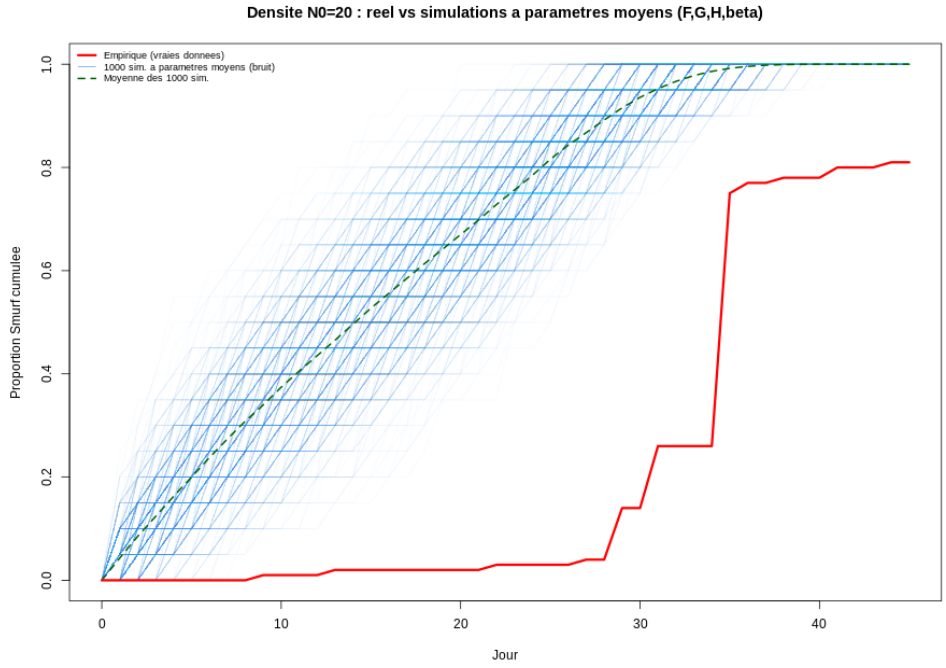


FIGURE 56 – Densité $N_0 = 20$: proportion cumulée de Smurf, réelle (rouge) vs 1000 simulations aux paramètres moyens estimés (bleu), et leur moyenne (vert).

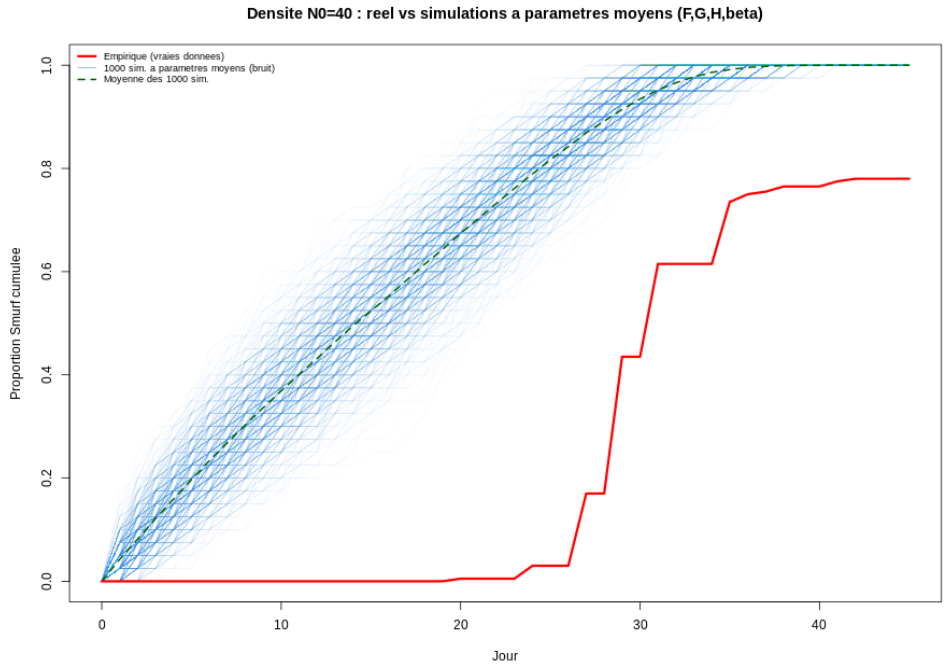


FIGURE 57 – Densité $N_0 = 40$: proportion cumulée de Smurf, réelle vs simulée aux paramètres moyens estimés.

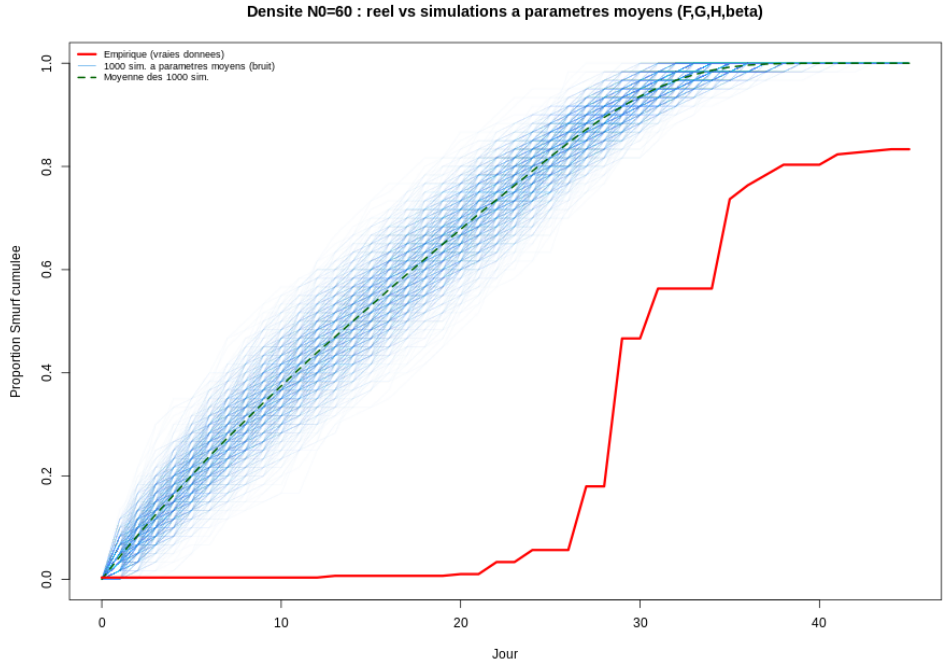


FIGURE 58 – Densité $N_0 = 60$: proportion cumulée de Smurf, réelle vs simulée aux paramètres moyens estimés.

Ces figures montrent un écart important et systématique entre la courbe observée et l'ensemble des simulations, pour les trois densités. À titre d'exemple, au jour 27, la proportion réelle de mouches Smurf est de 4 %, 17 % et 18 % pour $N_0 = 20, 40, 60$ respectivement, alors que la moyenne des 1000 simulations prédit déjà 87 % de transition, quelle que soit la densité. Cet

écart se maintient jusqu'au jour 35 (proportion réelle autour de 74–75 % contre plus de 99 % en simulation).

Deux constats se dégagent de cette confrontation. D'une part, même en laissant F, G, H libres en plus de β, l'algorithme ABC-SMC converge vers des valeurs de F, G, H proches des valeurs théoriques de référence (l'écart relatif reste inférieur à 20 % pour chacun des trois paramètres) : ce n'est donc pas un défaut de convergence de l'algorithme, mais bien une incompatibilité structurelle entre le modèle de référence et cette nouvelle population de mouches. D'autre part, la valeur de β obtenue est trop faible pour générer un écart notable entre les trois densités simulées, qui restent quasiment superposées – contrairement aux courbes réelles, nettement séparées entre le jour 24 et le jour 31.

Ce résultat est cohérent avec la vérification de la loi empirique menée dans la section précédente : le décalage observé provient principalement du calage de F, G, H sur une population de référence différente de celle utilisée dans cette expérience, et non d'un effet de densité mal quantifié par β. Faute de temps pour approfondir davantage cette piste dans le cadre du stage, ce point est identifié comme une limite importante de l'analyse et une direction claire pour un travail futur : il conviendrait de ré-estimer F, G, H spécifiquement sur les données de cette expérience (indépendamment de tout effet de densité), avant de chercher à quantifier un éventuel effet de N_0 ou $N(t)$ sur la transition Non-Smurf $\rightarrow$ Smurf.

5.6 Conclusion de la Partie 3

Cette dernière étude, menée sur l'expérience de densité proposée par notre encadrante biologiste, a permis de répondre partiellement à la question initiale tout en mettant en évidence une limite importante du modèle de référence sur cette nouvelle population.

L'analyse descriptive et la comparaison des taux de passage empiriques ont montré une différence nette entre densités : les tubes à 40 et 60 mouches transitionnent vers l'état Smurf plus rapidement que les tubes à 20 mouches, suggérant un véritable effet biologique de la densité de population sur la dynamique de vieillissement – même si cet effet ressemble davantage à un effet de seuil (40 et 60 se comportant de façon proche) qu'à une dépendance strictement linéaire en N_0.

L'estimation du paramètre β seul par ABC-SMC, sur données simulées avec une valeur théorique connue, a permis de valider le bon fonctionnement de la méthode : la moyenne a posteriori retrouve correctement β_{theo}, bien que la variance reste importante – une limite attendue compte tenu du faible nombre de tubes disponibles par densité (5), insuffisant pour bien approximer l'espérance intervenant dans la distance d_5.

En revanche, l'estimation conjointe de F, G, H et β sur les données réelles de cette expérience a révélé un résultat plus nuancé : bien que les valeurs de F, G, H retrouvées restent proches des valeurs théoriques de référence (écart relatif inférieur à 20 %), les simulations obtenues avec ces paramètres moyens surestiment très largement la vitesse de transition observée, et ce pour les trois densités. Ce résultat indique que l'écart ne provient pas d'un défaut de convergence de l'algorithme ABC-SMC, mais d'une incompatibilité structurelle entre le modèle calé sur la population de référence de l'article et la population de mouches utilisée dans cette expérience de densité. Cette incompatibilité limite fortement la portée de l'estimation de β obtenue : celle-ci risque de compenser artificiellement le mauvais calage global plutôt que de refléter un véritable effet de densité.

Faute de temps pour aller plus loin, cette incompatibilité constitue la principale limite de cette dernière partie. Un travail futur consisterait à ré-estimer F, G, H spécifiquement sur les données de cette population (indépendamment de tout effet de densité), avant de chercher à quantifier plus précisément l'effet de N_0, voire de tester d'autres formes fonctionnelles pour cet effet (par exemple un effet de seuil ou une dépendance à la densité courante $N(t)$ plutôt qu'à la densité initiale), afin de mieux rendre compte du comportement observé.

6 Conclusion générale

Ce stage avait pour objectif d'évaluer la capacité de la méthode Approximate Bayesian Computation – Sequential Monte Carlo (ABC-SMC) à estimer les paramètres d'un modèle de vieillissement biphasique chez la drosophile, en s'appuyant successivement sur des données simulées, des données expérimentales publiées, puis sur une nouvelle question biologique soulevée en cours de stage.

La première partie, menée sur des données simulées, a permis de valider la méthode dans un cadre contrôlé où les paramètres théoriques sont connus. L'estimation des paramètres F, G, H gouvernant la transition Non-Smurf $\rightarrow$ Smurf s'est révélée fiable, avec des erreurs relatives inférieures à 7 %. L'estimation des paramètres K_1, K_2, D gouvernant la mortalité en phase Smurf s'est avérée plus délicate, notamment pour K_1, en raison d'un problème d'identifiabilité lié à la faible fenêtre temporelle sur laquelle l'information est disponible – un problème que l'enrichissement de la distance (prise en compte de la proportion de mouches Smurf) a permis d'atténuer sensiblement. L'analyse de la fonction de mortalité $\kappa(a)$ a posteriori a par ailleurs montré que la courbe moyenne reconstruite restait proche de la théorie malgré la dispersion des paramètres estimés individuellement, illustrant l'intérêt d'une analyse fonctionnelle complète plutôt qu'une simple lecture des erreurs relatives ponctuelles.

La deuxième partie, appliquant cette même méthode aux données expérimentales de l'article de référence, a globalement confirmé la validité du modèle 3 pour décrire la transition Non-Smurf $\rightarrow$ Smurf : les paramètres F, G, H estimés sur données réelles restent cohérents avec ceux obtenus par maximum de vraisemblance. La phase de mortalité Smurf est apparue plus difficile à décrire fidèlement par ce modèle, avec des écarts plus marqués selon la distance utilisée ; la vérification de la loi reconstruite a néanmoins montré que la courbe moyenne a posteriori restait globalement proche de l'observation, en dehors des toutes premières heures suivant la transition.

La troisième partie, consacrée à l'étude de l'effet de la densité de population, a permis de mettre en évidence un effet biologique réel de la densité sur la vitesse de transition, tout en révélant une limite plus fondamentale : les paramètres F, G, H de référence, initialement calés sur la population de l'article, ne décrivent pas correctement la dynamique de cette nouvelle population de mouches, indépendamment de tout effet de densité. Ce constat, obtenu de manière rigoureuse par confrontation directe des simulations aux données réelles, constitue une limite importante mais aussi un résultat scientifique à part entière : il montre que la généralisation d'un modèle calé sur une population donnée à une nouvelle population n'est pas immédiate, et qu'elle nécessite une étape de recalibration préalable avant toute interprétation biologique des effets recherchés.

Au-delà des résultats obtenus sur chacune des trois parties, ce stage a permis de mettre en pratique l'ensemble de la démarche de modélisation statistique par méthodes bayésiennes approchées : construction et optimisation d'un simulateur, choix et comparaison de plusieurs fonctions de distance, analyse critique des résultats (au-delà des seules erreurs relatives), et confrontation systématique des modèles aux données réelles. Les limites identifiées, en particulier sur la Partie 3, ouvrent des perspectives claires pour un travail futur : ré-estimation des paramètres de base sur chaque nouvelle population étudiée, exploration de formes fonctionnelles alternatives pour l'effet de densité, et éventuellement recours à des outils de simulation individu-centrée dédiés pour consolider ces résultats.

Annexe A Analyse des paramètres et traçage de leurs histogrammes avec la distance d_1

Pour la distance d_1, on fixe $\epsilon = (9000\ ,\ 8000\ ,\ 6000\ ,\ 5000\ ,\ 4000\ ,\ 3000)$

Analysons l'estimation des paramètres ainsi que leurs histogrammes

Analyse des paramètres

```
Pour le paramètre K1 :
  Moyenne des estimations : 0.0119
  Variance des estimations : 2.6e-06
  Intervalle de crédibilité à 95% : [ 0.007717 ,  0.013802 ]
  Largeur de l'intervalle :  0.006085
  Ecart avec le paramètre du modèle 3 :  0.627243

Pour le paramètre K2 :
  Moyenne des estimations : 0.03556946
  Variance des estimations : 0.00018179
  Intervalle de crédibilité à 95% : [ 0.007532 ,  0.054967 ]
  Largeur de l'intervalle :  0.047435
  Ecart avec le paramètre du modèle 3 :  0.2132492

Pour le paramètre D :
  Moyenne des estimations : 0.046241
  Variance des estimations : 0.00107323
  Intervalle de crédibilité à 95% : [ 0.007599 ,  0.117973 ]
  Largeur de l'intervalle :  0.110374
  Ecart avec le paramètre du modèle 3 :  0.3113712
```

FIGURE 59 – Analyse des paramètres

On remarque que l'écart entre les deux résultats sont grands : environ 60% pour K_1 et 30%.

Regardons leurs histogrammes

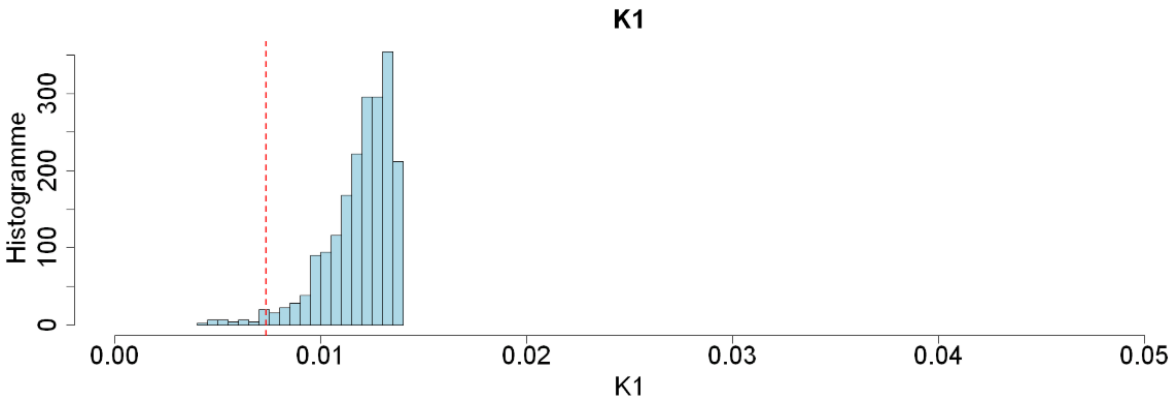


FIGURE 60 – Histogramme de K1

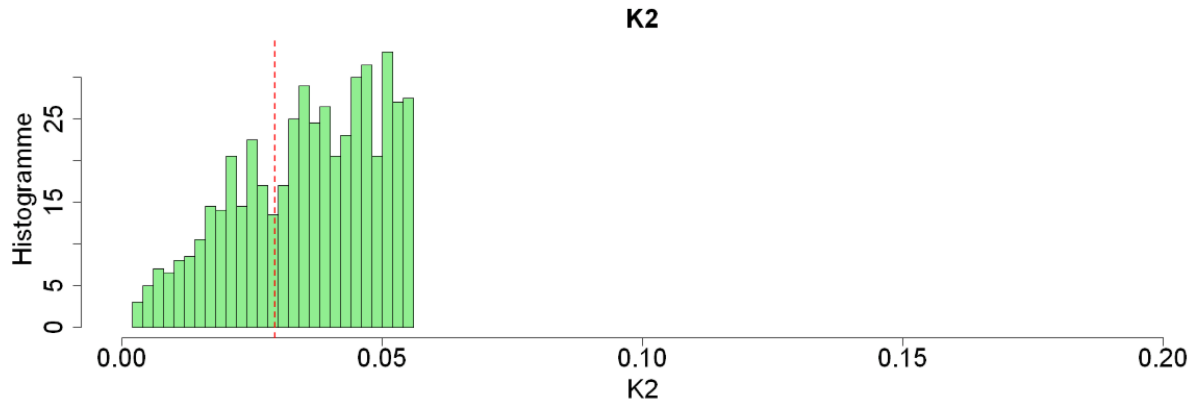


FIGURE 61 – Histogramme de K2

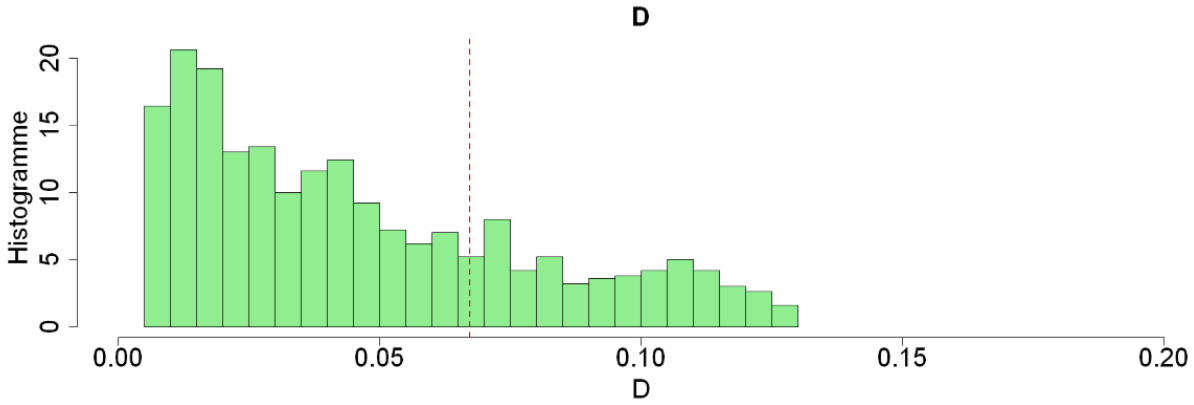


FIGURE 62 – Histogramme de D

Même conclusion que pour la distance d_4.

Annexe B Tracage de la population Smurf sur les données réelles avec la distance d_1

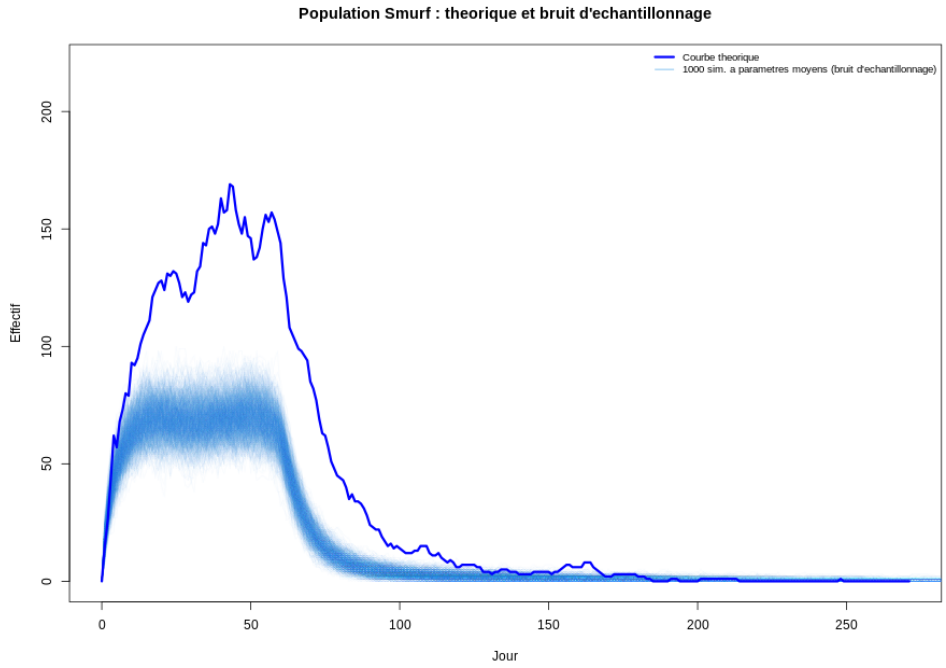


FIGURE 63 – Population Smurf sur données réelles (distance d_1) : trajectoire simulée aux paramètres moyens vs bruit d'échantillonnage (1000 simulations stochastiques, temps exprimé en jours).

On remarque qu'il y a un très grand écart entre la courbe théorique et les trajectoires simulées. On remarque également que ces trajectoires sous estiment la courbe théorique.

7 Bilan : Organisation, mission et acquisition

7.1 Présentation de la structure d'accueil et de l'entreprise

Ce stage est réalisé au LAGA qui est un laboratoire associé au CNRS, rattaché à l'Institut Galilée, composante de l'Université Sorbonne Paris Nord. Dans ce laboratoire, beaucoup de thèmes de recherches sont abordés comme l'arithmétique, la géométrie algébrique, la théorie des nombre etc.

Ce laboratoire est structuré en 8 équipes de recherches
— Arithmétique et géométrie algébrique (AGA)
— Algèbre, Géométrie, Combinatoire et applications à la Cryptographie et au Codage (AGC3)
— Modélisation et Calcul scientifique (MCS)
— Physique mathématique et Équations aux dérivées partielles (PM)
— Mathématiques pour la Biologie et les Images (MBI)
— Probabilités et Statistiques (PS)
— Théorie ergodique et Systèmes dynamiques (SD)
— Topologie Algébrique (TA)
Enfin, les résultats des recherches sont concrétisés par des séminaires permanents ou épisodiques. Toutes ces informations sont retrouvable sur le site du LAGA [6]

Ce stage s'est porté sur l'étude du vieillissement de la drosophile et plus précisément sur la transition entre les états Non-Smurf à Smurf et Smurf à mort. Dans ce projet, nous avons utilisé différents modèles mathématiques, données statistiques expérimentales et données statistiques de référence. Nous avons été encadrés par notre enseignante/maître de conférence Mme Kaakaï Sarah.

7.2 Organisation quotidiennes du travail

L'organisation du travail est centrée autour d'un cycle régulier : comprendre le problème et les données, trouver le bon modèle mathématique, développer du code, analyser les résultats et les comparer avec les données théoriques ou expérimentales. Cette démarche est répétée afin d'améliorer constamment les résultats.

Voici les étapes :
— lecture et compréhension des modèles de vieillissement et des articles scientifiques
— préparation et traitement des données afin de disposer des temps de transition et de décès sous une forme exploitable
— développement et optimisation du simulateur numérique
— exécution de nombreuses simulations nécessaires à l'ABC-SMC
— analyse des paramètres estimés, des histogrammes, des courbes et des erreurs
— interprétation des résultats et recherche de solutions lorsque certaines estimations étaient difficiles
— application de la méthodologie aux données réelles puis à l'étude de l'effet de la densité

7.3 Tâches réalisées pendant le stage

Notre première tâche était de comprendre le fonctionnement du modèle 3 pour décrire le vieillissement. Nous avons étudié le taux de transition et de mortalité, leurs fonctions de survies et les rôles des différents paramètres F, G, H, K_1, K_2, D. Nous avons ensuite mis en œuvre un simulateur permettant de générer les temps de transition des individus et nous avons reconstruit l'évolution des populations Non-Smurf, Smurf et décédées. Une partie importante du travail s'est portée sur l'estimation des paramètres par l'ABC-SMC. Nous avons estimé dans un premier temps

les 3 premiers paramètres F, G, H en fixant les 3 derniers K_1, K_2, D et vice-versa en utilisant plusieurs distances et plusieurs statistiques résumées afin d'obtenir une potentielle amélioration. Nous avons ensuite comparé les simulations obtenues aux données théoriques afin d'évaluer la qualité d'estimation.

La même démarche a ensuite été appliquée aux données expérimentales réelles. Enfin, une nouvelle étude a été réalisée pour rechercher un éventuel effet de la densité de population sur la transition vers l'état Smurf, en comparant des tubes contenant 20, 40 ou 60 mouches.

7.4 Partie techniques du travail

La partie technique du travail s'est porté la programmation, la simulation et le choix de la statistique résumé. Dans un premier temps, nous avons hésité sur quelle fonction utiliser pour résoudre les équations issues de la fonction de survie. Par la suite, nous avons également mis en place un système de cache afin d'éviter de recalculer une simulation déjà obtenue pour un même jeu de paramètres.

Nous avons utilisé l'algorithme ABC-SMC (Approximate Bayesian Computation Sequential Monte Carlo) afin d'obtenir une approximation de la loi des paramètres sachant les données. Le principe retenir les paramètres simulés qui se reproche le plus des paramètres théoriques. Cela se fait sur plusieurs générations avec une tolérance qui diminue progressivement.

Nous avons remarqué que l'estimation des paramètres F, G, H et plus précise et plus "simple" que K_1, K_2, D. Ceci est du au comportement des mouches dans la phase Smurf, car elles décèdent directement dans les heures qui suivent leurs transitions donc on a pas le temps de capturer assez d'information. Pour pallier à cela, nous choisissons judicieusement la distance et les statistiques résumées.

7.5 Ceux que nous avons appris

— comprendre un modèle mathématique et retranscrire les informations issues d'un modèle biologique réelle
— mettre en œuvre et valider les résultats simulés en comparant avec les paramètres théoriques
— utiliser des méthodes d'Inférence Bayésienne, notamment l'algorithme ABC-SMC et l'importance du choix de la distance et des statistiques résumées
— identifier les difficultés d'estimations
— analyser les données réelles après avoir valider les méthodes d'estimations sur les données simulées
— analyser et critiquer les résultats obtenus

7.6 Bilan

Ce stage nous a permis de découvrir un travail de recherche statistique mêlant plusieurs domaines. Nous avons appris à être plus critique au niveau des résultats obtenus en vérifiant le modèle, en testant les hypothèses, en analysant le choix des tolérances et distances.

Nous avons progressé au niveau de notre autonomie. Face à certaines difficultés, nous avons su proposer et explorer plusieurs pistes. L'étude de densité nous a montré l'importance de savoir remettre en question un modèle lorsque ses hypothèses ne permettent plus de reproduire correctement une nouvelle expérience.

Enfin, nous retenons à la fois des compétences techniques en programmation, simulation et statistique, et une méthode de travail plus générale :

— comprendre le problème
— construire une solution
— la valider
— analyser ses limites et proposer des pistes d'amélioration

8 Références

Références

[1] Hervé Tricoire and Michael Rera. A new, discontinuous 2 phases of aging model : Lessons from Drosophila melanogaster. *PLoS ONE*, 10(11) :e0141920, November 2015. https://hal.science/hal-02347534v1.

[2] Luce Breuil, Marie Doumic, Sarah Kaakai, and Michaël Rera. Acute Smurf mortality and age-dependence in a two-phase ageing model : Statistical inference from drosophila and mice experimental data. *bioRxiv*, April 2026. https://www.biorxiv.org/content/10.64898/2026.02.18.706552v3.full.pdf+html.

[3] Bayesian Statistics. Approximate bayesian computation, 2025. https://bayesianstatistics.com/Approximate_Bayesian_Computation.

[4] Mario Castro. Approximate bayesian computation made easy : A practical guide to abc-smc for dynamical systems, 2025. https://arxiv.org/html/2511.21587v1.

[5] Luce Breuil, Marie Doumic, Sarah Kaakai, and Michaël Rera. Experience's data, 2025. https://github.com/luce-breuil/smurf_stat/tree/main.

[6] LAGA. Laga. https://www.math.univ-paris13.fr/.

[7] Yacques Cheng Li and Damien Gandrey. Méthodes abc - taux de transition la modélisation du vieillissement, 2026. https://github.com/YChengLi31/methodes-abc-estimation-parametres-modeles-epidemiologiques/tree/main/Taux%20de%20transition%20la%20mod%C3%A9lisation%20du%20vieillissement.